



ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

ΕΛΕΝΗ ΣΤΥΛΙΑΝΟΥ

«ΑΞΙΟΠΟΙΗΣΗ ΤΕΧΝΙΚΩΝ ΒΑΘΙΑΣ ΕΝΙΣΧΥΤΙΚΗΣ
ΜΑΘΗΣΗΣ ΓΙΑ ΣΧΕΔΙΑΣΜΟ ΔΙΑΔΡΟΜΗΣ ΚΑΙ
ΑΠΟΦΥΓΗ ΕΜΠΟΔΙΩΝ ΣΕ ΣΥΣΤΗΜΑΤΑ ΣΜΗΝΩΝ
 $U \times V$ »

ΣΤΗΝ ΕΠΙΣΤΗΜΟΝΙΚΗ ΠΕΡΙΟΧΗ:
ΤΕΧΝΗΤΗ ΝΟΗΜΟΣΥΝΗ - ΔΙΚΤΥΑ - ΠΛΗΡΟΦΟΡΙΚΗ

ΕΠΙΒΛΕΠΩΝ:

Ιάκωβος Στ. Βενιέρης, Καθηγητής ΣΗΜΜΥ

ΤΡΙΜΕΛΗΣ ΕΠΙΤΡΟΠΗ

Ιάκωβος Στ. Βενιέρης, Καθηγητής ΣΗΜΜΥ

Αντώνιος Συμβώνης, Καθηγητής ΣΕΜΦΕ

Ιωάννης Μπαρτσιώκας, Ε.ΔΙ.Π

Αθήνα, Ιούνιος 2026

ΕΥΧΑΡΙΣΤΙΕΣ

Η παρούσα διπλωματική εργασία σηματοδοτεί την λήξη μιας σημαντικής περιόδου των προπτυχιακών σπουδών μου και θα ήταν παράλειψη να μην αναγνωρίσω την αμέριστη συνεισφορά όσων με στήριξαν κατά την εκπόνηση της.

Καταρχάς, θα ήθελα να ευχαριστήσω τον επιβλέποντα της εργασίας, Καθηγητή κ. Ιάκωβο Στ. Βενιέρη, για την ευκαιρία που μου παρείχε να ασχοληθώ με το παρόν θέμα στο Εργαστήριο Ευφών Επικοινωνιών και Δικτύων Ευρείας Ζώνης της Σχολής Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών του Εθνικού Μετσόβιου Πολυτεχνείου.

Θερμές και ξεχωριστές ευχαριστίες οφείλω στον συνεπιβλέποντα Δρ. Ιωάννη Μπαρτσιώκα, ο οποίος υπήρξε καθημερινός συνεργάτης καθ' όλη τη διάρκεια εκπόνησης της εργασίας. Η συνεχής καθοδήγηση του, οι εποικοδομητικές παρατηρήσεις και η διαθεσιμότητα του να συζητήσει τόσο τις τεχνικές λεπτομέρειες της υλοποίησης όσο και τις ευρύτερες ερευνητικές κατευθύνσεις, αποτέλεσαν καθοριστικούς παράγοντες για την ολοκλήρωση της παρούσας μελέτης.

Θα ήθελα ακόμη να εκφράσω την ευγνωμοσύνη μου στους συμφοιτητές μου, με τους οποίους διανύσαμε μαζί αυτό το μονοπάτι των σπουδών, για τις πολυάριθμες ώρες κοινής μελέτης, εργαστηρίων και συζητήσεων που μοιραστήκαμε όλα αυτά τα χρόνια.

Δεν θα μπορούσα να κλείσω χωρίς να ευχαριστήσω την οικογένεια μου, η οποία στάθηκε δίπλα μου σε κάθε στάδιο των σπουδών μου, αλλά και τους φίλους μου, που με συντρόφεψαν σε όλη αυτή την πορεία.

.....
Ελένη Στυλιανού

© (2026) Εθνικό Μετσόβιο Πολυτεχνείο. All rights Reserved. Απαγορεύεται η αντιγραφή, αποθήκευση και διανομή της παρούσας εργασίας, εξ ολοκλήρου ή τμήματος αυτής, για εμπορικό σκοπό. Επιτρέπεται η ανατύπωση, αποθήκευση και διανομή για σκοπό μη κερδοσκοπικό, εκπαιδευτικής ή ερευνητικής φύσης, υπό την προϋπόθεση να αναφέρεται η πηγή προέλευσης και να διατηρείται το παρόν μήνυμα. Ερωτήματα που αφορούν τη χρήση της εργασίας για κερδοσκοπικό σκοπό πρέπει να απευθύνονται προς το συγγραφέα. Οι απόψεις και τα συμπεράσματα που περιέχονται σ' αυτό το έγγραφο εκφράζουν το συγγραφέα και δεν πρέπει να ερμηνευτεί ότι αντιπροσωπεύουν τις επίσημες θέσεις του Εθνικού Μετσόβιου Πολυτεχνείου.

Η παρούσα διπλωματική εργασία ασχολείται με την αξιοποίηση τεχνικών Βαθιάς Ενισχυτικής Μάθησης (Deep Reinforcement Learning, DRL) για τον σχεδιασμό διαδρομής και την αποφυγή εμποδίων σε συστήματα σμηγών μη επανδρωμένων οχημάτων (UxV). Πρωταρχικός στόχος της εργασίας είναι η ανάπτυξη και αξιολόγηση πρακτόρων ικανών να πλοηγούνται αυτόνομα σε περιβάλλοντα με εμπόδια, τόσο μεμονωμένα όσο και ως μέλη συντονισμένου σμήνους, αξιοποιώντας αποκλειστικά τοπικές παρατηρήσεις.

Το θεωρητικό υπόβαθρο περιλαμβάνει τις αρχές της Ενισχυτικής Μάθησης και της Βαθιάς Μάθησης, με έμφαση στον αλγόριθμο Deep Q-Network (DQN) και στις επεκτάσεις του, όπως το Double DQN. Παράλληλα, αναλύονται οι αρχές της συνοχής, του διαχωρισμού και της ευθυγράμμισης σμήνους, καθώς και οι σύγχρονες προσεγγίσεις DRL για συστήματα πολλαπλών πρακτόρων.

Η κεντρική ιδέα της μελέτης είναι η χρήση ενός κοινού πράκτορα Double DQN, υλοποιημένου εξ ολοκλήρου σε NumPy, ο οποίος εκπαιδεύεται να πλοηγείται σε περιβάλλον δύο διαστάσεων με στοχαστικά τοποθετημένα εμπόδια. Επιπλέον, για την επέκταση σε σμήνος αναπτύχθηκε ειδική συνάρτηση ανταμοιβής που ενθαρρύνει τη συλλογική συμπεριφορά. Επιπρόσθετα, για την μελέτη του προβλήματος διερευνήθηκαν δύο στρατηγικές εκπαίδευσης, εκπαίδευση σε σταθερό περιβάλλον και εκπαίδευση με Curriculum Learning, όπου το σμήνος εκτίθεται προοδευτικά σε τυχαία περιβάλλοντα για καλύτερη γενίκευση.

Τα αποτελέσματα της μελέτης καταδεικνύουν ότι ο αλγόριθμος Double DQN με κατάλληλη διαμόρφωση ανταμοιβής επιτυγχάνει αποτελεσματική πλοήγηση τόσο σε μονό UAV όσο και σε σμήνη διαφορετικών μεγεθών. Η συγκριτική αξιολόγηση των δύο στρατηγικών εκπαίδευσης υποδεικνύει ότι το Curriculum Learning ευνοεί πιο ομοιόμορφη γενίκευση σε άγνωστα περιβάλλοντα, ενώ η εκπαίδευση σε σταθερό περιβάλλον ευνοεί την εξειδίκευση.

Εν κατακλείδι, η διπλωματική εργασία αποδεικνύει τη δυνατότητα αξιοποίησης τεχνικών DRL για τον αποτελεσματικό συντονισμό σμήνους UAV σε πολύπλοκα περιβάλλοντα, συνεισφέροντας στην ερευνητική περιοχή των αυτόνομων συστημάτων πολλαπλών πρακτόρων.

Λέξεις κλειδιά: Βαθιά Ενισχυτική Μάθηση, Deep Q-Network, Σμήνος UAV, Σχεδιασμός Διαδρομής, Αποφυγή Εμποδίων, Reward Shaping, Curriculum Learning, Συστήματα Πολλαπλών Πρακτόρων

ABSTRACT

This thesis investigates the application of Deep Reinforcement Learning (DRL) techniques for path planning and obstacle avoidance in Unmanned Vehicle (UxV) swarm systems. The primary objective is development and evaluation of agents capable of navigating autonomously in obstacle-laden environments, both individually and as members of a coordinated swarm, relying exclusively on local observations.

The theoretical background encompasses the principles of Reinforcement Learning and Deep Learning, with emphasis on the Deep Q-Network (DQN) algorithm and its extensions, most notably Double DQN. Furthermore, the principles of swarm cohesion, separation, and alignment are analyzed, along with contemporary DRL approaches for multi-agent systems.

The central concept of the study is the use of a shared Double DQN agent, implemented entirely in NumPy, trained to navigate a two-dimensional environment with stochastically placed obstacles. In addition, a dedicated reward function was developed to encourage collective swarm behavior. Two training strategies were also investigated training in a fixed environment and Curriculum Learning, where the swarm is progressively exposed to randomized environments to improve generalization.

The study's findings demonstrate that the Double DQN algorithm with appropriate reward shaping achieves effective navigation for both single UAV and multi-UAV swarm configurations. Comparative evaluation of the two training strategies indicates that Curriculum Learning favors more uniform generalization to unseen environments, while fixed-environment training favors specialization.

In conclusion, this thesis highlights and contributes the potential of DRL techniques for effective UAV swarm coordination in complex environments, contributing to the research area of autonomous multi-agent systems.

Keywords: Deep Reinforcement Learning, Deep Q-Network, UAV Swarm, Path Planning, Obstacle Avoidance, Reward Shaping, Curriculum Learning, Multi-Agent Systems

ΠΕΡΙΕΧΟΜΕΝΑ

ΕΥΧΑΡΙΣΤΙΕΣ	i
ΠΕΡΙΛΗΨΗ	ii
ABSTRACT	iii
ΚΑΤΑΛΟΓΟΣ ΕΙΚΟΝΩΝ	ix
ΚΑΤΑΛΟΓΟΣ ΠΙΝΑΚΩΝ	x
ΚΑΤΑΛΟΓΟΣ ΣΥΝΤΟΜΟΓΡΑΦΙΩΝ	xi
ΚΕΦΑΛΑΙΟ 1: Εισαγωγή	1
1.1 Κίνητρο και Ερευνητικό Πρόβλημα	1
1.2 Αντικείμενο Διπλωματικής Εργασίας	1
1.3 Διάρθρωση Εργασίας	2
ΚΕΦΑΛΑΙΟ 2: Βασικές Αρχές Τεχνητής Νοημοσύνης και Ενισχυτικής Μάθη- σης	3
2.1 Τεχνητή Νοημοσύνη και Μηχανική Μάθηση	3
2.1.1 Τεχνητή Νοημοσύνη	3
2.1.2 Μηχανική Μάθηση	4
2.1.3 Βαθιά Μάθηση	4
2.1.4 Κατηγορίες Μηχανικής Μάθησης	5
2.1.5 Τυπική Ροή Εργασιών Μηχανικής Μάθησης	6
2.2 Βασικές Έννοιες Ενισχυτικής Μάθησης	8
2.2.1 Διαδικασίες Απόφασης Markov (MDP)	8
2.2.2 Συνάρτηση Αξίας και Πολιτική	9
2.2.3 Συνάρτηση Ανταμοιβής	9
2.3 Q-Learning	10
2.4 Deep Q-Network (DQN)	11
2.4.1 Replay Buffer	12
2.4.2 Target Network	12
2.4.3 Double DQN	13
2.5 Διαμόρφωση Ανταμοιβής (Reward Shaping)	14
ΚΕΦΑΛΑΙΟ 3: Θεωρητικό Υπόβαθρο	16
3.1 Συστήματα UxV - Ορισμοί και Κατηγορίες	16

3.2	Σχεδιασμός Διαδρομής (Path Planning)	17
3.2.1	Κλασικές Μέθοδοι	17
3.2.2	Μέθοδοι Βασισμένες σε Μηχανική Μάθηση	19
3.3	Αποφυγή Εμποδίων (Obstacle Avoidance)	20
3.4	Συστήματα Σμήνους (Swarm Systems)	22
3.4.1	Αρχές Σμηνιαίας Συμπεριφοράς	23
3.4.2	Συνοχή, Διαχωρισμός και Ευθυγράμμιση	23
3.5	Βιβλιογραφική Ανασκόπηση Εφαρμογών DRL σε Σμήνη UAV	24
ΚΕΦΑΛΑΙΟ 4: Σχεδιασμός Συστήματος		26
4.1	Περιβάλλον Προσομοίωσης	26
4.1.1	Γεωμετρία Κόσμου και Σύνορα	26
4.1.2	Στοχαστική Δημιουργία Εμποδίων (UAVEnvTopology)	27
4.2	Περιβάλλον Single UAV (UAVEnv)	28
4.2.1	Χώρος Καταστάσεων και Παρατηρήσεων	28
4.2.2	Χώρος Ενεργειών - Γωνίες Στροφής	29
4.2.3	Αισθητήρες Εμβέλειας (Range Sensors)	30
4.2.4	Συνάρτηση Ανταμοιβής	31
4.2.5	Ανίχνευση Σύγκρουσης και Τερματισμός	32
4.3	Περιβάλλον Σμήνους (SwarmUAVEnv)	32
4.3.1	Επέκταση από Μονό σε Πολλαπλά UAV	32
4.3.2	Χώρος Παρατηρήσεων Σμήνους	33
4.3.3	Συνθήκες Τερματισμού Σμήνους	34
4.4	Αρχιτεκτονική Πράκτορα DQN (DQNAgent)	34
4.4.1	Νευρωνικό Δίκτυο MLP (_NumpyMLP)	35
4.4.2	Αρχικοποίηση He και Αρχιτεκτονική Στρωμάτων	36
4.4.3	Αλγόριθμος Βελτιστοποίησης Adam	36
4.4.4	Huber Loss και Gradient Clipping	36
4.4.5	Στρατηγική Εξερεύνησης ϵ -greedy	37
4.4.6	Υλοποίηση Double DQN	38
4.5	Διαμόρφωση Ανταμοιβής Σμήνους (SwarmRewardShaper)	39
4.5.1	Συνιστώσα Συνοχής (Cohesion)	39
4.5.2	Συνιστώσα Διαχωρισμού (Separation) και Ζώνη Κινδύνου	40
4.5.3	Συνιστώσα Ευθυγράμμισης (Alignment)	41
4.5.4	Επιλογή Υπερπαραμέτρων	42
ΚΕΦΑΛΑΙΟ 5: Πειράματα και Αποτελέσματα		45
5.1	Πρωτόκολλο Εκπαίδευσης και Αξιολόγησης	45
5.1.1	Διάρκεια και Παράμετροι Εκπαίδευσης	45
5.1.2	Πρωτόκολλο Αξιολόγησης	45
5.1.3	Μετρικές Απόδοσης	46
5.1.4	Παρατηρήσεις για τον Ορισμό της Επιτυχίας	47
5.2	Εκπαίδευση και Αξιολόγηση Single UAV	47
5.2.1	Καμπύλη Σύγκλισης Εκπαίδευσης	47

5.3	Εκπαίδευση και Αξιολόγηση Σμήνους Αναφοράς ($N = 5$)	48
5.3.1	Καμπύλη Σύγκλισης	48
5.3.2	Δείγματα Τροχιών Αξιολόγησης	49
5.4	Επίδραση Μεγέθους Σμήνους (2 έως 10 UAV)	50
5.4.1	Εκπαίδευση με Σταθερό Περιβάλλον (Fixed Seed)	50
5.4.2	Εκπαίδευση με Σταδιακή Μάθηση (Curriculum Learning)	52
5.4.3	Σύγκριση Στρατηγικών Εκπαίδευσης	54
5.5	Αξιολόγηση Εκπαιδευμένων Πρακτόρων	55
5.5.1	Επίδραση Αριθμού Εμποδίων (4, 6, 8)	55
5.5.2	Απόδοση για 1 έως 10 Εμπόδια	56
5.5.3	Σύγκριση Μεγεθών Σμήνους (3, 4, 5 UAV)	58
5.5.4	Σύγκριση Single UAV vs Swarm	59
ΚΕΦΑΛΑΙΟ 6:	Συμπεράσματα και Μελλοντική Έρευνα	61
6.1	Σύνοψη Εργασίας	61
6.2	Κύρια Συμπεράσματα και Συνεισφορά	61
6.2.1	Επεκτασιμότητα της Κοινής Πολιτικής	61
6.2.2	Δίλημμα Εξειδίκευσης - Γενίκευσης στην Εκπαίδευση	62
6.2.3	Ευθραυστότητα της Πολυπρακτορικής Q-Learning	62
6.2.4	Στατιστική Φύση της Συλλογικής Επιτυχίας	62
6.3	Περιορισμοί	63
6.3.1	Στατικά Εμπόδια	63
6.3.2	Δισδιάστατος Χώρος	63
6.3.3	Διακριτός Χώρος Ενεργειών	63
6.3.4	Ασθενής Ορισμός Επιτυχίας	63
6.3.5	Διαφορετικές Συνθήκες Αξιολόγησης στη Σύγκριση Στρατηγικών	63
6.3.6	Απουσία Αβεβαιότητας Αισθητήρων	64
6.4	Προτάσεις για Μελλοντική Έρευνα	64
6.4.1	Συνεχής Έλεγχος και Σύγχρονοι Αλγόριθμοι	64
6.4.2	Δυναμικά και Τρισδιάστατα Περιβάλλοντα	64
6.4.3	Ετερογενή Σμήνη	64
6.4.4	Ισχυρότεροι Ορισμοί Επιτυχίας	64
6.4.5	Πραγματική Ανάπτυξη και Sim-to-Real	65
6.4.6	Σύγκριση με Μη Μαθησιακές Μεθόδους	65
6.5	Επίλογος	65
ΒΙΒΛΙΟΓΡΑΦΙΑ		68

ΚΑΤΑΛΟΓΟΣ ΕΙΚΟΝΩΝ

2.1	Ιεραρχική σχέση μεταξύ Τεχνητής Νοημοσύνης, Μηχανικής Μάθησης, Βαθιάς Μάθησης και Βαθιάς Ενισχυτικής Μάθησης.	3
2.2	Τυπική αρχιτεκτονική βαθιού νευρωνικού δικτύου (DNN) τύπου Multi-Layer Perceptron. Αναπαραγωγή από [1].	5
2.3	Τυπική ροή εργασιών επίλυσης προβλήματος με μηχανική μάθηση, αποτελούμενη από τέσσερα διασυνδεδεμένα και επαναληπτικά στάδια. Βασισμένο σε [2].	7
2.4	Πλαίσιο αλληλεπίδρασης πράκτορα-περιβάλλοντος σε διαδικασία απόφασης Markov. Αναπαραγωγή από [3].	8
2.5	Δομή του αλγορίθμου Deep Q-Network (DQN) με τα κύρια στοιχεία: Q-eval Network, Target Network και Replay Memory. Αναπαραγωγή από [4].	12
3.1	Οι τέσσερις βασικές κατηγορίες μη επανδρωμένων οχημάτων (UxV) ανάλογα με το περιβάλλον λειτουργίας τους [5].	16
3.2	Δομικά στοιχεία ενός τυπικού UAV: ESC, GPS, αισθητήρες, ελεγκτής πτήσης και μπαταρία. Αναπαραγωγή από [6].	17
3.3	Ταξονομία μεθόδων σχεδιασμού διαδρομής για UAV. Αναπαραγωγή από [6].	18
3.4	Παράδειγμα κλασικών μεθόδων σχεδιασμού διαδρομής σε δισδιάστατο χώρο. Αναπαραγωγή από [6].	19
3.5	Προσομοίωση συλλογικής κίνησης boids βάσει του μοντέλου Reynolds. Αναπαραγωγή από [7].	23
3.6	Οι τρεις θεμελιώδεις κανόνες σημαϊκής συμπεριφοράς κατά Reynolds: διαχωρισμός, ευθυγράμμιση και συνοχή [7].	24
4.1	Παράδειγμα στοχαστικά παραγόμενης τοπολογίας του περιβάλλοντος προσομοίωσης με έξι εμπόδια. Η αρχική θέση $\mathbf{p}_{\text{start}} = (-40, -40)$ παρουσιάζεται με πράσινο κύκλο και η θέση στόχου $\mathbf{p}_{\text{goal}} = (40, 40)$ με κόκκινο αστέρι. Ο κόκκινος διακεκομμένος κύκλος γύρω από τον στόχο δείχνει την ακτίνα επιτυχίας $r_{\text{goal}} = 3.0$. Τα εμπόδια αναπαριστούνται ως γκρι δίσκοι μεταβλητής ακτίνας. Η συγκεκριμένη τοπολογία παρήχθη με σταθερά $\text{seed} = 42$ και είναι αναπαραγωγίμη.	28
4.2	Διάταξη των πέντε αισθητήρων εμβέλειας του UAV. Οι αισθητήρες εκπέμπουν ακτίνες σε σχετικές γωνίες ως προς τον τρέχοντα προσανατολισμό ψ_t , καλύπτοντας μετωπιαίο τόξο 120° . Όταν μια ακτίνα συναντά εμπόδιο, ο αντίστοιχος αισθητήρας επιστρέφει την απόσταση έως το σημείο τομής, αλλιώς επιστρέφει τη μέγιστη εμβέλεια ρ_{max}	30
4.3	Αρχιτεκτονική του νευρωνικού δικτύου MLP του πράκτορα DQN. Το δίκτυο αποτελείται από τρία πλήρως συνδεδεμένα στρώματα με δύο ενδιάμεσες ενεργοποιήσεις ReLU. Η διάσταση εισόδου είναι 9 για το περιβάλλον μονού UAV και 17 για το βασικό σενάριο σμήνους ($N = 5$).	35

4.4	Συνολική ανταμοιβή διαχωρισμού $r_{\text{safe},ij} + r_{\text{danger},ij}$ ως συνάρτηση της απόστασης d_{ij} μεταξύ δύο πρακτόρων, για βάρος $w_{\text{sep}} = 4.0$. Η ομαλή συνιστώσα έχει τη μορφή ανεστραμμένης τετραγωνικής συνάρτησης με μέγιστο (μηδενική ποινή) στην επιθυμητή απόσταση $d^* = 6.0$. Όταν η απόσταση πέσει κάτω από το κρίσιμο όριο $d_{\text{min}}^{\text{sep}} = 3.0$, ενεργοποιείται η ασυνεχής ποινή ζώνης κινδύνου με σταθερή προσθήκη $-10 \cdot w_{\text{sep}} = -40$. Στα σαρωτικά πειράματα μεταβλητού μεγέθους σμήνους, το βάρος w_{sep} κανονικοποιείται ως $4.0/(N - 1)$ (βλ. Κεφάλαιο 5).	41
5.1	Καμπύλη σύγκλισης εκπαίδευσης του πράκτορα DQN για το περιβάλλον μονού UAV. Αριστερά: συνολική ανταμοιβή ανά επεισόδιο. Δεξιά: αριθμός βημάτων ανά επεισόδιο.	48
5.2	Καμπύλη σύγκλισης εκπαίδευσης του πράκτορα DQN για το σμήνος αναφοράς $N = 5$. Αριστερά: μέση ανταμοιβή σμήνους ανά βήμα. Δεξιά: αριθμός βημάτων ανά επεισόδιο.	49
5.3	Δείγματα τροχιών αξιολόγησης του εκπαιδευμένου σμήνους $N = 5$ UAV. Πράσινος κύκλος: αρχική θέση. Μπλε αστέρι: στόχος. Έγχρωμες γραμμές: τροχίες ανά πράκτορα. Τετράγωνα σύμβολα: τελικές θέσεις των πρακτόρων στο τέλος του επεισοδίου.	50
5.4	Καμπύλες ανταμοιβής εκπαίδευσης για σμήνη μεγέθους $N = 2$ έως $N = 10$ με στρατηγική σταθερού περιβάλλοντος. Κάθε καμπύλη εκτείνεται σε 800 επεισόδια.	51
5.5	Ποσοστό επιτυχίας ως συνάρτηση του μεγέθους σμήνους για τη στρατηγική σταθερού περιβάλλοντος.	52
5.6	Μετρικές διαδρομής για τη στρατηγική σταθερού περιβάλλοντος. Αριστερά: μήκος διαδρομής. Κέντρο: ομαλότητα. Δεξιά: ενεργειακό κόστος.	52
5.7	Καμπύλες ανταμοιβής εκπαίδευσης για τη στρατηγική σταδιακής μάθησης. Παρατηρούνται περιοδικές διαταραχές στις πρώτες 320 επαναλήψεις λόγω της εναλλαγής μεταξύ σταθερής και τυχαίας φάσης.	53
5.8	Αριθμός επεισοδίων μέχρι τη σύγκλιση (80% της μέγιστης εξομαλυμένης ανταμοιβής) για κάθε μέγεθος σμήνους με τη στρατηγική σταδιακής μάθησης.	53
5.9	Συγκεντρωτική επισκόπηση των έξι κύριων μετρικών για τη στρατηγική σταδιακής μάθησης.	54
5.10	Ποσοστό επιτυχίας του εκπαιδευμένου σμήνους $N = 5$ σε σενάρια με 4, 6 και 8 εμπόδια. Κάθε σημείο προκύπτει από 300 ντετερμινιστικά επεισόδια αξιολόγησης.	56
5.11	Θερμικός χάρτης κανονικοποιημένων μετρικών απόδοσης για τα τρία σενάρια εμποδίων. Πράσινες αποχρώσεις υποδηλώνουν καλύτερη απόδοση ανά γραμμή. Οι μετρικές $1/\text{Path}$, $1/\text{Smooth}$ και $1/\text{Energy}$ απεικονίζονται ως αντίστροφες ώστε οι υψηλότερες τιμές να αντιστοιχούν πάντα σε καλύτερη απόδοση.	57
5.12	Ποσοστό επιτυχίας του εκπαιδευμένου σμήνους $N = 5$ σε σενάρια με αυξανόμενο αριθμό εμποδίων από 1 έως 10. Κάθε σημείο προκύπτει από 100 ντετερμινιστικά επεισόδια αξιολόγησης σε στοχαστικά παραγόμενα περιβάλλοντα.	57
5.13	Σύγκριση τεσσάρων μετρικών απόδοσης μεταξύ σμηνών 3, 4 και 5 UAV σε σενάριο με 4 εμπόδια. Από αριστερά προς τα δεξιά: ποσοστό επιτυχίας, μήκος διαδρομής, ομαλότητα και ενεργειακό κόστος. Κάθε μέγεθος αντιστοιχεί σε ξεχωριστά εκπαιδευμένο πράκτορα.	58
5.14	Καμπύλες σύγκλισης εκπαίδευσης για τους πράκτορες $N = 3$ (αριστερά) και $N = 4$ (δεξιά). Παρατηρούνται έντονες διαταραχές κατά τη διάρκεια της εκπαίδευσης, ιδιαίτερα στις περιπτώσεις μερικής αποσταθεροποίησης που χαρακτηρίζουν την πολυπρακτορική Q-Learning.	58

5.15	Σύγκριση τεσσάρων μετρικών απόδοσης μεταξύ μονού UAV και σμήνους $N = 5$. Πάνω αριστερά: ποσοστό επιτυχίας. Πάνω δεξιά: μέσο μήκος διαδρομής. Κάτω αριστερά: μέση ομαλότητα. Κάτω δεξιά: ενεργειακό κόστος.	60
------	--	----

ΚΑΤΑΛΟΓΟΣ ΠΙΝΑΚΩΝ

2.1	Παράδειγμα πίνακα τιμών Q (Q-value table).	11
3.1	Σχετικές εργασίες κλασικών μεθόδων σχεδιασμού διαδρομής UxV.	19
3.2	Σχετικές εργασίες μεθόδων Μηχανικής Μάθησης για σχεδιασμό διαδρομής UxV.	21
4.1	Υπερπαραμέτροι του SwarmRewardShaper	42
4.2	Συγκεντρωτικός πίνακας υπερπαραμέτρων του συστήματος όπως χρησιμοποιήθηκαν στα πειράματα του Κεφαλαίου 5.	44
5.1	Συγκριτικοί δείκτες των δύο στρατηγικών εκπαίδευσης κατά μήκος όλων των μεγεθών σμήνους.	54

ΚΑΤΑΛΟΓΟΣ ΣΥΝΤΟΜΟΓΡΑΦΙΩΝ

Συντομογραφία	Περιγραφή
A3C	Asynchronous Advantage Actor-Critic
Adam	Adaptive Moment Estimation
AI	Artificial Intelligence
ANN	Artificial Neural Network
APF	Artificial Potential Field
AUV	Autonomous Underwater Vehicle
CNN	Convolutional Neural Network
D3QN	Dueling Double Deep Q-Network
DDPG	Deep Deterministic Policy Gradient
DL	Deep Learning
DNN	Deep Neural Network
DQL	Deep Q-Learning
DQN	Deep Q-Network
DRL	Deep Reinforcement Learning
DWA	Dynamic Window Approach
ESC	Electronic Speed Controller
F-DQN	Fuzzy Deep Q-Network
GA	Genetic Algorithm
GAN	Generative Adversarial Network
GPS	Global Positioning System
GPU	Graphics Processing Unit
k-NN	k-Nearest Neighbors
LIDAR	Light Detection and Ranging
MAPPO	Multi-Agent Proximal Policy Optimization
MARL	Multi-Agent Reinforcement Learning
MDP	Markov Decision Process
ML	Machine Learning
MLP	Multi-Layer Perceptron
MPC	Model Predictive Control
MSE	Mean Squared Error
NN-MPC	Neural Network Model Predictive Controller
PFM	Potential Field Method
POSG	Partially Observable Stochastic Game
PPO	Proximal Policy Optimization
PSO	Particle Swarm Optimization
ReLU	Rectified Linear Unit
RL	Reinforcement Learning
RNN	Recurrent Neural Network

Συντομογραφία	Περιγραφή
RTT	Rapidly-Exploring Random Tree
SAC	Soft Actor-Critic
SARSA	State–Action–Reward–State–Action
SGD	Stochastic Gradient Descent
SVM	Support Vector Machine
UAV	Unmanned Aerial Vehicle
UGV	Unmanned Ground Vehicle
USV	Unmanned Surface Vehicle
UxV	Unmanned Vehicle
VTOL	Vertical Take-Off and Landing

ΚΕΦΑΛΑΙΟ 1: Εισαγωγή

1.1 Κίνητρο και Ερευνητικό Πρόβλημα

Τα τελευταία χρόνια τα μη επανδρωμένα εναέρια οχήματα (Unmanned Aerial Vehicles, UAV) έχουν προσελκύσει το έντονο ενδιαφέρον τόσο της ερευνητικής κοινότητας όσο και του βιομηχανικού κλάδου. Η ικανότητα τους να εκτελούν αποστολές σε επικίνδυνα ή δυσπρόσιτα περιβάλλοντα, χωρίς την παρουσία ανθρώπινου χειριστή, τα καθιστά ιδιαίτερα χρήσιμα σε εφαρμογές όπως η αναζήτηση και διάσωση, η παρακολούθηση περιοχών, η χαρτογράφηση εδάφους και η γεωργία ακριβείας [5, 6].

Ωστόσο, η αποτελεσματική αξιοποίηση των UAV απαιτεί την επίλυση δύο θεμελιωδών προβλημάτων: τον αυτόνομο σχεδιασμό διαδρομής (path planning) και την αποφυγή εμποδίων (obstacle avoidance) [1]. Σε πραγματικά περιβάλλοντα τα εμπόδια είναι συχνά άγνωστα εκ των προτέρων και δυναμικά μεταβαλλόμενα, γεγονός που καθιστά ανεπαρκείς τις κλασικές μεθόδους σχεδιασμού, όπως ο A^* , ο D^* Lite και τις μεθόδους δυναμικού πεδίου, οι οποίες βασίζονται σε πλήρη γνώση του χάρτη [1, 8].

Η επέκταση από μεμονωμένα UAV σε συστήματα σμήνους (swarm systems) εισάγει επιπλέον πολυπλοκότητα, καθώς απαιτεί τον συντονισμό πολλαπλών πρακτόρων που αλληλεπιδρούν μεταξύ τους και με το περιβάλλον τους [5]. Η ανάγκη για αποκεντρωμένη λήψη αποφάσεων, βασισμένη αποκλειστικά σε τοπικές παρατηρήσεις, αναδεικνύει τις προκλήσεις επεκτασιμότητας και γενίκευσης που αντιμετωπίζουν οι παραδοσιακές προσεγγίσεις.

Υπό αυτό το πρίσμα, η Βαθιά Ενισχυτική Μάθηση (Deep Reinforcement Learning, DRL) αναδεικνύεται ως μια ιδιαίτερα υποσχόμενη προσέγγιση [1, 9]. Μέσω της αλληλεπίδρασης με το περιβάλλον και της βελτιστοποίησης μιας συνάρτησης ανταμοιβής, οι πράκτορες DRL μπορούν να αναπτύξουν αποτελεσματικές πολιτικές πλοήγησης, χωρίς να απαιτείται εκ των προτέρων γνώση του περιβάλλοντος [9].

1.2 Αντικείμενο Διπλωματικής Εργασίας

Αντικείμενο της παρούσας διπλωματικής εργασίας είναι η ανάπτυξη και αξιολόγηση πρακτόρων Deep Q-Network (DQN) για τον αυτόνομο σχεδιασμό διαδρομής και την αποφυγή εμποδίων σε συστήματα σμήνων UAV. Για την επίτευξη αυτού του στόχου, πραγματοποιήθηκαν τα ακόλουθα:

- Σχεδιασμός και υλοποίηση περιβάλλοντος προσομοίωσης για μονό UAV και σμήνος, με στοχαστικά τοποθετημένα εμπόδια.
- Υλοποίηση αλγορίθμου Double DQN από μηδενική βάση σε NumPy, χωρίς τη χρήση εξειδικευμένων πλαισίων βαθιάς μάθησης.
- Ανάπτυξη ειδικής συνάρτησης διαμόρφωσης ανταμοιβής (Reward Shaping) για την ενθάρρυνση συλλογικής συμπεριφοράς εντός του σμήνους.
- Διερεύνηση δύο στρατηγικών εκπαίδευσης: εκπαίδευση σε σταθερό περιβάλλον και εκπαίδευση με Curriculum Learning.
- Συγκριτική αξιολόγηση των εκπαιδευσιμων πρακτόρων σε σενάρια με διαφορετικό αριθμό εμποδίων και διαφορετικά μεγέθη σμήνους.

Η εργασία συνεισφέρει στην ερευνητική περιοχή των αυτόνομων συστημάτων πολλαπλών πρακτόρων, αναδεικνύοντας τις δυνατότητες και τους περιορισμούς των τεχνικών DRL για τις εφαρμογές σμήνους UAV.

1.3 Διάρθρωση Εργασίας

Η παρούσα εργασία οργανώνεται ως εξής:

Στο **Κεφάλαιο 2** αναλύονται οι έννοιες της Μηχανικής Μάθησης και της Ενισχυτικής Μάθησης, με ιδιαίτερη έμφαση στο αλγόριθμο Deep Q-Network και τις επεκτάσεις του.

Στο **Κεφάλαιο 3** παρουσιάζεται το θεωρητικό υπόβαθρο που αφορά τα συστήματα UxV, τον σχεδιασμό διαδρομής, την αποφυγή εμποδίων και τις αρχές της σημανιάς συμπεριφοράς, καθώς και βιβλιογραφική ανασκόπηση σχετικών εφαρμογών DRL.

Στο **Κεφάλαιο 4** περιγράφεται ο σχεδιασμός του συστήματος, συμπεριλαμβανομένων του περιβάλλοντος προσομοίωσης, της αρχιτεκτονικής του πράκτορα και της συνάρτησης διαμόρφωσης ανταμοιβής σμήνους.

Στο **Κεφάλαιο 5** παρουσιάζονται τα πειράματα και τα αποτελέσματα της εκπαίδευσης και αξιολόγησης των πρακτόρων, τόσο για μονό UAV όσο και για σμήνη διαφορετικών μεγεθών.

Στο **Κεφάλαιο 6** συνοψίζονται τα συμπεράσματα της μελέτης, αναλύονται οι περιορισμοί της και προτείνονται κατευθύνσεις για μελλοντική έρευνα.

ΚΕΦΑΛΑΙΟ 2: Βασικές Αρχές Τεχνητής Νοημοσύνης και Ενισχυτικής Μάθησης


2.1 Τεχνητή Νοημοσύνη και Μηχανική Μάθηση

Η Τεχνητή Νοημοσύνη (Artificial Intelligence, AI) αποτελεί έναν ευρύ επιστημονικό κλάδο που στοχεύει στην ανάπτυξη υπολογιστικών συστημάτων ικανών να εκτελούν εργασίες που κανονικά απαιτούν ανθρώπινη νοημοσύνη. Στο πλαίσιο της AI, η Μηχανική Μάθηση (Machine Learning, ML) και η Βαθιά Μάθηση (Deep Learning, DL) αποτελούν τους πλέον καθοριστικούς υποτομείς για την ανάπτυξη αυτόνομων πρακτόρων πλοήγησης, όπως αυτών που μελετώνται στην παρούσα εργασία.

2.1.1 Τεχνητή Νοημοσύνη

Ο όρος Τεχνητή Νοημοσύνη (Artificial Intelligence, AI) αναφέρεται στην ικανότητα των μηχανών και των υπολογιστικών συστημάτων να επιδεικνύουν συμπεριφορά που προσομοιάζει την ανθρώπινη νοημοσύνη, όπως η αντίληψη του περιβάλλοντος, ο συλλογισμός, η μάθηση και η λήψη αποφάσεων. Στον τομέα της αυτόνομης ρομποτικής, η AI έχει καταστεί καθοριστικός παράγοντας, καθώς επιτρέπει την ανάπτυξη οχημάτων ικανών να ερμηνεύουν το περιβάλλον τους και να αλληλεπιδρούν με αυτό χωρίς ανθρώπινο έλεγχο [1].

Η Τεχνητή Νοημοσύνη περιλαμβάνει ένα ευρύ φάσμα μεθοδολογιών, με τη Μηχανική Μάθηση να αποτελεί τον πλέον σημαντικό υποτομέα της για την ανάπτυξη εφαρμογών πραγματικού χρόνου [1]. Η σχέση μεταξύ των εννοιών αυτών είναι ιεραρχική. Η Μηχανική Μάθηση αποτελεί υποσύνολο της Τεχνητής Νοημοσύνης. Η Βαθιά Ενισχυτική Μάθηση αποτελεί υποσύνολο της Μηχανικής Μάθησης, ενώ παράλληλα βρίσκεται στην τομή της Βαθιάς Μάθησης και της Ενισχυτικής Μάθησης [10]. Στις ακόλουθες υποενότητες αναλύονται διαδοχικά αυτές οι έννοιες, ξεκινώντας από τη Μηχανική Μάθηση και καταλήγοντας στην Ενισχυτική Μάθηση που αποτελεί τη βάση της παρούσας εργασίας.



Σχήμα 2.1: Ιεραρχική σχέση μεταξύ Τεχνητής Νοημοσύνης, Μηχανικής Μάθησης, Βαθιάς Μάθησης και Βαθιάς Ενισχυτικής Μάθησης.

2.1.2 Μηχανική Μάθηση

Η Μηχανική Μάθηση αποτελεί υποσύνολο της Τεχνητής Νοημοσύνης που επιτρέπει σε υπολογιστικά συστήματα να ανταποκρίνονται χωρίς να έχουν ρητά προγραμματιστεί [6]. Στον πυρήνα της, η Μηχανική Μάθηση βασίζεται σε στατιστικές τεχνικές και μαθηματικά μοντέλα για την ανάλυση και ερμηνεία σύνθετων προτύπων και σχέσεων στα δεδομένα [10]. Μέσω της εκπαίδευσης σε επισημασμένα (labeled) ή μη επισημασμένα (unlabeled) δεδομένα, οι αλγόριθμοι Μηχανικής Μάθησης μπορούν να αναγνωρίζουν και να γενικεύουν πρότυπα, επιτρέποντάς τους να κάνουν προβλέψεις ή να λαμβάνουν αποφάσεις βάσει νέων, άγνωστων δεδομένων [10].

Ένας από τους πρώτους ερευνητές που όρισαν τον όρο Μηχανική Μάθηση ήταν ο Tom M. Mitchell, ο οποίος διατύπωσε τον ακόλουθο συστηματικό ορισμό [10]: ένα σύστημα μαθαίνει την εκτέλεση μιας συγκεκριμένης εργασίας T , με στόχο τη διατήρηση μιας μετρικής απόδοσης P , βάσει μιας συγκεκριμένης εμπειρίας E , όπου το σύστημα βελτιώνει αξιόπιστα την απόδοση του P κατά την εκτέλεση της εργασίας T , αξιοποιώντας την εμπειρία του E . Βασικό χαρακτηριστικό των αλγορίθμων ML είναι ότι μαθαίνουν μέσω της εμπειρίας, κατ' αναλογία με τον τρόπο που μαθαίνουν οι άνθρωποι [10].

Η ευρεία διάδοση της Μηχανικής Μάθησης τα τελευταία χρόνια οφείλεται σε μεγάλο βαθμό στην αύξηση της αποθηκευτικής ικανότητας και της υπολογιστικής ισχύος των σύγχρονων συστημάτων [10]. Η ML αποτελεί έναν επεκτάσιμο τρόπο επίλυσης σύνθετων προβλημάτων πραγματικού κόσμου, γεγονός που εξηγεί τη ραγδαία υιοθέτησή της σε ερευνητικές και βιομηχανικές εφαρμογές [10].


Αξίζει επίσης να σημειωθεί ότι κατά τη διαδικασία εκπαίδευσης ενός μοντέλου Μηχανικής Μάθησης, ο έλεγχος των φαινομένων υποπροσαρμογής (underfitting) και υπερπροσαρμογής (overfitting) είναι καίριας σημασίας [10]. Η υποπροσαρμογή εμφανίζεται όταν το μοντέλο δεν είναι σε θέση να επιτύχει χαμηλό σφάλμα στο σύνολο εκπαίδευσης, δηλαδή αδυνατεί να περιγράψει επαρκώς τα χαρακτηριστικά των δεδομένων. Αντίθετα, η υπερπροσαρμογή εμφανίζεται όταν παρατηρείται σημαντική διαφορά μεταξύ του σφάλματος στο σύνολο εκπαίδευσης και του σφάλματος στο σύνολο δοκιμής, υποδηλώνοντας ότι το μοντέλο έχει προσαρμοστεί υπερβολικά στα δεδομένα εκπαίδευσης και αδυνατεί να γενικεύσει σε νέα, άγνωστα δεδομένα [10].

2.1.3 Βαθιά Μάθηση

Η Βαθιά Μάθηση είναι ένα υποσύνολο της Μηχανικής Μάθησης που εστιάζει στην εκπαίδευση τεχνητών νευρωνικών δικτύων με πολλαπλά επίπεδα, γνωστών ως βαθιά νευρωνικά δίκτυα (Deep Neural Networks, DNNs), για την εκμάθηση και αναπαράσταση σύνθετων προτύπων και σχέσεων στα δεδομένα [10]. Είναι εμπνευσμένη από τη δομή και τη λειτουργία του ανθρώπινου εγκεφάλου και ειδικότερα από το διασυνδεδεμένο δίκτυο νευρώνων [10].

Ένα από τα βασικά πλεονεκτήματα της Βαθιάς Μάθησης είναι η ικανότητα της να μαθαίνει αυτόματα ιεραρχικές αναπαραστάσεις των δεδομένων. Κάθε επίπεδο ενός DNN μαθαίνει προοδευτικά πιο αφηρημένα χαρακτηριστικά, επιτρέποντας στο δίκτυο να συλλάβει περίπλοκα πρότυπα και εξαρτήσεις στα δεδομένα εισόδου [10]. Αυτή η ιεραρχική εκμάθηση χαρακτηριστικών επιτρέπει στα μοντέλα DL να διαπρέπουν σε εργασίες όπως η αναγνώριση εικόνας και ομιλίας, η επεξεργασία φυσικής γλώσσας και η γενετική μοντελοποίηση [10]. Ορισμένες βασικές κατηγορίες DNN περιλαμβάνουν τα συνελικτικά νευρωνικά δίκτυα (CNNs), τα ανακυκλωτικά νευρωνικά δίκτυα (RNNs) και τα γενετικά ανταγωνιστικά δίκτυα (GANs) [10].

Οι πρόσφατες εξελίξεις στη Βαθιά Μάθηση οφείλονται κυρίως στη διαθεσιμότητα μεγάλης κλίμακας επισημασμένων συνόλων δεδομένων, στις σημαντικές βελτιώσεις της υπολογιστικής ισχύος, καθώς και



Σχήμα 2.2: Τυπική αρχιτεκτονική βαθιού νευρωνικού δικτύου (DNN) τύπου Multi-Layer Perceptron. Αναπαραγωγή από [1].

σε καινοτομίες στις αρχιτεκτονικές νευρωνικών δικτύων και στους αλγορίθμους εκπαίδευσης [10].

Πέρα από αυτά, η Βαθιά Μάθηση έχει επωφεληθεί από καινοτομίες σε τεχνικές κανονικοποίησης (regularization), σε αλγορίθμους βελτιστοποίησης και στην ενσωμάτωση γνώσης πεδίου στις αρχιτεκτονικές των νευρωνικών δικτύων [10]. Επίσης, η Μεταφορά Μάθησης (Transfer Learning) και οι στρατηγικές προεκπαίδευσης (pretraining), όπως η χρήση προεκπαιδευμένων μοντέλων ή η αξιοποίηση αυτοεποπτευόμενης μάθησης (self-supervised learning), διαδραματίζουν καθοριστικό ρόλο στη βελτίωση της απόδοσης των μοντέλων DL, ιδιαίτερα σε σενάρια με περιορισμένα επισημασμένα δεδομένα [10].

2.1.4 Κατηγορίες Μηχανικής Μάθησης

Ανάλογα με τον τύπο των δεδομένων που επεξεργάζονται και τους μηχανισμούς που υιοθετούν, οι αλγόριθμοι διακρίνονται σε τρεις βασικές κατηγορίες [10, 6]: την Επιβλεπόμενη Μάθηση, τη Μη Επιβλεπόμενη Μάθηση και την Ενισχυτική Μάθηση.

Επιβλεπόμενη Μάθηση (Supervised Learning)

Η Επιβλεπόμενη Μάθηση βασίζεται σε ένα σύνολο δεδομένων όπου οι τιμές συνοδεύονται από τις αντίστοιχες ετικέτες τους (labels), οι οποίες μπορούν να παραχθούν είτε από ανθρώπους είτε αυτόματα μέσω υπολογισμού [10]. Συνήθης πρακτική είναι ο διαχωρισμός του συνόλου δεδομένων σε σύνολο εκπαίδευσης (training set) και σύνολο δοκιμής (test set), όπου το πρώτο χρησιμοποιείται για την εκπαίδευση του μοντέλου, δημιουργώντας μια αντιστοίχιση μεταξύ των εισόδων και των ετικετών [10]. Οι πιο αντιπροσωπευτικές περιπτώσεις χρήσης είναι τα προβλήματα ταξινόμησης (classification) και παλινδρόμησης (regression). Χαρακτηριστικοί αλγόριθμοι περιλαμβάνουν τους k-NN, τις Μηχανές Διανυσμάτων Υποστήριξης (SVMs), τα δέντρα αποφάσεων και τα τεχνητά νευρωνικά δίκτυα (ANNs) [10].

Μη Επιβλεπόμενη Μάθηση (Unsupervised Learning)

Η Μη Επιβλεπόμενη Μάθηση διαφέρει από την επιβλεπόμενη, καθώς το ίδιο το μοντέλο προσπαθεί να εντοπίσει τα κοινά χαρακτηριστικά του συνόλου δεδομένων χωρίς τη χρήση ετικετών [10]. Το σύστημα προσπαθεί να ανακαλύψει μόνο του τις υποκείμενες δομές των δεδομένων. Οι βασικές εργασίες της Μη Επιβλεπόμενης Μάθησης περιλαμβάνουν την ομαδοποίηση (clustering) με αλγόριθμους όπως ο k-Means, τη μείωση διαστατικότητας (dimensionality reduction), την ανίχνευση ανωμαλιών (anomaly detection) και τα γενετικά μοντέλα (generative models) [10]. Επίσης, στον τομέα του σχεδιασμού διαδρομής, αλγόριθμοι ομαδοποίησης όπως ο k-means χρησιμοποιούνται για την ομαδοποίηση σημείων στόχων σε προβλήματα προγραμματισμού αποστολών UAV [6].

Ενισχυτική Μάθηση (Reinforcement Learning)


Η Ενισχυτική Μάθηση (Reinforcement Learning, RL) είναι μια κατηγορία Μηχανικής Μάθησης που βασίζεται στην αλληλεπίδραση και επικοινωνία με το περιβάλλον μάθησης για την εκπαίδευση και επικύρωση αποτελεσματικών μοντέλων [10]. Αυτό επιτυγχάνεται μέσω της αξιοποίησης μιας μαθησιακής οντότητας που ονομάζεται πράκτορας λογισμικού (software agent). Η πληροφορία ανατροφοδότησης που ο πράκτορας λαμβάνει από το περιβάλλον ονομάζεται ανταμοιβή (reward) στη θετική περίπτωση ή ποινή (penalty) στην αρνητική [10]. Με αυτόν τον τρόπο, ο πράκτορας δημιουργεί μια πολιτική (policy) για να οργανώσει το δικό του σχήμα μάθησης και να αποφασίσει ποιες ενέργειες θα επιλέξει σε μια δεδομένη κατάσταση. Ο σκοπός ενός αποτελεσματικού μοντέλου RL είναι η μεγιστοποίηση της αθροιστικής ανταμοιβής στον χρόνο [10].

Σε αντίθεση με τις άλλες δύο κατηγορίες Μηχανικής Μάθησης, η RL υιοθετεί μια προσέγγιση εκπαίδευσης δοκιμής-λάθους (trial-and-error) και δεν απαιτεί ανθρώπινη γνώση ή προκαθορισμένους κανόνες, γεγονός που της επιτρέπει να επιτυγχάνει υψηλό επίπεδο νοημοσύνης και την καθιστά ιδιαίτερα ελκυστική για τον σχεδιασμό διαδρομής αυτόνομων οχημάτων [3]. Υπάρχουν αρκετά γνωστά σχήματα RL, όπως το State-Action-Reward-State-Action (SARSA), το Q-Learning, το Deep Q-Learning (DQL) και ο αλγόριθμος Asynchronous Advantage Actor-Critic (A3C) [10]. Λόγω της καταλληλότητας της για το πρόβλημα της αυτόνομης πλοήγησης, η Ενισχυτική Μάθηση και ειδικότερα ο αλγόριθμος DQN αποτελούν το θεμέλιο της μεθοδολογίας της παρούσας εργασίας και αναλύονται διεξοδικά στις επόμενες ενότητες.

2.1.5 Τυπική Ροή Εργασιών Μηχανικής Μάθησης

Πριν από την εμβάθυνση στην Ενισχυτική Μάθηση, κρίνεται χρήσιμη η συνοπτική παρουσίαση της τυπικής ροής εργασιών (typical workflow) που ακολουθείται κατά την αντιμετώπιση ενός προβλήματος με μηχανική μάθηση. Σύμφωνα με [2], η διαδικασία αυτή περιλαμβάνει τέσσερα διακριτά αλλά αλληλένδετα στάδια, τα οποία συχνά επαναλαμβάνονται κυκλικά μέχρι την επίτευξη ικανοποιητικής απόδοσης. Τα στάδια είναι η διατύπωση του προβλήματος, η προετοιμασία των δεδομένων, η μοντελοποίηση και η διανομή. Η συνολική ροή απεικονίζεται στο Σχήμα 2.3.

Διατύπωση Προβλήματος (Problem Formulation). Το πρώτο στάδιο αφορά τη σαφή διατύπωση του προβλήματος προς επίλυση. Καθορίζεται το είδος του προβλήματος (π.χ. ταξινόμηση ή συσταδοποίηση), ώστε να επιλεγεί ο κατάλληλος τύπος αλγόριθμου, ορίζεται ρητά ο στόχος και προσδιορίζονται οι μετρικές αξιολόγησης της απόδοσης. Μια ορθή διατύπωση είναι ζωτικής σημασίας, καθώς διευκολύνει την επιλογή κατάλληλου μοντέλου και την αποφυγή φαινομένων υπερπροσαρμογής



Σχήμα 2.3: Τυπική ροή εργασιών επίλυσης προβλήματος με μηχανική μάθηση, αποτελούμενη από τέσσερα διασυνδεδεμένα και επαναληπτικά στάδια. Βασισμένο σε [2].

ή υποπροσαρμογής [2].

Προετοιμασία Δεδομένων (Data Preparation). Καθώς το πλήθος και η ποιότητα των δεδομένων επηρεάζουν άμεσα την απόδοση των μοντέλων, το στάδιο αυτό περιλαμβάνει τη συλλογή (data collection), την προεπεξεργασία (data preprocessing), τη μηχανική χαρακτηριστικών (feature engineering) και τον διαχωρισμό του συνόλου δεδομένων. Η προεπεξεργασία ενσωματώνει διεργασίες όπως ο καθαρισμός, ο μετασχηματισμός, η κανονικοποίηση (π.χ. min-max ή Z-score), η επισήμανση και η επαύξηση των δεδομένων. Ο διαχωρισμός χωρίζει τα δεδομένα σε σύνολα εκπαίδευσης, επικύρωσης και ελέγχου, με τυπικούς λόγους της τάξης του 60–80% για την εκπαίδευση και 10–20% για καθένα από τα υπόλοιπα [2].

Μοντελοποίηση (Modeling). Στο στάδιο αυτό πραγματοποιείται η επιλογή του μοντέλου (model selection), η εκπαίδευσή του (training) μέσω επαναληπτικής ελαχιστοποίησης μιας συνάρτησης σφάλματος και η αξιολόγησή του (evaluation) σε άγνωστα δεδομένα. Η διαδικασία συμπληρώνεται από την προσαρμογή των υπερπαραμέτρων (hyperparameter tuning), με τεχνικές όπως η αναζήτηση πλέγματος (grid search), η τυχαία αναζήτηση (random search) ή η μπεϋζιανή βελτιστοποίηση (Bayesian optimization), σχηματίζοντας έναν κύκλο αξιολόγησης και αναπροσαρμογής μέχρι την επίτευξη της επιθυμητής απόδοσης [2].


Διανομή (Deployment). Στο τελικό στάδιο, το εκπαιδευμένο μοντέλο τίθεται σε παραγωγή και χρησιμοποιείται για συμπερασματολογία (inference) σε νέα, άγνωστα δεδομένα. Μετά τη διανομή, υποβάλλεται σε συνεχή παρακολούθηση της απόδοσης του, η οποία ενδέχεται να υποδείξει την ανάγκη επανεκπαίδευσης ή ενημέρωσής του [2].

Η μεθοδολογία της παρούσας εργασίας ακολουθεί την ίδια γενική λογική. Το πρόβλημα διατυπώνεται ως διαδικασία απόφασης Markov, όπως αναλύεται στη συνέχεια, τα δεδομένα παράγονται μέσω της αλληλεπίδρασης του πράκτορα με το περιβάλλον προσομοίωσης, το μοντέλο Double DQN εκπαιδε-

ύεται και αξιολογείται σε διαφορετικά σενάρια, ενώ η τελική πολιτική θα μπορούσε να αναπτυχθεί σε πραγματικά συστήματα UAV.

2.2 Βασικές Έννοιες Ενισχυτικής Μάθησης

Η Ενισχυτική Μάθηση βασίζεται σε ένα αυστηρά καθορισμένο μαθηματικό πλαίσιο που περιγράφει την αλληλεπίδραση ενός πράκτορα με το περιβάλλον του. Στις ακόλουθες υποενότητες παρουσιάζονται οι θεμελιώδεις έννοιες που διέπουν αυτό το πλαίσιο: η Διαδικασία Απόφασης Markov, η συνάρτηση αξίας και η πολιτική, καθώς και η συνάρτηση ανταμοιβής.



Σχήμα 2.4: Πλαίσιο αλληλεπίδρασης πράκτορα-περιβάλλοντος σε διαδικασία απόφασης Markov. Αναπαράγωγή από [3].

2.2.1 Διαδικασίες Απόφασης Markov (MDP)

Η Διαδικασία Απόφασης Markov (Markov Decision Process, MDP) αποτελεί το τυπικό μαθηματικό πλαίσιο για τη μοντελοποίηση περιβαλλόντων ενισχυτικής μάθησης, στα οποία ένας στόχος μπορεί να επιτευχθεί μέσω συνεχών αλληλεπιδράσεων μεταξύ ενός πράκτορα και του περιβάλλοντος [3]. Μια MDP αναπαρίσταται μέσω μιας πλειάδας τεσσάρων στοιχείων [3]:

$$M = (S, A, P, R) \quad (2.1)$$

όπου:

- $S = \{s_1, s_2, \dots, s_t, s_{t+1}\}$ αναπαριστά το πεπερασμένο σύνολο καταστάσεων (states) του δυναμικού περιβάλλοντος, με s_t να δηλώνει την κατάσταση τη χρονική στιγμή t .
- $A = \{a_1, a_2, \dots, a_t, a_{t+1}\}$ αναπαριστά το σύνολο ενεργειών (actions) που εκτελεί ο πράκτορας, με a_t να δηλώνει την ενέργεια τη χρονική στιγμή t .
- P είναι η συνάρτηση πιθανότητας μετάβασης (transition probability), που ορίζεται ως:

$$P_{ss'}^a = \mathbb{P}[s_{t+1} = s' \mid s_t = s, a_t = a] \quad (2.2)$$

- R είναι η συνάρτηση ανταμοιβής (reward function), με $\gamma \in [0, 1]$ τον συντελεστή έκπτωσης (discount factor) που καθορίζει την παρούσα αξία των μελλοντικών ανταμοιβών.

Η αλληλεπίδραση μεταξύ πράκτορα και περιβάλλοντος ακολουθεί μια κυκλική διαδικασία. Ο πράκτορας, ως οντότητα μάθησης και λήψης αποφάσεων, επιλέγει μια ενέργεια a_t βάσει της παρατηρούμενης κατάστασης s_t . Το περιβάλλον, ως απόκριση στην ενέργεια του πράκτορα, ενημερώνει την κατάσταση του σε s_{t+1} και επιστρέφει μια ανταμοιβή r_t στον πράκτορα [3].

Σε προβλήματα πολλαπλών πρακτόρων, όπως τα συστήματα σμήνους, η MDP επεκτείνεται σε μερικώς παρατηρήσιμη στοχαστική παιγνιοθεωρητική διατύπωση (Partially Observable Stochastic Game, POSG), όπου οι ανταμοιβές και οι μεταβάσεις μεταξύ καταστάσεων καθορίζονται από τις από κοινού ενέργειες όλων των πρακτόρων [5]. Στην περίπτωση αυτή, κάθε πράκτορας i διαθέτει τοπικό χώρο παρατήρησης O_i και η ομάδα συνεργάζεται όταν όλοι οι πράκτορες μοιράζονται την ίδια συνάρτηση ανταμοιβής ($\forall i, j : R_i = R_j$) [5].

2.2.2 Συνάρτηση Αξίας και Πολιτική

Στόχος της Ενισχυτικής Μάθησης είναι η εύρεση μιας βέλτιστης πολιτικής (policy) π^* για μια δεδομένη MDP. Η πολιτική $\pi(a | s)$ ορίζει την πιθανότητα επιλογής της ενέργειας a όταν ο πράκτορας βρίσκεται στην κατάσταση s [1]. Η ποιότητα μιας πολιτικής αξιολογείται μέσω της συνάρτησης αξίας ενέργειας-κατάστασης (action-value function ή Q-function), η οποία εκφράζει την αναμενόμενη αθροιστική εκπτώτικη ανταμοιβή [3, 11]:

$$Q^*(s, a) = \max_{\pi} \mathbb{E} \left[\sum_{k=0}^{\infty} \gamma^k r_{t+k} \mid s_t = s, a_t = a, \pi \right] \quad (2.3)$$

Η συνάρτηση αυτή δηλώνει τη δεσμευμένη αναμενόμενη τιμή της αθροιστικής ανταμοιβής που συγκεντρώνεται από την πολιτική π , δεδομένου ενός αρχικού ζεύγους κατάστασης-ενέργειας (s, a) [11]. Η βέλτιστη πολιτική π^* είναι εκείνη που μεγιστοποιεί την $Q^*(s, a)$ για κάθε κατάσταση [3].

Ο συντελεστής έκπτωσης γ διαδραματίζει κρίσιμο ρόλο. Ικανοποιεί τη σχέση $0 \leq \gamma \leq 1$, όπου μια μηδενική τιμή σημαίνει ότι λαμβάνονται υπόψη μόνο οι τρέχουσες ανταμοιβές, ενώ μια τιμή κοντά στη μονάδα υποδηλώνει ότι οι μακροπρόθεσμες υψηλές ανταμοιβές είναι σημαντικές [10].

2.2.3 Συνάρτηση Ανταμοιβής

Η συνάρτηση ανταμοιβής (reward function) αποτελεί τον κεντρικό μηχανισμό καθοδήγησης της συμπεριφοράς του πράκτορα στην Ενισχυτική Μάθηση. Σε ένα πρόβλημα σχεδιασμού διαδρομής, η συνάρτηση ανταμοιβής πρέπει να σχεδιαστεί ώστε να επιβάλλει στον πράκτορα την εκμύληση της επιθυμητής συμπεριφοράς και την ολοκλήρωση των καθορισμένων εργασιών [3]. Η πληροφορία ανατροφοδότησης που λαμβάνει ο πράκτορας ονομάζεται ανταμοιβή (reward) στη θετική περίπτωση ή ποινή (penalty) στην αρνητική [10].

Στα προβλήματα πλοήγησης αυτόνομων οχημάτων, η συνολική συνάρτηση ανταμοιβής συνήθως αποτελείται από ένα άθροισμα επιμέρους συνιστωσών (sub-rewards), καθεμία από τις οποίες ενθαρρύνει μια συγκεκριμένη πτυχή της επιθυμητής συμπεριφοράς [3, 11]. Χαρακτηριστικά παραδείγματα τέτοιων συνιστωσών περιλαμβάνουν:

- **Ανταμοιβή Τερματισμού (Terminal Reward):** Μια μεγάλη θετική ανταμοιβή που ενεργοποιείται όταν ο πράκτορας φτάνει στην περιοχή του στόχου, καθώς η επίτευξη του στόχου αποτελεί το πιο κρίσιμο κριτήριο ολοκλήρωσης της αποστολής [3].
- **Ανταμοιβή Αποφυγής Σύγκρουσης (Collision Avoidance Reward):** Μια μεγάλη

αρνητική ανταμοιβή (ποινή) που επιβάλλεται όταν ο πράκτορας συγκρούεται με εμπόδιο, ώστε να αποθαρρύνει την επιλογή επικίνδυνων ενεργειών [3, 11].

- **Ανταμοιβή Απόστασης (Distance Reward):** Μια ανταμοιβή ανάλογη της απόστασης από τον στόχο, η οποία ενθαρρύνει τον πράκτορα να ακολουθεί τη συντομότερη διαδρομή προς αυτόν [11].

Ο σχεδιασμός της συνάρτησης ανταμοιβής αποτελεί καθοριστικό παράγοντα για την επιτυχία της εκπαίδευσης. Η τεχνική της διαμόρφωσης ανταμοιβής (Reward Shaping), η οποία αναλύεται στην επόμενη ενότητα, παρέχει έναν συστηματικό τρόπο ενσωμάτωσης πρόσθετης γνώσης στη συνάρτηση ανταμοιβής για την επιτάχυνση και βελτίωση της μάθησης.

2.3 Q-Learning

Ο αλγόριθμος Q-Learning, ο οποίος προτάθηκε από τους Watkins και Dayan (1992), αποτελεί έναν από τους πρώτους σημαντικούς αλγορίθμους στην Ενισχυτική Μάθηση [3, 9]. Πρόκειται για μια μέθοδο που αξιοποιεί τη χρονική διαφορά (temporal difference) και ενημερώνεται βήμα προς βήμα κατά τη διαδικασία αλληλεπίδρασης μεταξύ του πράκτορα και του περιβάλλοντος, χωρίς να απαιτείται γνώση της καθολικής πιθανότητας μετάβασης καταστάσεων [4]. Η μέθοδος της χρονικής διαφοράς συνδυάζει τη μέθοδο δυναμικού δειγματοληψίας Monte Carlo με τη μέθοδο δυναμικού προγραμματισμού, καθιστώντας την κατάλληλη για αλγορίθμους ελεύθερου μοντέλου (model-free) που μπορούν να ενημερώνονται σε ένα μόνο βήμα [4].

Στόχος του Q-Learning είναι η εύρεση μιας βέλτιστης πολιτικής ελέγχου π^* για μια δεδομένη MDP, η οποία μεγιστοποιεί τη συνάρτηση αξίας ενέργειας-κατάστασης [3]. Η μέθοδος βασίζεται στην εξίσωση Bellman, η οποία εκφράζει την ακόλουθη διαίσθηση: εάν η βέλτιστη τιμή $Q^*(s', a')$ της επόμενης κατάστασης s' είναι γνωστή για όλες τις πιθανές ενέργειες a' , τότε η βέλτιστη στρατηγική είναι η επιλογή της ενέργειας a' που μεγιστοποιεί την αναμενόμενη τιμή του $r + \gamma Q^*(s', a')$ [9]:

$$Q^*(s, a) = \mathbb{E}_{s'} \left[r + \gamma \max_{a'} Q^*(s', a') \mid s, a \right] \quad (2.4)$$

Ο Q-Learning είναι μια προσέγγιση εκτός πολιτικής (off-policy) που προσεγγίζει άμεσα τη συνάρτηση αξίας ενέργειας μέσω του ακόλουθου κανόνα ενημέρωσης [3, 4]:

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right] \quad (2.5)$$

όπου α είναι ο ρυθμός μάθησης (learning rate), ένας αριθμός μικρότερος της μονάδας, και γ ο συντελεστής έκπτωσης [4]. Ο όρος α καθορίζει το μέγεθος της διόρθωσης που εφαρμόζεται στην εκτίμηση $Q(s, a)$ σε κάθε βήμα ενημέρωσης.

Στον κλασικό Q-Learning, η συνάρτηση $Q(s, a)$ αναπαρίσταται ουσιαστικά ως ένας πίνακας που αποθηκεύει την τιμή Q που αντιστοιχεί σε κάθε ενέργεια στις διάφορες καταστάσεις του περιβάλλοντος [4]. Ο πίνακας αυτός ονομάζεται πίνακας τιμών Q (Q-value table) και έχει τη μορφή που παρουσιάζεται στον Πίνακα 2.1.

Για την επιλογή ενεργειών, ο Q-Learning χρησιμοποιεί τυπικά μια στρατηγική ε – greedy επιλογής, δηλαδή με πιθανότητα ε ο πράκτορας επιλέγει τυχαία μια ενέργεια, ενώ με πιθανότητα $1 - \varepsilon$ επιλέγει την ενέργεια με την μέγιστη τιμή Q στον πίνακα [9, 4].

Πίνακας 2.1: Παράδειγμα πίνακα τιμών Q (Q-value table).

Q-Value Table	a_1	a_2	a_3
s_1	$Q(s_1, a_1)$	$Q(s_1, a_2)$	$Q(s_1, a_3)$
s_2	$Q(s_2, a_1)$	$Q(s_2, a_2)$	$Q(s_2, a_3)$
s_3	$Q(s_3, a_1)$	$Q(s_3, a_2)$	$Q(s_3, a_3)$
$\vdots$	$\vdots$	$\vdots$	$\vdots$

Παρά την αποδεδειγμένη σύγκλιση του σε βέλτιστη πολιτική, ο κλασικός Q-Learning παρουσιάζει ένα θεμελιώδες μειονέκτημα, το γεγονός ότι η επιλογή ενεργειών βασίζεται στον πίνακα τιμών Q , του οποίου η χωρητικότητα είναι περιορισμένη [4]. Όταν το περιβάλλον γίνεται πιο σύνθετο, ο αριθμός των καταστάσεων αυξάνεται εκθετικά, καθιστώντας τον πίνακα Q ανεπαρκή [4]. Ο Q-Learning εκπαιδεύει έναν πράκτορα διατηρώντας έναν πίνακα Q και αυτή η στρατηγική αποτυγχάνει με την αύξηση του αριθμού των ενεργειών και των καταστάσεων [3]. Αντίθετα, οι μέθοδοι που είναι βασισμένες σε τεχνητά νευρωνικά δίκτυα, όπως το Deep Q-Network (DQN), μπορούν να χρησιμοποιηθούν σε σενάρια με χώρους καταστάσεων και ενεργειών υψηλών διαστάσεων [3]. Η μετάβαση από τον πίνακα Q σε μια προσέγγιση βασισμένη σε νευρωνικά δίκτυα αποτελεί το αντικείμενο της επόμενης ενότητας.

2.4 Deep Q-Network (DQN)


Το Deep Q-Network (DQN) αναπτύχθηκε από τους Mnih et al. (2015) ως απάντηση στους περιορισμούς του κλασικού Q-Learning σε περιβάλλοντα με μεγάλους ή συνεχείς χώρους καταστάσεων [9]. Αντί να διατηρείται ένας πίνακας τιμών Q , το DQN χρησιμοποιεί ένα βαθύ νευρωνικό δίκτυο για να προσεγγίσει τη συνάρτηση αξίας ενέργειας-κατάστασης $Q(s, a; \theta)$, όπου θ αναπαριστά τις παραμέτρους (βάρη) του δικτύου [9, 4]. Αυτή η προσέγγιση ξεπερνά τους περιορισμούς μνήμης του πίνακα Q και επιπλέον προσδίδει στο σύστημα ικανότητα γενίκευσης σε καταστάσεις που δεν έχουν παρατηρηθεί ποτέ κατά την εκπαίδευση [4].

Το νευρωνικό δίκτυο εκπαιδεύεται προσαρμόζοντας τις παραμέτρους θ_i σε κάθε επανάληψη i ώστε να ελαχιστοποιηθεί το μέσο τετραγωνικό σφάλμα της εξίσωσης Bellman, οδηγώντας σε μια ακολουθία συναρτήσεων απώλειας [9]:

$$L_i(\theta_i) = \mathbb{E}_{(s,a,r,s')} [(y - Q(s, a; \theta_i))^2] \quad (2.6)$$

όπου $y = r + \gamma \max_{a'} Q(s', a'; \theta_i^-)$ είναι η τιμή-στόχος (target) που υπολογίζεται από τις παραμέτρους θ_i^- μιας προηγούμενης επανάληψης [9]. Η βελτιστοποίηση πραγματοποιείται μέσω στοχαστικής καθόδου κλίσης (stochastic gradient descent) και ο αλγόριθμος είναι ελεύθερου μοντέλου (model-free) και εκτός πολιτικής (off-policy) [9].

Η εκπαίδευση ενός νευρωνικού δικτύου για προσέγγιση συναρτήσεων Q είναι γνωστό ότι είναι ασταθής ή αποκλίνει όταν χρησιμοποιείται μη γραμμικός προσεγγιστής συναρτήσεων [9]. Αυτή η αστάθεια οφείλεται σε δύο βασικούς παράγοντες, τις συσχετίσεις στην ακολουθία παρατηρήσεων και τη συσχέτιση μεταξύ των τιμών Q και των τιμών-στόχων [9]. Το DQN αντιμετωπίζει αυτές τις αστάθειες μέσω δύο βασικών καινοτομιών, του Experience Replay και του Target Network, οι οποίες αναλύονται στις ακόλουθες υποενότητες.



Σχήμα 2.5: Δομή του αλγορίθμου Deep Q-Network (DQN) με τα κύρια στοιχεία: Q-eval Network, Target Network και Replay Memory. Αναπαράγωγή από [4].

2.4.1 Replay Buffer

Ο μηχανισμός επανάληψης εμπειρίας (Experience Replay) αποτελεί μία από τις κεντρικές καινοτομίες του DQN και είναι εμπνευσμένος από βιολογικές διεργασίες μνήμης [9]. Σε κάθε χρονικό βήμα t , η εμπειρία του πράκτορα $e_t = (s_t, a_t, r_t, s_{t+1})$ αποθηκεύεται σε ένα σύνολο δεδομένων $D_t = \{e_1, \dots, e_t\}$, γνωστό ως replay buffer ή experience replay pool [9, 4].

Κατά την εκπαίδευση, ένας σταθερός αριθμός δειγμάτων επιλέγεται τυχαία και ομοιόμορφα από το replay buffer για την ενημέρωση των παραμέτρων του δικτύου, αντί να χρησιμοποιείται η πιο πρόσφατη εμπειρία [9]. Αυτή η προσέγγιση παρουσιάζει αρκετά πλεονεκτήματα έναντι του συμβατικού Q-Learning σε επικαιροποίηση πραγματικού χρόνου [9, 4]:

- **Αποδοτικότητα δεδομένων:** Κάθε βήμα εμπειρίας μπορεί να χρησιμοποιηθεί σε πολλαπλές ενημερώσεις βαρών, αυξάνοντας την αποδοτικότητα των δεδομένων [9].
- **Διάσπαση συσχετίσεων:** Η μάθηση απευθείας από διαδοχικά δείγματα είναι αποτελεσματική λόγω των ισχυρών συσχετίσεων μεταξύ τους. Η τυχαία δειγματοληψία διασπά αυτές τις συσχετίσεις και επομένως μειώνει τη διακύμανση των ενημερώσεων [9, 4].
- **Αποφυγή ανεπιθύμητων βρόχων ανατροφοδότησης:** Στη μάθηση εντός πολιτικής (on-policy), οι τρέχουσες παραμέτροι καθορίζουν το επόμενο δείγμα δεδομένων, γεγονός που μπορεί να οδηγήσει σε ανεπιθύμητους βρόχους ανατροφοδότησης και κακή σύγκλιση [9]. Με τη χρήση experience replay, η κατανομή συμπεριφοράς υπολογίζεται κατά μέσο όρο από πολλές προηγούμενες καταστάσεις, ομαλοποιώντας τη μάθηση.

Σημειώνεται ότι η μάθηση μέσω experience replay απαιτεί προσέγγιση εκτός πολιτικής, καθώς οι τρέχουσες παραμέτροι διαφέρουν από εκείνες που χρησιμοποιήθηκαν για τη δημιουργία του δείγματος, γεγονός που αιτιολογεί την επιλογή του Q-Learning ως βάση της μεθόδου [9].

2.4.2 Target Network

Η δεύτερη βασική καινοτομία του DQN είναι η χρήση ενός ξεχωριστού δικτύου-στόχου (target network) για τη δημιουργία των τιμών-στόχων y_j στην ενημέρωση του Q-Learning [9]. Συγκεκριμένα, διατηρούνται δύο νευρωνικά δίκτυα με την ίδια αρχιτεκτονική αλλά διαφορετικές παραμέτρους [4]:

- Το **Q-eval network** με παραμέτρους θ , το οποίο εκπαιδεύεται συνεχώς και χρησιμοποιείται για την επιλογή της βέλτιστης ενέργειας στην τρέχουσα κατάσταση.
- Το **Q-target network** με παραμέτρους θ^- , το οποίο χρησιμοποιείται για τον υπολογισμό των τιμών-στόχων κατά την εκπαίδευση.

Κάθε C ενημερώσεις, οι παράμετροι του Q-eval network αντιγράφονται στο Q-target network ($\theta^- \leftarrow \theta$) [9, 4]. Η συνάρτηση απώλειας για την ενημέρωση του δικτύου παίρνει τη μορφή [4]:

$$L(\theta) = \mathbb{E} \left[\left(r_t + \gamma \max_{a'} Q(s_{t+1}, a'; \theta^-) - Q(s_t, a_t; \theta) \right)^2 \right] \quad (2.7)$$

Αυτή η τροποποίηση καθιστά τον αλγόριθμο πιο σταθερό σε σύγκριση με το συμβατικό Q-Learning σε απευθείας μάθηση, όπου μια ενημέρωση που αυξάνει το $Q(s_t, a_t)$ συχνά αυξάνει επίσης το $Q(s_{t+1}, a)$ για όλες τις ενέργειες a , και ως εκ τούτου αυξάνει τον στόχο y_j , οδηγώντας ενδεχομένως σε ταλαντώσεις ή απόκλιση της πολιτικής [9]. Η δημιουργία των στόχων χρησιμοποιώντας ένα παλαιότερο σύνολο παραμέτρων προσθέτει μια χρονική καθυστέρηση μεταξύ της στιγμής που η ενημέρωση επηρεάζει τους στόχους, καθιστώντας πολύ λιγότερο πιθανές την απόκλιση και τις ταλαντώσεις [9].

Επιπλέον, το DQN εφαρμόζει την τεχνική του gradient clipping, περικλύποντας τον όρο σφάλματος της ενημέρωσης ώστε να βρίσκεται στο διάστημα $[-1, 1]$ [9]. Αυτή η μορφή περικυπής σφάλματος αντιστοιχεί στη χρήση μιας συνάρτησης απώλειας απόλυτης τιμής για σφάλματα εκτός του διαστήματος $(-1, 1)$ και βελτιώνει περαιτέρω τη σταθερότητα του αλγορίθμου [9].

2.4.3 Double DQN

Παρά τις βελτιώσεις του DQN έναντι του κλασικού Q-Learning, οι τιμές Q εξακολουθούν να υπερεκτιμώνται [12]. Η υπερεκτίμηση αυτή οφείλεται στον τελεστή μεγίστου $\max$ στην εξίσωση ενημέρωσης, ο οποίος χρησιμοποιεί τις ίδιες τιμές τόσο για την επιλογή ενέργειας (action selection) όσο και για την αξιολόγηση ενέργειας (action evaluation) [12]. Ειδικότερα, η τιμή-στόχος του DQN μπορεί να γραφεί ως:

$$y_t^{\text{DQN}} = r_{t+1} + \gamma Q \left(s_{t+1}, \arg \max_{a'} Q(s_{t+1}, a'; \theta^-); \theta^- \right) \quad (2.8)$$

όπου παρατηρείται ότι το ίδιο δίκτυο θ^- χρησιμοποιείται και για την επιλογή και για την αξιολόγηση της ενέργειας [12].

Το Double DQN (DDQN), που προτάθηκε από τους Van Hasselt et al., αντιμετωπίζει αυτό το πρόβλημα αποσυνδέοντας την επιλογή ενέργειας από την αξιολόγηση της [13]:

$$y_t^{\text{DDQN}} = r_{t+1} + \gamma Q \left(s_{t+1}, \arg \max_{a'} Q(s_{t+1}, a'; \theta); \theta^- \right) \quad (2.9)$$

όπου το θ είναι οι παράμετροι του online δικτύου που χρησιμοποιείται για την επιλογή ενέργειας, ενώ το θ^- είναι οι παράμετροι του δικτύου-στόχου που χρησιμοποιείται για την αποτίμηση της τιμής [12]. Αυτή η αποσύνδεση μειώνει σημαντικά την υπερεκτίμηση των τιμών Q , οδηγώντας σε πιο σταθερή και ακριβέστερη πολιτική [12].

Στο πλαίσιο εφαρμογών σχεδιασμού διαδρομής αυτόνομων οχημάτων, το DDQN έχει αποδειχθεί ότι οδηγεί σε καλύτερη γενίκευση και ταχύτερη σύγκλιση από το βασικό DQN [12]. Λόγω αυτών των

πλεονεκτημάτων, στην παρούσα εργασία υιοθετείται η αρχιτεκτονική Double DQN για την εκπαίδευση των πρακτόρων σμήνους UAV, η αναλυτική υλοποίηση της οποίας παρουσιάζεται στην Ενότητα 4.4.

2.5 Διαμόρφωση Ανταμοιβής (Reward Shaping)

Στην Ενισχυτική Μάθηση, ο σχεδιασμός της συνάρτησης ανταμοιβής αποτελεί μία από τις πιο κρίσιμες αποφάσεις, καθώς καθορίζει άμεσα τη συμπεριφορά που τελικά θα μάθει ο πράκτορας. Σε προβλήματα σχεδιασμού διαδρομής, η φυσική επιλογή είναι μια αραιή (sparse) συνάρτηση ανταμοιβής, η οποία παρέχει θετική ανταμοιβή μόνο όταν ο πράκτορας φτάνει στον στόχο και αρνητική ανταμοιβή σε περίπτωση σύγκρουσης. Ωστόσο, οι αραιές ανταμοιβές οδηγούν σε άκυρη εξερεύνηση και τοπικά βέλτιστα, ενώ καθιστούν την εκπαίδευση εξαιρετικά αργή ή ακόμη και αδύνατη σε σύνθετα περιβάλλοντα [14].

Η διαμόρφωση ανταμοιβής (Reward Shaping) αποτελεί μια τεχνική η οποία ενσωματώνει πρόσθετη πληροφορία στη συνάρτηση ανταμοιβής μέσω επιμέρους συνιστωσών (sub-rewards) που καθοδηγούν τον πράκτορα προς την επιθυμητή συμπεριφορά σε κάθε χρονικό βήμα [3, 1]. Αντί ο πράκτορας να λαμβάνει ανατροφοδότηση μόνο στο τέλος ενός επεισοδίου, η διαμόρφωση ανταμοιβής παρέχει πυκνά σήματα (dense rewards) που επιταχύνουν τη σύγκλιση και βελτιώνουν την ποιότητα της τελικής πολιτικής.

Δομή Διαμορφωμένης Συνάρτησης Ανταμοιβής

Σε εφαρμογές πλοήγησης αυτόνομων οχημάτων, η συνολική συνάρτηση ανταμοιβής εκφράζεται συνήθως ως ένα σταθμισμένο άθροισμα επιμέρους συνιστωσών [3, 11]:

$$r_t = \sum_k w_k \cdot r_k(s_t, a_t) \quad (2.10)$$

όπου r_k είναι κάθε επιμέρους ανταμοιβή και w_k το αντίστοιχο βάρος που εκφράζει τη σχετική σημασία της συνιστώσας στην επιθυμητή συμπεριφορά. Οι τυπικές συνιστώσες περιλαμβάνουν [3]:

- **Ανταμοιβή τερματισμού (r_{terminal}):** Μεγάλη θετική ανταμοιβή όταν ο πράκτορας επιτυχώς φτάνει τον στόχο. Αποτελεί το μόνο σήμα ανατροφοδότησης σε μια αραιή διατύπωση [3].
- **Ανταμοιβή σύγκρουσης (r_{obstacle}):** Μεγάλη αρνητική ανταμοιβή (ποινή) που επιβάλλεται σε περίπτωση σύγκρουσης με εμπόδιο, αποθαρρύνοντας επικίνδυνες ενέργειες [3, 11].
- **Ανταμοιβή απόστασης / προόδου (r_{progress}):** Συνιστώσα ανάλογη της μείωσης της απόστασης από τον στόχο σε κάθε βήμα. Παρέχει συνεχή ανατροφοδότηση που ενθαρρύνει την προοδευτική προσέγγιση του στόχου, ακόμη και χωρίς ολοκλήρωση της αποστολής [11].
- **Ανταμοιβή προσανατολισμού (r_{heading}):** Συνιστώσα που επιβραβεύει ή τιμωρεί την ευθυγράμμιση του οχήματος με την κατεύθυνση του στόχου, εξασφαλίζοντας ομαλές αλλαγές κατεύθυνσης [3, 11].
- **Ανταμοιβή ενέργειας / ομαλότητας (r_{energy}):** Ποινή ανάλογη του μεγέθους της γωνίας στροφής ή της επιτάχυνσης, η οποία ενθαρρύνει ομαλές και ενεργειακά αποδοτικές τροχιές [1].
- **Ανταμοιβή χρονικού βήματος (r_{step}):** Μικρή σταθερή αρνητική ανταμοιβή σε κάθε βήμα, η οποία ενθαρρύνει τον πράκτορα να ολοκληρώσει την αποστολή σε όσο το δυνατόν λιγότερα βήματα [3].

Επιλογή Βαρών και Ιεράρχηση

Η επιλογή των βαρών w_k είναι καθοριστική για την επιτυχία της εκπαίδευσης. Σε γενικές γραμμές, οι ποινές για κρίσιμες παραβιάσεις (π.χ. σύγκρουση) πρέπει να είναι κατά τάξεις μεγέθους μεγαλύτερες από τις ανταμοιβές διαμόρφωσης, διατηρώντας ιεραρχική σχέση όπως: $|r_{\text{obstacle}}| > |r_{\text{heading}}| > |r_{\text{distance}}| > |r_{\text{step}}|$ [3]. Αυτή η ιεράρχηση εξασφαλίζει ότι ο πράκτορας μαθαίνει πρώτα τους θεμελιώδεις κανόνες ασφαλείας πριν βελτιστοποιήσει δευτερεύοντες στόχους όπως η ομαλότητα ή η ενεργειακή αποδοτικότητα.

Διαμόρφωση Ανταμοιβής σε Συστήματα Σμήνους

Σε πολυπρακτορικά συστήματα όπως τα σμήνη UAV, η διαμόρφωση ανταμοιβής επεκτείνεται ώστε να ενσωματώσει συλλογικές συμπεριφορές πέρα από την ατομική πλοήγηση. Συγκεκριμένα, η συνολική ανταμοιβή κάθε πράκτορα συμπληρώνεται με συνιστώσες που αντιπροσωπεύουν τους κανόνες συμπεριφοράς σμήνους του Reynolds [7, 15]:

$$r_{\text{total},i} = r_{\text{individual},i} + r_{\text{cohesion},i} + r_{\text{separation},i} + r_{\text{alignment},i} \quad (2.11)$$

όπου $r_{\text{individual},i}$ είναι η ατομική ανταμοιβή πλοήγησης του πράκτορα i και $r_{\text{cohesion},i}$, $r_{\text{separation},i}$, $r_{\text{alignment},i}$ είναι οι συνιστώσες σμήνους που αντιπροσωπεύουν τη συνοχή, τον διαχωρισμό και την ευθυγράμμιση αντίστοιχα. Η μαθηματική διατύπωση αυτών των συνιστωσών στην παρούσα εργασία παρουσιάζεται αναλυτικά στην Ενότητα 4.5, όπου περιγράφεται η υλοποίηση του `SwarmRewardShaper`.

Προκλήσεις και Σχεδιαστικές Επιλογές

Παρά τα οφέλη της, η διαμόρφωση ανταμοιβής εισάγει σημαντικές προκλήσεις. Η ακατάλληλη επιλογή συνιστωσών ή βαρών μπορεί να οδηγήσει σε μη επιθυμητές συμπεριφορές, όπου ο πράκτορας μαθαίνει να μεγιστοποιεί τις διαμορφωμένες ανταμοιβές χωρίς να επιτυγχάνει τον πραγματικό στόχο της αποστολής [1]. Επιπλέον, η ισορρόπηση πολλαπλών συνιστωσών δημιουργεί ένα σύνθετο πρόβλημα πολυκριτηριακής βελτιστοποίησης, ιδιαίτερα όταν οι στόχοι είναι αντικρουόμενοι (π.χ. ασφάλεια έναντι μήχους διαδρομής) [1].


Πρόσφατες μελέτες έχουν προτείνει την ενσωμάτωση ασαφούς λογικής (fuzzy logic) στη διαμόρφωση ανταμοιβής για τη διαχείριση αντικρουόμενων στόχων με τρόπο ερμηνεύσιμο και κοντινό στον ανθρώπινο συλλογισμό [1]. Στην παρούσα εργασία υιοθετείται μια απλούστερη αλλά αποτελεσματική προσέγγιση, μια εμπειρικά βαθμονομημένη διαμόρφωση ανταμοιβής με σαφή ιεράρχηση σημασίας μεταξύ ατομικών και συλλογικών συνιστωσών, η οποία αποδεικνύεται ικανή να καθοδηγήσει αποδοτικά την εκπαίδευση των πρακτόρων σμήνους UAV σε σύνθετα περιβάλλοντα με εμπόδια.

ΚΕΦΑΛΑΙΟ 3: Θεωρητικό Υπόβαθρο

3.1 Συστήματα UxV - Ορισμοί και Κατηγορίες

Ο όρος UxV (Unmanned Vehicle) αναφέρεται σε ένα ευρύ φάσμα αυτόνομων ή τηλεκατευθυνόμενων οχημάτων που λειτουργούν χωρίς την άμεση παρουσία ανθρώπινου χειριστή επί του οχήματος. Ανάλογα με το περιβάλλον λειτουργίας τους τα συστήματα UxV κατηγοριοποιούνται σε τέσσερις βασικούς τύπους [5]:

- **UAV (Unmanned Aerial Vehicle):** Μη επανδρωμένα εναέρια οχήματα που λειτουργούν στον αέρα. Αποτελούν την πιο διαδεδομένη κατηγορία UxV και χρησιμοποιούνται ευρέως σε στρατιωτικές και αστικές εφαρμογές.
- **UGV (Unmanned Ground Vehicle):** Μη επανδρωμένα χερσαία οχήματα που κινούνται στο έδαφος. Χρησιμοποιούνται κυρίως για αποστολές σε επικίνδυνα εδαφικά περιβάλλοντα.
- **USV (Unmanned Surface Vehicle):** Μη επανδρωμένα πλωτά οχήματα επιφάνειας. Εφαρμόζονται σε περιβαλλοντικές και θαλάσσιες αποστολές παρακολούθησης και χαρτογράφησης.
- **AUV (Autonomous Underwater Vehicle):** Αυτόνομα υποβρύχια οχήματα που λειτουργούν κάτω από την επιφάνεια της θάλασσας για υποβρύχιες έρευνες και αποστολές.




Σχήμα 3.1: Οι τέσσερις βασικές κατηγορίες μη επανδρωμένων οχημάτων (UxV) ανάλογα με το περιβάλλον λειτουργίας τους [5].

Η παρούσα εργασία εστιάζει στην κατηγορία των UAV, και ειδικότερα στην ανάπτυξη συστημάτων σμήνους αυτών. Τα UAV ορίζονται ως αεροσκάφη που λειτουργούν χωρίς ανθρώπινο πιλότο επί του οχήματος [6]. Ορισμένα από τα κύρια δομικά στοιχεία ενός UAV περιλαμβάνουν [6]:

- **Ηλεκτρονικός Ελεγκτής Ταχύτητας (ESC):** Ηλεκτρονικό κύκλωμα που ελέγχει την ταχύτητα των κινητήρων του UAV.
- **Μονάδα GPS:** Χρησιμοποιείται για τον υπολογισμό της θέσης και του χρόνου, παρέχοντας πληροφορίες γεωγραφικού πλάτους, μήκους και υψομέτρου.
- **Αισθητήρες:** Περιλαμβάνουν συστήματα LIDAR, υπέρυθρες κάμερες και αισθητήρες εμβέλειας για ανίχνευση εμποδίων και αποφυγή συγκρούσεων.

- **Ελεγκτής Πτήσης (Flight Controller):** Αποτελεί το κεντρικό σύστημα ελέγχου που λαμβάνει δεδομένα από τον GPS και τους αισθητήρες για τη λήψη αποφάσεων πλοήγησης.
- **Μπαταρία:** Παρέχει την ενέργεια που απαιτείται για τη λειτουργία του UAV.



Σχήμα 3.2: Δομικά στοιχεία ενός τυπικού UAV: ESC, GPS, αισθητήρες, ελεγκτής πτήσης και μπαταρία. Αναπαραγωγή από [6].

Τα UAV διακρίνονται επίσης ανάλογα με τον τύπο τους σε σταθερής πτέρυγας (fixed-wing) και περιστρεφόμενης πτέρυγας (rotary-wing). Τα πρώτα προσφέρουν μεγαλύτερη εμβέλεια και αυτονομία, ενώ τα δεύτερα παρέχουν μεγαλύτερη ευελιξία και δυνατότητα κατακόρυφης απογείωσης και προσγείωσης (VTOL) [6].

Η ανάγκη για αυτόνομη λειτουργία αποτελεί βασική προϋπόθεση για την αξιοποίηση των UAVs σε πραγματικές αποστολές. Για τον σκοπό αυτό, τα UAVs πρέπει να είναι σε θέση να λαμβάνουν αποφάσεις σχεδιασμού ασφαλούς διαδρομής αυτόνομα, αξιοποιώντας τις πληροφορίες που συλλέγουν από τους αισθητήρες τους [6]. Αυτή η ανάγκη αποτελεί το βασικό κίνητρο για την ανάπτυξη τεχνικών DRL για τον σχεδιασμό διαδρομής και την αποφυγή εμποδίων σε συστήματα σμήνους UAV, όπως διερευνάται στην παρούσα εργασία.

3.2 Σχεδιασμός Διαδρομής (Path Planning)

Ο σχεδιασμός διαδρομής αποτελεί ένα θεμελιώδες πρόβλημα στον τομέα των αυτόνομων οχημάτων. Ορίζεται ως η διαδικασία εύρεσης μιας βέλτιστης και ασφαλούς διαδρομής για ένα όχημα από ένα σημείο εκκίνησης προς έναν στόχο, ελεύθερης από συγκρούσεις με τα εμπόδια του περιβάλλοντος [6]. Ο στόχος του σχεδιασμού διαδρομής δεν είναι μόνο η εύρεση μιας βέλτιστης και συντομότερης διαδρομής, αλλά και η παροχή ενός περιβάλλοντος ελεύθερου από συγκρούσεις για το όχημα, λαμβάνοντας υπόψη παραμέτρους όπως το μήκος διαδρομής, η βελτιστότητα και η πληρότητα [6].

3.2.1 Κλασικές Μέθοδοι

Οι κλασικές μέθοδοι σχεδιασμού διαδρομής αποτελούν τις παραδοσιακές προσεγγίσεις που έχουν αναπτυχθεί για την επίλυση του προβλήματος πλοήγησης σε περιβάλλοντα με εμπόδια. Οι κυριότερες από αυτές είναι οι εξής:

Αλγόριθμος A*: Ο A* είναι ένας από τους πιο διαδεδομένους αλγόριθμους αναζήτησης διαδρομής, ο οποίος χρησιμοποιεί μια ευρετική συνάρτηση για να καθοδηγεί την αναζήτηση προς τον στόχο.



Σχήμα 3.3: Ταξινόμια μεθόδων σχεδιασμού διαδρομής για UAV. Αναπαραγωγή από [6].

Έχει εφαρμοστεί ευρέως σε προβλήματα πλοήγησης UAV και παρέχει βέλτιστες λύσεις όταν η ευρετική συνάρτηση είναι αποδεκτή [6, 1].


Αλγόριθμος RRT (Rapidly-Exploring Random Tree): Ο RRT είναι ένας αλγόριθμος βασισμένος σε δειγματοληψία που σχεδιάζει δέντρα τυχαίας εξερεύνησης στον χώρο διαμόρφωσης. Χρησιμοποιείται για τον σχεδιασμό διαδρομής UAV σε χώρους υψηλών διαστάσεων και σε μη κυρτά περιβάλλοντα [6]. Η επέκτασή του, RRT*, προσφέρει ασυμπτωτική βελτιστότητα και χρησιμοποιείται για βέλτιστο σχεδιασμό τροχιάς.

Μέθοδος Δυναμικού Πεδίου (Potential Field Method, PFM): Η PFM είναι μια απλή μέθοδος για δυναμικό σχεδιασμό διαδρομής. Αναπαριστά το περιβάλλον σχεδιάζοντας ένα αντικείμενο ως σωματίδιο που κινείται υπό τον έλεγχο πεδίων δυναμικού γύρω από τον χώρο διαμόρφωσης. Η διαδρομή υπολογίζεται βάσει των ελκτικών δυνάμεων προς τον στόχο και των απωθητικών δυνάμεων από τα εμπόδια. Παρόλα αυτά, η συμβατική PFM υποφέρει από το πρόβλημα τοπικών ελαχίστων, το οποίο μπορεί να παγιδεύσει το όχημα πριν φτάσει στον στόχο. Η βελτιωμένη έκδοσή της, το Τεχνητό Δυναμικό Πεδίο (Artificial Potential Field, APF), χρησιμοποιείται για να σχεδιάσει τη διαδρομή και να προσελκύσει το UAV προς τις επιθυμητές διαμορφώσεις στόχου, και ταυτόχρονα να το απωθήσει από τα εμπόδια [6].

Άλλες Μέθοδοι: Εκτός από τις παραπάνω, έχουν αναπτυχθεί και άλλες κλασικές μέθοδοι όπως ο αλγόριθμος Dijkstra, τα διαγράμματα Voronoi, η Βελτιστοποίηση Σμήνους Σωματιδίων (PSO) και ο Γενετικός Αλγόριθμος (GA), οι οποίοι έχουν εφαρμοστεί σε διάφορα σενάρια σχεδιασμού διαδρομής [1, 8].

Παρά την αποτελεσματικότητά τους σε ορισμένα σενάρια, οι κλασικές μέθοδοι παρουσιάζουν σημαντικούς περιορισμούς. Συγκεκριμένα, όλες αυτές οι μέθοδοι υιοθετούν μια επαναληπτική στρατηγική, όπου ο χάρτης του περιβάλλοντος πρέπει να κατασκευάζεται συνεχώς και να τροφοδοτείται στους αλγορίθμους για την αναζήτηση τροχιών, γεγονός που εμποδίζει την υιοθέτησή τους σε εφαρμογές πραγματικού χρόνου [3]. Επιπλέον, η απόδοση τους υποβαθμίζεται σημαντικά σε δυναμικά και μερικώς γνωστά περιβάλλοντα, όπου τα εμπόδια είναι άγνωστα εκ των προτέρων [1].

Ο Πίνακας 3.1 συνοψίζει τις κυριότερες εργασίες που έχουν χρησιμοποιήσει κλασικές μεθόδους για τον σχεδιασμό διαδρομής UAV.



Σχήμα 3.4: Παράδειγμα κλασικών μεθόδων σχεδιασμού διαδρομής σε διδιάστατο χώρο. Αναπαγωγή από [6].

Πίνακας 3.1: Σχετικές εργασίες κλασικών μεθόδων σχεδιασμού διαδρομής UAV.

Εργασία	Πεδίο	Μέθοδος	Στόχοι	Περιβάλλον	Κύρια Ευρήματα
Singh et al. [16]	USV	A* με δυναμικά εμπόδια	Βέλτιστη διαδρομή, ασφάλεια	Θαλάσσιο περιβάλλον	A* με περιορισμούς επιτυγχάνει ασφαλή πλοήγηση USV σε δυναμικά θαλάσσια περιβάλλοντα με ρεύματα.
Song & Hu [17]	UAV	Τροποποιημένο A* (Dubins)	Βελτιστοποίηση μήκους διαδρομής	Προσομοίωση	Μείωση μήκους διαδρομής από 71.1m σε 68.58m έναντι κλασικού A* σε πλέγμα.
Zhang et al. [18]	UAV	RRT-Connect + APF	Βέλτιστη διαδρομή, αποφυγή εμποδίων	Προσομοίωση	RRT-Connect μειώνει απόσταση από 197.9m σε 188.7m και χρόνο από 0.75s σε 0.04s.
Yang et al. [19]	UAV	EPF-RRT	Αποδοτική διαδρομή, σύγκλιση	Προσομοίωση	Μείωση μέσου μήκους διαδρομής κατά 20% έναντι κλασικού RRT, υψηλή αποδοτικότητα σε προβλήματα σύγκλισης.
Abeywickramanayake et al. [20]	UAV	Βελτιωμένη PFM (virtual target relocation)	Μείωση συγχρούσεων, χρονική αποδοτικότητα	Προσομοίωση	Μείωση του συνολικού χρόνου του συστήματος κατά ~ 20% έναντι του παραδοσιακού PFM.
Phung & Ha (2021) [21]	UAV	PSO με σφαιρικά διανύσματα	Ασφαλής πλοήγηση, αποφυγή εμποδίων	Προσομοίωση	Ενισχυμένη ασφάλεια UAV μέσω PSO, βελτίωση σε τρισδιάστατο χώρο με στατικά εμπόδια.
Ntakolia et al. (2022) [8]	UAV	Γενετικός Αλγόριθμος + Ασαφής Λογική	Πολυκριτηριακός σχεδιασμός αποστολής	Πραγματικά σενάρια	Υπεροχή σε πολυκριτηριακά προβλήματα, ευελιξία σε πολλαπλούς στόχους αποστολής.
Bartsiokas et al. (2025) [1]	USV	A*, D* Lite, APF (αξιολόγηση)	Αποφυγή εμποδίων, μήκος διαδρομής	Θαλάσσιο περιβάλλον	Κλασικές μέθοδοι αδυνατούν να αντιμετωπίσουν ταυτόχρονα πολλαπλούς στόχους σε δυναμικά περιβάλλοντα.

3.2.2 Μέθοδοι Βασισμένες σε Μηχανική Μάθηση

Η ραγδαία ανάπτυξη της Τεχνητής Νοημοσύνης και ειδικότερα της Μηχανικής Μάθησης έχει ανοίξει νέες δυνατότητες για την επίλυση του προβλήματος σχεδιασμού διαδρομής. Σε αντίθεση με τις κλασικές

μεθόδους, οι προσεγγίσεις βασισμένες σε DRL επιτρέπουν στα οχήματα να μαθαίνουν βέλτιστες στρατηγικές πλοήγησης απευθείας μέσω αλληλεπίδρασης με το περιβάλλον, καθιστώντας τις κατάλληλες για μερικώς γνωστά ή στοχαστικά περιβάλλοντα [1].

Οι μέθοδοι μηχανικής μάθησης που χρησιμοποιούνται στον σχεδιασμό διαδρομής διακρίνονται στις εξής κατηγορίες [6]:

- **Μη Επιβλεπόμενη Μάθηση:** Αλγόριθμοι ομαδοποίησης (clustering) όπως ο k-means χρησιμοποιούνται για ομαδοποίηση σημείων στόχων και επίλυση προβλημάτων προγραμματισμού αεροσπολίων UAV.
- **Ενισχυτική Μάθηση (RL):** Αποτελεί την πιο διαδεδομένη κατηγορία μηχανικής μάθησης για τον σχεδιασμό διαδρομής UAV. Ο πράκτορας εκπαιδεύεται μέσω αλληλεπίδρασης με το περιβάλλον, χωρίς να απαιτείται εκ των προτέρων γνώση αυτού [6, 3].
- **Βαθιά Ενισχυτική Μάθηση (Deep Reinforcement Learning, DRL):** Η DRL είναι ένας υποτομέας της Τεχνητής Νοημοσύνης που συνδυάζει τεχνικές της Βαθιάς Μάθησης με αυτές της Ενισχυτικής Μάθησης [10]. Περιλαμβάνει την εκπαίδευση τεχνητών πρακτόρων για την εκμάθηση βέλτιστων πολιτικών λήψης αποφάσεων μέσω αλληλεπίδρασης με το περιβάλλον. Η DRL αξιοποιεί βαθιά νευρωνικά δίκτυα (DNNs) για την προσέγγιση σύνθετων συναρτήσεων αξίας ή πολιτικών που αντιστοιχούν παρατηρούμενες καταστάσεις σε ενέργειες [10]. Σε αντίθεση με τα παραδοσιακά σχήματα RL όπου οι πράκτορες μαθαίνουν από βαθμωτές ανταμοιβές, στη DRL τα DNNs χρησιμοποιούνται για την επεξεργασία εισόδων υψηλών διαστάσεων, όπως δεδομένα αισθητήρων, επιτρέποντας στον πράκτορα να μαθαίνει απευθείας από ακατέργαστες αισθητηριακές εισόδους χωρίς χειροκίνητη δημιουργία χαρακτηριστικών [10, 9].

Ειδικότερα, η Βαθιά Ενισχυτική Μάθηση έχει αναδειχθεί ως η πιο υποσχόμενη προσέγγιση για τον σχεδιασμό διαδρομής σε σύνθετα περιβάλλοντα. Σε αντίθεση με το Q-learning που εκπαιδεύει έναν πράκτορα διατηρώντας έναν πίνακα Q και υποφέρει από την αύξηση του αριθμού ενεργειών, μέθοδοι βασισμένες στο ANN όπως το DQN μπορούν να χρησιμοποιηθούν σε σενάρια με χώρους καταστάσεων υψηλών διαστάσεων [3]. Χρησιμοποιώντας μια προσέγγιση εκπαίδευσης δοκιμής-λάθους, σε αντίθεση με τις άλλες δύο μεθόδους μηχανικής μάθησης, η RL δεν απαιτεί ανθρώπινη γνώση ή προκαθορισμένους κανόνες [3].

Πρώιμες εφαρμογές DRL σε UAV επικεντρώθηκαν στην αποφυγή εμποδίων και στη βελτιστοποίηση τροχιάς υπό ενεργειακούς ή επικοινωνιακούς περιορισμούς, ενώ πιο πρόσφατες μελέτες έχουν υιοθετήσει DRL για την αντιμετώπιση δυναμικών προκλήσεων, συμπεριλαμβανομένων κινούμενων εμποδίων και περιβάλλοντων με αβεβαιότητα [1].

Ο Πίνακας 3.2 παρουσιάζει αντιπροσωπευτικές εργασίες ML/DRL για σχεδιασμό διαδρομής UAV, συμπεριλαμβανομένης της παρούσας εργασίας για σύγκριση.

3.3 Αποφυγή Εμποδίων (Obstacle Avoidance)

Η αποφυγή εμποδίων αποτελεί αναπόσπαστο τμήμα του σχεδιασμού διαδρομής και ορίζεται ως η ικανότητα ενός αυτόνομου οχήματος να ανιχνεύει και να αποφεύγει στατικά ή δυναμικά εμπόδια κατά τη διάρκεια της πλοήγησής του, χωρίς φυσική βλάβη στο όχημα ή στο περιβάλλον [6]. Η ανίχνευση εμποδίων πραγματοποιείται μέσω αισθητήρων όπως LIDAR, υπέρηχοι, υπέρυθρες κάμερες και αισθητήρες

Πίνακας 3.2: Σχετικές εργασίες μεθόδων Μηχανικής Μάθησης για σχεδιασμό διαδρομής UxV.

Εργασία	Πεδίο	Μέθοδος	Στόχοι	Περιβάλλον	Κύρια Ευρήματα
Yan et al. (2020) [12]	UAV	DRL (D3QN)	Σχεδιασμός διαδρομής πραγματικού χρόνου σε δυναμικά περιβάλλοντα	Προσομοίωση με κινούμενα εμπόδια	DRL επιτυγχάνει αποτελεσματική πλοήγηση χωρίς εκ των προτέρων γνώση χάρτη, υπεροχή έναντι κλασικών μεθόδων σε δυναμικά σενάρια.
Zhou et al. (2019) [3]	USV (μονό & σχηματισμοί)	DRL (DQN)	Αποφυγή σύγκρουσης, μήκος διαδρομής, διατήρηση σχηματισμού	Προσομοίωση + πραγματικά λιμενικά δεδομένα	DRL υπολογίζει συντομότερες διαδρομές χωρίς συγκρούσεις, εφαρμόσιμότητα σε πυκνά περιβάλλοντα εμποδίων.
Qu et al. [11]	USV	DWA + Safe RL	Αποφυγή εμποδίων, ασφάλεια, εφικτότητα διαδρομής	Προσομοίωση θαλάσσιου περιβάλλοντος	Συνδυασμός τοπικής κίνησης DW-A με πολιτική Safe-RL, βελτιωμένη ασφάλεια σε θαλάσσιες προσομοιώσεις.
Li et al. (2023) [22]	USV	DQN + NN-MPC	Αποφυγή δυναμικών εμποδίων, ακρίβεια παρακολούθησης	Προσομοίωση + πραγματικό περιβάλλον	Cross-domain εκπαίδευση μειώνει το χρόνο κατά 28% και αυξάνει την απόδοση κατά 70 μονάδες ανταμοιβής.
Xing et al. [4]	USV	RL (DQN)	Πληρότητα κάλυψης, μήκος διαδρομής	Προσομοίωση	Σχεδιαστής πλήρους κάλυψης βάσει RL, εστίαση σε μετρικές αποστολής κάλυψης.
Nantogma et al. (2023) [5]	Πολλαπλά USV	Υβριδικό MARL + Ευρετικοί μηχανισμοί	Κατανομή εργασιών, αποφυγή εμποδίων, συντονισμός ομάδας	Προσομοίωση	Ευρετικό μοντέλο ανοσοποιητικού δικτύου + actor-critic επιτυγχάνει αποτελεσματική ομαδική αποστολή.
Bartsiokas et al. (2025) [1]	USV	DQN & Fuzzy DQN	Πολυκριτηριακός σχεδιασμός (διαδρομή, ομαλότητα, κατανάλωση καυσίμου)	Θαλάσσιο περιβάλλον με εμπόδια	F-DQN επιτυγχάνει μείωση μήκους 35% και μείωση ενέργειας 70-80% έναντι βασικού DQN.

εμβέλειας, οι οποίοι παρέχουν πληροφορίες για τη θέση και τις διαστάσεις των εμποδίων στο περιβάλλον [6, 22].

Οι παραδοσιακές μέθοδοι αποφυγής δυναμικών εμποδίων αξιοποιούν τυπικά αισθητήρες προς τα εμπρός για την ανίχνευση και πρόβλεψη της κίνησης των εμποδίων. Οι υπάρχουσες προσεγγίσεις για αποφυγή συγκρούσεων ενός πράκτορα μπορούν να κατηγοριοποιηθούν ευρέως σε δύο κατηγορίες [22]:

- **Έλεγχος Πρόβλεψης Μοντέλου (Model Predictive Control, MPC):** Χρησιμοποιεί ένα μοντέλο δεδομένων ή αριθμητικό μοντέλο για να συσχετίσει τις εξόδους ελέγχου με αλλαγές κατάστασης του οχήματος σε σχέση με περιβαλλοντικούς και κινηματικούς περιορισμούς. Το πλεονέκτημα του MPC για αποφυγή εμποδίων είναι η ικανότητα να λαμβάνει υπόψη μελλοντικές χρονικές καταστάσεις κατά τη δημιουργία εξόδων ελέγχου [22].
- **Αλγόριθμοι Αποφυγής Συγκρούσεων:** Μετατρέπουν συγχωνευμένες εισόδους περιβαλ-

λοντικής αίσθησης (Lidar, radar, εικόνες) σε εντολές ρομποτικής δράσης μέσω αλλαγών τροχιάς ή απευθείας ενεργοποίησης οχήματος χαμηλού επιπέδου [22].

Ωστόσο, οι παραδοσιακοί αλγόριθμοι σχεδιασμού κίνησης παρουσιάζουν περιορισμούς ως προς την αντιδραστική συμπεριφορά λόγω της υπολογιστικής προσπάθειας που απαιτείται για τον επανασχεδιασμό της διαδρομής. Επιπλέον, σε σενάρια μεγάλης κλίμακας, οι μέθοδοι βασισμένες σε πλέγμα υποφέρουν από ανακριβείς αναπαραστάσεις εμποδίων ή μεγάλες απαιτήσεις μνήμης [22].

Πρόσφατες εξελίξεις στην υπολογιστική ισχύ έχουν επιτρέψει την εφαρμογή της DRL για την επίτευξη νέων δυνατοτήτων πέρα από αυτές που παρέχει η κλασική πλοήγηση [22, 9]. Η DRL έχει εφαρμοστεί επιτυχώς για την επίλυση προβλημάτων αποφυγής εμποδίων σε διαφορετικά πεδία, όπως το έδαφος, ο αέρας και το νερό [22]. Ειδικότερα:

- Στο **εναέριο πεδίο**, η Deep Deterministic Policy Gradient (DDPG) υιοθετήθηκε για την ανάπτυξη αλγόριθμου αντιδραστικής πλοήγησης χωρίς χάρτη για πολυκόπτερα [22].
- Στο **χερσαίο πεδίο**, αναπτύχθηκε αρχιτεκτονική ανακυκλούμενου νευρωνικού δικτύου για την υπέρβαση του περιορισμένου πεδίου όρασης στην πλοήγηση κινητών ρομπότ [22].
- Στο **θαλάσσιο πεδίο**, έχουν αναπτυχθεί υβριδικές προσεγγίσεις που συνδυάζουν DRL με NN-MPC για αποφυγή δυναμικών εμποδίων, επιτυγχάνοντας σημαντική βελτίωση της απόδοσης αποφυγής συγκρούσεων σε σύγκριση με την αμιγή εκπαίδευση σε ένα μόνο πεδίο [22].

Στη συγκεκριμένη μελέτη η αποφυγή εμποδίων υλοποιείται μέσω αισθητήρων εμβέλειας που ανιχνεύουν εμπόδια σε πέντε γωνίες ($-60^\circ, -30^\circ, 0^\circ, 30^\circ, 60^\circ$) ως προς τον προσανατολισμό του UAV. Η πληροφορία αυτή ενσωματώνεται στον χώρο παρατηρήσεων του πράκτορα DQN, επιτρέποντας την ανάπτυξη αποτελεσματικής πολιτικής αποφυγής εμποδίων μέσω εκπαίδευσης ενισχυτικής μάθησης, χωρίς την ανάγκη εκ των προτέρων γνώσης του χάρτη [1, 9].


3.4 Συστήματα Σμήνους (Swarm Systems)

Τα συστήματα σμήνους αποτελούν μια από τις πλέον δυναμικά αναπτυσσόμενες ερευνητικές περιοχές στο πεδίο της αυτόνομης ρομποτικής και των πολυπρακτορικών συστημάτων. Η θεμελιώδης ιδέα πίσω από τη λογική του σμήνους προέρχεται από την παρατήρηση της φύσης, όπου απλά όντα, όπως πουλιά, ψάρια και έντομα, επιδεικνύουν εξαιρετικά περίπλοκη συλλογική συμπεριφορά μέσω τοπικών αλληλεπιδράσεων, χωρίς κεντρικό έλεγχο ή καθολική γνώση του περιβάλλοντος [7, 15]. Στα συστήματα UAV, η μεταφορά αυτής της αρχής οδηγεί σε σμήνη αυτόνομων οχημάτων ικανά να εκτελούν σύνθετες αποστολές με εγγενή ανθεκτικότητα, επεκτασιμότητα και αποτελεσματικότητα [5].

Σε σύγκριση με μεμονωμένους πράκτορες, τα πολυπρακτορικά συστήματα παρουσιάζουν σημαντικά πλεονεκτήματα, μεταξύ των οποίων ισχυρή προσαρμοστικότητα και ανοχή σε βλάβες (fault tolerance) [5]. Μέσω της διαίρεσης εργασίας και της συνεργασίας, κάθε μέλος του σμήνους μπορεί να αντιλαμβάνεται το περιβάλλον και να αποκτά πληροφορίες για την περιοχή αποστολής γρηγορότερα και με μεγαλύτερη ακρίβεια, επιταχύνοντας την ολοκλήρωση της αποστολής και βελτιώνοντας την αποδοτικότητα της ομάδας [5].

3.4.1 Αρχές Σμηνιαίας Συμπεριφοράς

Το θεμέλιο της μοντελοποίησης της σμηνιαίας συμπεριφοράς τέθηκε από τον Reynolds (1987) [7], ο οποίος πρότεινε ένα υπολογιστικό μοντέλο για την προσομοίωση της συλλογικής κίνησης ιπτάμενων πλασμάτων ("boids"). Το μοντέλο αυτό, παρά την απλότητα του, αναπαράγει με ακρίβεια τη φυσική συμπεριφορά σμηνών, αποδεικνύοντας ότι πολύπλοκη συλλογική δυναμική μπορεί να αναδυθεί από ελάχιστους τοπικούς κανόνες αλληλεπίδρασης, χωρίς κεντρικό έλεγχο ή καθολική γνώση του περιβάλλοντος [7].



Σχήμα 3.5: Προσομοίωση συλλογικής κίνησης boids βάσει του μοντέλου Reynolds. Αναπαγωγή από [7].


Η κεντρική παρατήρηση του Reynolds είναι ότι η συλλογική κίνηση που αναγνωρίζουμε ως "flocking" εξαρτάται από μια περιορισμένη, τοπική αντίληψη του κόσμου [7]. Κάθε boid αντιλαμβάνεται μόνο τους γείτονες του εντός μιας σφαιρικής ζώνης ευαισθησίας (neighborhood), η οποία ορίζεται από μια ακτίνα και έναν εκθέτη και ενεργεί αποκλειστικά βάσει αυτών των τοπικών πληροφοριών [7]. Αυτή η αρχή αποκεντρωμένης αντίληψης και δράσης αποτελεί τον πυρήνα των σύγχρονων συστημάτων σμήνους UAV, όπου κάθε πράκτορας λαμβάνει αποφάσεις βασισμένες αποκλειστικά σε τοπικές παρατηρήσεις, χωρίς πρόσβαση σε κεντρική πληροφορία [15].

3.4.2 Συνοχή, Διαχωρισμός και Ευθυγράμμιση

Το μοντέλο Reynolds ορίζει τρεις θεμελιώδεις κανόνες συμπεριφοράς, οι οποίοι εφαρμόζονται τοπικά από κάθε μέλος του σμήνους [7]:

- **Αποφυγή Σύγκρουσης (Collision Avoidance / Separation):** Κάθε μέλος του σμήνους κινείται ώστε να αποφύγει την υπερβολική προσέγγιση με γειτονικά μέλη. Διατηρείται μια ελάχιστη απόσταση ασφαλείας εντός της οποίας ενεργοποιείται απωθητική τάση που εμποδίζει συγκρούσεις εντός του σμήνους [7].
- **Ευθυγράμμιση Ταχύτητας (Velocity Matching / Alignment):** Κάθε μέλος του σμήνους ευθυγραμμίζει τον προσανατολισμό και την ταχύτητα κίνησης του με τον μέσο όρο των γειτονικών μελών, επιτυγχάνοντας ομοιόμορφη και συντονισμένη κίνηση [7]. Αποτέλεσμα αυτής της αρχής είναι το σμήνος να κινείται προς κοινή κατεύθυνση με ομοιόμορφη ταχύτητα, δημιουργώντας την εικόνα ενός συντονισμένου συνόλου [7].

- **Συνοχή (Flock Centering / Cohesion):** Κάθε μέλος του σμήνους κινείται προς το κέντρο μάζας των γειτονικών μελών, διατηρώντας τη συνοχή του σμήνους ως ενιαία οντότητα [7]. Ο κανόνας αυτός εξασφαλίζει ότι τα μέλη δεν διασκορπίζονται στο περιβάλλον, αλλά παραμένουν ενωμένα ως λειτουργική ομάδα [7].



Σχήμα 3.6: Οι τρεις θεμελιώδεις κανόνες σμηνιαίας συμπεριφοράς κατά Reynolds: διαχωρισμός, ευθυγράμμιση και συνοχή [7].

Η ισορροπία μεταξύ αυτών των τριών αρχών καθορίζει τη συμπεριφορά του σμήνους. Η υπεροχή της συνοχής οδηγεί σε συμπαγή σχηματισμό, η υπεροχή του διαχωρισμού διασκορπίζει τα μέλη, ενώ η ευθυγράμμιση εξασφαλίζει συντονισμένη κατεύθυνση [15]. Ο κάθε κανόνας παράγει μια πρόταση επιτάχυνσης, και η τελική κίνηση του κάθε boid ορίζεται από ένα σύστημα ιεράρχησης αυτών των προτάσεων, εξασφαλίζοντας ότι σε κατάσταση ανάγκης ο διαχωρισμός υπερισχύει της συνοχής [7].

Τα τρία αυτά συμπεριφορικά πρότυπα αποτελούν τον εννοιολογικό πυρήνα της συνάρτησης διαμόρφωσης ανταμοιβής που αναπτύχθηκε στην παρούσα εργασία. Η μαθηματική τους διατύπωση ως συνιστώσες ανταμοιβής του πράκτορα DRL παρουσιάζεται αναλυτικά στην Ενότητα 4.5, όπου περιγράφεται η υλοποίηση του *SwarmRewardShaper*.

3.5 Βιβλιογραφική Ανασκόπηση Εφαρμογών DRL σε Σμήνη UAV

Η εφαρμογή της Βαθιάς Ενισχυτικής Μάθησης σε συστήματα αυτόνομης πλοήγησης UxV έχει γνωρίσει ταχεία ανάπτυξη την τελευταία δεκαετία. Πρώιμες εφαρμογές DRL σε UAV επικεντρώθηκαν κυρίως στην αποφυγή εμποδίων και στη βελτιστοποίηση τροχιάς υπό ενεργειακούς ή επικοινωνιακούς περιορισμούς, ενώ πιο πρόσφατες μελέτες έχουν υιοθετήσει DRL για την αντιμετώπιση δυναμικών προκλήσεων, συμπεριλαμβανομένων κινούμενων εμποδίων και περιβάλλοντων με αβεβαιότητα [1]. Παρόλα αυτά, οι περισσότερες υπάρχουσες μελέτες δίνουν προτεραιότητα είτε στην ασφάλεια είτε στην ενεργειακή απόδοση, σπάνια αντιμετωπίζοντας αυτούς τους στόχους από κοινού μέσω πλαισίου βελτιστοποίησης πολλαπλών στόχων [1].

Μονό UAV/UxV - Σχεδιασμός Διαδρομής: Οι Zhou et al. (2019) [3] πρότειναν έναν αλγόριθμο DQN για συνεργατικό σχεδιασμό διαδρομής USV, διατυπώνοντας ξεχωριστά MDP για μονό USV και για σχηματισμούς, με συναρτήσεις ανταμοιβής που αντιμετωπίζουν ταυτόχρονα την αποφυγή σύγκρουσης, το μήκος διαδρομής και τη διατήρηση σχηματισμού. Τα αποτελέσματα κατέδειξαν ότι το DRL μπορεί να υπολογίσει τις συντομότερες διαδρομές που αποφεύγουν συγκρούσεις σε περιβάλλοντα με πυκνά εμπόδια [3].

Υβριδικές Προσεγγίσεις: Οι Li et al. (2023) [22] ανέπτυξαν ένα υβριδικό πλαίσιο που συνδυάζει DQN με Ελεγκτή Πρόβλεψης Νευρωνικού Δικτύου (NN-MPC) για αποφυγή δυναμικών εμποδίων σε USV. Μέσω cross-domain εκπαίδευσης, αρχικά σε χερσαίο περιβάλλον και στη συνέχεια μεταφορά

στο θαλάσσιο, η προσέγγιση πέτυχε μείωση του χρόνου εκπαίδευσης κατά 28% και αύξηση της απόδοσης αποφυγής εμποδίων κατά 70 μονάδες ανταμοιβής σε σύγκριση με αμιγή εκπαίδευση στο θαλάσσιο πεδίο [22]. Παρόμοια, οι Qu et al. συνδύασαν τον αλγόριθμο DWA με Safe RL για τοπικό σχεδιασμό κίνησης USV, βελτιώνοντας σημαντικά την ασφάλεια σε προσομοιωμένα θαλάσσια περιβάλλοντα [11].

Βελτιστοποίηση με πολλαπλά κριτήρια: Οι Bartsiokas et al. (2025) [1] πρότειναν ένα πλαίσιο Fuzzy DQN (F-DQN) για πολυκριτηριακό σχεδιασμό διαδρομής USV, ενσωματώνοντας ανθρώπινη ασαφή συλλογισμό στη συνάρτηση ανταμοιβής DRL. Το F-DQN πέτυχε ομαλότερες τροχιές, χαμηλότερη κατανάλωση καυσίμου και ταχύτερη σύγκλιση σε σχέση με το βασικό DQN, χωρίς συμβιβασμό στο ποσοστό επιτυχίας [1].

Πολυπρακτορικά Συστήματα και Σμήνη: Ένα αυξανόμενο σώμα ερευνητικών εργασιών επικεντρώνεται στη συνεργατική πλοήγηση πολλαπλών πρακτόρων. Οι Nantogma et al. (2023) [5] ανέπτυξαν ένα υβριδικό πλαίσιο MARL που αξιοποιεί ευρετικούς μηχανισμούς για την καθοδήγηση της μάθησης ομαδικής αποστολής πολλαπλών USV, χρησιμοποιώντας ένα μοντέλο επιλογής υποστόχων βασισμένο στο ανοσοποιητικό δίκτυο και βελτιστοποίηση actor-critic. Παρόμοια, multi-USV προσεγγίσεις βασισμένες σε δίκτυα αποσύνθεσης αξίας (value-decomposition) έχουν εφαρμοστεί για κατανομή εργασιών και αποφυγή συγκρούσεων σε αποστολές παρατήρησης ωκεανών [1].

Κοινή Πολιτική (Parameter Sharing): Μια ιδιαίτερα αποτελεσματική προσέγγιση για σμήνη UAV είναι η χρήση κοινής πολιτικής (parameter sharing), όπου ένας μοναδικός πράκτορας DRL εκπαιδεύεται και χρησιμοποιείται από όλα τα μέλη του σμήνους [5]. Αυτή η προσέγγιση μειώνει δραστικά τον υπολογιστικό φόρτο εκπαίδευσης ενώ παράλληλα παρέχει εγγενή επεκτασιμότητα, καθώς δεν απαιτεί επανεκπαίδευση για διαφορετικά μεγέθη σμήνους [6].

Παρά τις σημαντικές προόδους, η υπάρχουσα βιβλιογραφία αναδεικνύει αρκετά ανοικτά ερευνητικά ζητήματα [1, 3]. Πρώτον, οι περισσότερες μελέτες εστιάζουν σε μονοκριτηριακή βελτιστοποίηση, παραμελώντας τις αλληλεξαρτήσεις μεταξύ ασφάλειας, ενεργειακής αποδοτικότητας και ομαλότητας διαδρομής. Δεύτερον, η επεκτασιμότητα σε σμήνη μεγάλου μεγέθους παραμένει αδύνατη, καθώς η πολυπλοκότητα της αλληλεπίδρασης αυξάνεται εκθετικά με τον αριθμό των πρακτόρων [5]. Τρίτον, η έλλειψη ερμηνευσιμότητας (interpretability) των νευρωνικών πολιτικών αποτελεί σημαντικό περιορισμό για κρίσιμες εφαρμογές πραγματικού κόσμου [1]. Η παρούσα εργασία αντιμετωπίζει αυτές τις προκλήσεις αναπτύσσοντας έναν πράκτορα Double DQN με κοινή πολιτική για σμήνη UAV διαφορετικών μεγεθών, με ειδικά σχεδιασμένη συνάρτηση ανταμοιβής που ενσωματώνει τις αρχές συνοχής, διαχωρισμού και ευθυγράμμισης του Reynolds [7].

ΚΕΦΑΛΑΙΟ 4: Σχεδιασμός Συστήματος

4.1 Περιβάλλον Προσομοίωσης

Η αξιολόγηση τεχνικών Βαθιάς Ενισχυτικής Μάθησης σε προβλήματα σχεδιασμού διαδρομής UAV προϋποθέτει την ανάπτυξη ενός ελεγχόμενου περιβάλλοντος προσομοίωσης, στο οποίο ο πράκτορας μπορεί να αλληλεπιδρά με τον κόσμο, να συλλέγει εμπειρίες και να βελτιστοποιεί την πολιτική του χωρίς τους κινδύνους και το κόστος ενός φυσικού συστήματος. Στην παρούσα εργασία, αναπτύχθηκε εξ ολοκλήρου ένα δισδιάστατο περιβάλλον προσομοίωσης σε γλώσσα προγραμματισμού Python, με αποκλειστική χρήση της βιβλιοθήκης NumPy για τους αριθμητικούς υπολογισμούς. Η αρχιτεκτονική του περιβάλλοντος ακολουθεί ιεραρχική δομή. Συγκεκριμένα, μια βασική κλάση `UAVEnvTopology` ορίζει τη γεωμετρία του κόσμου και τη χωροθέτηση των εμποδίων, ενώ οι κλάσεις `UAVEnv` και `SwarmUAVEnv` κληρονομούν από αυτήν και προσθέτουν τη δυναμική του οχήματος και τη λογική αλληλεπίδρασης. Στις ακόλουθες υποενότητες αναλύονται η γεωμετρία του κόσμου και ο μηχανισμός στοχαστικής δημιουργίας εμποδίων.

Ολόκληρη η υλοποίηση που περιγράφεται στο παρόν κεφάλαιο είναι διαθέσιμη στο δημόσιο αποθετήριο <https://github.com/stphliανουελени/Tησεισ>.

4.1.1 Γεωμετρία Κόσμου και Σύνορα

Το περιβάλλον μοντελοποιείται ως ένας δισδιάστατος ευκλείδειος χώρος, του οποίου τα όρια ορίζονται από μια ορθογώνια περιοχή $\mathcal{W} \subset \mathbb{R}^2$. Στην παρούσα υλοποίηση, ο χώρος έχει διαστάσεις $[-50, 50] \times [-50, 50]$ μονάδων μήκους. Τα όρια του κόσμου αντιμετωπίζονται ως φυσικά εμπόδια, η έξοδος του UAV από την περιοχή $\mathcal{W}$ θεωρείται ισοδύναμη με σύγκρουση και οδηγεί σε τερματισμό του επεισοδίου με αρνητική ανταμοιβή.

Εντός του κόσμου ορίζονται δύο σταθερά σημεία ενδιαφέροντος: η αρχική θέση $\mathbf{p}_{\text{start}} = (-40, -40)$ και η θέση στόχου $\mathbf{p}_{\text{goal}} = (40, 40)$. Η επιλογή αυτών των διαμετρικά αντίθετων σημείων εξασφαλίζει ότι το UAV καλείται να διασχίσει τη μέγιστη διαγώνια απόσταση του χώρου, αυξάνοντας έτσι την πιθανότητα συνάντησης με εμπόδια και ενισχύοντας τη δυσκολία του προβλήματος. Η αποστολή θεωρείται επιτυχής όταν η ευκλείδεια απόσταση του πράκτορα από τον στόχο γίνει μικρότερη από την ακτίνα στόχου $r_{\text{goal}} = 3.0$ μονάδες.

Η ντετερμινιστική εκκίνηση οδηγεί σε υπερπροσαρμογή του πράκτορα σε συγκεκριμένες τροχιές [1]. Για την αποφυγή αυτού του φαινομένου, η αρχική θέση και ο προσανατολισμός του UAV διαταράσσονται με προσθετικό θόρυβο Gauss:

$$\mathbf{p}_0 = \mathbf{p}_{\text{start}} + \boldsymbol{\eta}_p, \quad \boldsymbol{\eta}_p \sim \mathcal{N}(\mathbf{0}, \sigma_p^2 \mathbf{I}) \quad (4.1)$$

$$\psi_0 = \psi_{\text{goal}} + \eta_\psi, \quad \eta_\psi \sim \mathcal{N}(0, \sigma_\psi^2) \quad (4.2)$$

όπου $\sigma_p = 2.0$ και $\sigma_\psi = 0.2$ rad, ενώ ο αρχικός προσανατολισμός $\psi_{\text{goal}} = \text{atan2}(p_{\text{goal},y} - p_{0,y}, p_{\text{goal},x} - p_{0,x})$ είναι η κατεύθυνση από την αρχική θέση προς τον στόχο. Αυτή η στοχαστική αρχικοποίηση εμπλουτίζει την κατανομή των αρχικών καταστάσεων και ενισχύει την ικανότητα γενίκευσης του πράκτορα.

4.1.2 Στοχαστική Δημιουργία Εμποδίων (UAVEnvTopology)

Τα εμπόδια στο περιβάλλον μοντελοποιούνται ως κυκλικοί δίσκοι, καθένας από τους οποίους χαρακτηρίζεται από το κέντρο του $\mathbf{c}_i \in \mathbb{R}^2$ και την ακτίνα του $r_i \in [r_{\min}, r_{\max}]$. Στην παρούσα υλοποίηση, οι ακτίνες λαμβάνουν τιμές στο διάστημα $[3.0, 8.0]$ μονάδες, παρέχοντας ποικιλομορφία στο μέγεθος των εμποδίων και αναγκάζοντας τον πράκτορα να αναπτύξει στρατηγικές προσαρμοζόμενες σε διαφορετικές γεωμετρίες.

Η τοποθέτηση των εμποδίων πραγματοποιείται μέσω στοχαστικού αλγορίθμου απόρριψης (rejection sampling). Για κάθε εμπόδιο $i \in \{1, \dots, N\}$, ο αλγόριθμος εκτελεί έως $K_{\max} = 500$ προσπάθειες δειγματοληψίας, σε κάθε μια από τις οποίες παράγει υποψήφιες τιμές κέντρου και ακτίνας από ομοιόμορφες κατανομές:

$$r_i \sim \mathcal{U}(r_{\min}, r_{\max}) \quad (4.3)$$

$$\mathbf{c}_i \sim \mathcal{U}([x_{\min} + r_i, x_{\max} - r_i] \times [y_{\min} + r_i, y_{\max} - r_i]) \quad (4.4)$$

Ο περιορισμός των άκρων στις παραπάνω κατανομές εξασφαλίζει ότι κανένα τμήμα του εμποδίου δεν βγαίνει εκτός των ορίων του κόσμου. Στη συνέχεια, κάθε υποψήφιο εμπόδιο ελέγχεται έναντι δύο γεωμετρικών περιορισμών.

Πρώτον, ισχύει ο περιορισμός διαχωρισμού μεταξύ εμποδίων, στον οποίο για κάθε ήδη τοποθετημένο εμπόδιο j , πρέπει να ικανοποιείται η ανισότητα

$$\|\mathbf{c}_i - \mathbf{c}_j\| \geq r_i + r_j + d_{\text{clear}} \quad (4.5)$$

όπου $d_{\text{clear}} = 1.0$ μονάδα είναι η ελάχιστη απόσταση εκκαθάρισης μεταξύ δύο εμποδίων. Ο περιορισμός αυτός εξασφαλίζει ότι μεταξύ οποιουδήποτε ζεύγους εμποδίων υπάρχει διάδρομος ικανός για διέλευση του UAV.

Δεύτερον, ισχύει ο περιορισμός εκκαθάρισης αρχής-στόχου, στον οποίο το κέντρο του υποψήφιου εμποδίου πρέπει να απέχει επαρκώς τόσο από την αρχική θέση όσο και από τη θέση στόχου:

$$\|\mathbf{c}_i - \mathbf{p}_{\text{start}}\| \geq r_i + d_{\text{sg}} \quad (4.6)$$


$$\|\mathbf{c}_i - \mathbf{p}_{\text{goal}}\| \geq r_i + d_{\text{sg}} \quad (4.7)$$

όπου $d_{\text{sg}} = 6.0$ μονάδες είναι η απαιτούμενη απόσταση εκκαθάρισης. Ο περιορισμός αυτός εγγυάται ότι ούτε η αρχική θέση ούτε ο στόχος καλύπτονται από εμπόδιο, αποτρέποντας τη δημιουργία αδύνατων προς επίλυση επεισοδίων.

Εάν ένα υποψήφιο εμπόδιο ικανοποιεί και τους δύο περιορισμούς, προστίθεται στη συλλογή και ο αλγόριθμος προχωρά στο επόμενο. Αν μετά από $K_{\max}$ προσπάθειες δεν έχει βρεθεί έγκυρη θέση ο αλγόριθμος τερματίζει με σφάλμα, υποδηλώνοντας ότι ο χώρος δεν επιδέχεται την επιθυμητή πυκνότητα εμποδίων. Στην πράξη, για τις τιμές παραμέτρων που χρησιμοποιήθηκαν στα πειράματα, ο μηχανισμός καταφέρνει σχεδόν πάντα να τοποθετήσει επιτυχώς έως και δέκα εμπόδια.

Η αναπαραγωγικότητα των πειραμάτων εξασφαλίζεται μέσω της δυνατότητας προσδιορισμού μιας αρχικής τιμής (seed) στη γεννήτρια ψευδοτυχαίων αριθμών. Όταν παρέχεται συγκεκριμένη αρχική τιμή, η γεωμετρία του περιβάλλοντος είναι πλήρως αναπαραγώγιμη, γεγονός κρίσιμο για τη συγκριτική αξιολόγηση διαφορετικών στρατηγικών εκπαίδευσης. Αντίθετα, η απουσία της αρχικής τιμής επιτρέπει τη δειγματοληψία τυχαίων τοπολογιών, υποστηρίζοντας στρατηγικές όπως το Curriculum Learning που

παρουσιάζεται στο Κεφάλαιο 5.



Σχήμα 4.1: Παράδειγμα στοχαστικά παραγόμενης τοπολογίας του περιβάλλοντος προσομοίωσης με έξι εμπόδια. Η αρχική θέση $\mathbf{p}_{\text{start}} = (-40, -40)$ παρουσιάζεται με πράσινο κύκλο και η θέση στόχου $\mathbf{p}_{\text{goal}} = (40, 40)$ με κόκκινο αστέρι. Ο κόκκινος διακεκομμένος κύκλος γύρω από τον στόχο δείχνει την ακτίνα επιτυχίας $r_{\text{goal}} = 3.0$. Τα εμπόδια αναπαριστούνται ως γκρι δίσκοι μεταβλητής ακτίνας. Η συγκεκριμένη τοπολογία παρήχθη με σταθερά $\text{seed} = 42$ και είναι αναπαραγώγιμη.

4.2 Περιβάλλον Single UAV (UAVEnv)

Η κλάση `UAVEnv` κληρονομεί από την `UAVEnvTopology` και επεκτείνει τη στατική γεωμετρία του κόσμου με τη δυναμική ενός μεμονωμένου UAV. Στις ακόλουθες υποενότητες παρουσιάζονται διαδοχικά ο χώρος καταστάσεων, ο χώρος ενεργειών, το σύστημα αντίληψης μέσω αισθητήρων εμβέλειας, η συνάρτηση ανταμοιβής, καθώς και οι συνθήκες σύγκρουσης και τερματισμού.

4.2.1 Χώρος Καταστάσεων και Παρατηρήσεων

Η εσωτερική κατάσταση του UAV περιγράφεται από το ζεύγος θέσης $\mathbf{p}_t = (x_t, y_t) \in \mathbb{R}^2$ και προσανατολισμού $\psi_t \in [-\pi, \pi]$, ο οποίος μετράται από τον θετικό άξονα x . Η εξέλιξη της κατάστασης ακολουθεί ντετερμινιστική κινηματική με σταθερή ταχύτητα και διακριτό χρονικό βήμα Δt . Δεδομένης μιας γωνίας στροφής $\Delta\psi_t$ που επιλέγει ο πράκτορας, η κατάσταση ενημερώνεται σύμφωνα με τις σχέσεις:

$$\psi_{t+1} = \text{wrap}_{\pi}(\psi_t + \Delta\psi_t) \quad (4.8)$$

$$\mathbf{p}_{t+1} = \mathbf{p}_t + v \cdot \Delta t \cdot (\cos \psi_{t+1}, \sin \psi_{t+1}) \quad (4.9)$$

όπου $v = 3.0$ μονάδες/δευτερόλεπτο είναι η σταθερή ταχύτητα κίνησης, $\Delta t = 0.5$ δευτερόλεπτα το χρονικό βήμα και $\text{wrap}_\pi(\cdot)$ ο τελεστής περιορισμού γωνίας στο διάστημα $[-\pi, \pi]$. Η σταθερή ταχύτητα χρησιμοποιείται για απλοποίηση, η οποία επιτρέπει στον πράκτορα να εστιάσει αποκλειστικά στον έλεγχο κατεύθυνσης χωρίς να επιβαρύνεται με ταυτόχρονη βελτιστοποίηση επιτάχυνσης.

Σε αντίθεση με την εσωτερική κατάσταση, ο πράκτορας δεν έχει πρόσβαση σε καθολική πληροφορία για τη γεωμετρία του κόσμου. Αντί αυτής, λαμβάνει σε κάθε χρονικό βήμα ένα διάνυσμα παρατήρησης $\mathbf{o}_t \in \mathbb{R}^9$ που συγκεντρώνει τοπική εγωκεντρική πληροφορία:

$$\mathbf{o}_t = (x_t, y_t, \psi_t, d_t^{\text{goal}}, \rho_t^{(1)}, \rho_t^{(2)}, \rho_t^{(3)}, \rho_t^{(4)}, \rho_t^{(5)}) \quad (4.10)$$

όπου $d_t^{\text{goal}} = \|\mathbf{p}_{\text{goal}} - \mathbf{p}_t\|$ είναι η ευκλείδεια απόσταση από τον στόχο, και $\rho_t^{(k)}$ είναι οι μετρήσεις εμβέλειας των πέντε αισθητήρων που αναλύονται στην Ενότητα 4.2.3. Αξίζει επίσης να σημειωθεί ότι η παρατήρηση δεν περιλαμβάνει ρητή πληροφορία για τη θέση των εμποδίων. Ο πράκτορας πρέπει να συμπεράνει την παρουσία και τη γεωμετρία τους αποκλειστικά μέσω των μετρήσεων εμβέλειας. Η σχεδιαστική αυτή επιλογή προσομοιώνει ρεαλιστικά τους περιορισμούς αντίληψης ενός πραγματικού UAV εξοπλισμένου με αισθητήρες LIDAR [22], το οποίο δεν έχει πρόσβαση σε καθολικό χάρτη του περιβάλλοντος αλλά μόνο σε τοπικές μετρήσεις απόστασης.

Πριν την τροφοδότησή του στο νευρωνικό δίκτυο, το διάνυσμα παρατήρησης κανονικοποιείται ανά συνιστώσα, ώστε όλες οι εισοδοί να βρίσκονται περίπου στο ίδιο εύρος τιμών και να αποφεύγεται η κυριαρχία συνιστωσών μεγάλης κλίμακας (όπως η απόσταση) έναντι εκείνων μικρότερης κλίμακας. Συγκεκριμένα, οι συντεταγμένες θέσης διαιρούνται με το ήμισυ του εύρους του κόσμου ($x_t, y_t \mapsto x_t/50, y_t/50$), ο προσανατολισμός ψ_t με π , η απόσταση από τον στόχο d_t^{goal} με τη μέγιστη δυνατή απόσταση εντός του κόσμου $d_{\text{max}} = 2 \cdot 50\sqrt{2} \approx 141.4$ μονάδες και οι μετρήσεις εμβέλειας $\rho_t^{(k)}$ με τη μέγιστη εμβέλεια $\rho_{\text{max}} = 30$. Η επιλογή αυτή είναι συνεπής με την αρχικοποίηση $\mathbf{He}$ των βαρών, η οποία προϋποθέτει εισόδους παρόμοιες κλίμακας για τη διατήρηση σταθερής διασποράς των ενεργοποιήσεων κατά μήκος των στρωμάτων.

4.2.2 Χώρος Ενεργειών - Γωνίες Στροφής

Ο χώρος ενεργειών είναι διακριτός και αποτελείται από πέντε επιλογές που αντιστοιχούν σε διαφορετικές γωνίες στροφής:

$$\mathcal{A} = \{-30^\circ, -15^\circ, 0^\circ, +15^\circ, +30^\circ\} \quad (4.11)$$

Η συμμετρική κατανομή των γωνιών γύρω από το μηδέν επιτρέπει στον πράκτορα να εκτελεί στροφές αριστερά-δεξιά με ίσες δυνατότητες, ενώ η παρουσία της μηδενικής γωνίας (0°) δίνει τη δυνατότητα ευθείας πορείας. Η επιλογή δύο διαφορετικών μεγεθών στροφής ($\pm 15^\circ$ και $\pm 30^\circ$) προσδίδει στον πράκτορα ευελιξία και επιλέγει μεταξύ ήπιων διορθώσεων πορείας, δηλαδή ιδανικών για ομαλή πλοήγηση σε ανοιχτό χώρο, και έντονων στροφών, απαραίτητων για την αποφυγή εμποδίων υψηλής γειτνίασης.

Ο διακριτός χώρος ενεργειών συμβαδίζει με τις απαιτήσεις του αλγορίθμου DQN, ο οποίος παράγει εκτίμηση τιμής $Q(s, a)$ για κάθε διακριτή ενέργεια. Η αθέρατη αναπαράσταση της ενέργειας $a_t \in \{0, 1, 2, 3, 4\}$ αντιστοιχίζεται μέσω πίνακα στις παραπάνω γωνίες στροφής, με την αντιστοίχιση να γίνεται κατά την εκτέλεση του βήματος.

4.2.3 Αισθητήρες Εμβέλειας (Range Sensors)

Η αντίληψη του περιβάλλοντος από τον UAV επιτυγχάνεται μέσω πέντε εικονικών αισθητήρων εμβέλειας, εμπνευσμένων από τη λειτουργία συστημάτων LIDAR. Οι αισθητήρες είναι τοποθετημένοι σε σχετικές γωνίες ως προς τον προσανατολισμό του UAV:

$$\theta_{\text{sensor}} = \{-60^\circ, -30^\circ, 0^\circ, +30^\circ, +60^\circ\} \quad (4.12)$$


καλύπτοντας ένα μετωπιαίο τόξο εύρους 120° . Η συμμετρική διάταξη εξασφαλίζει ισορροπημένη αντίληψη αριστερά-δεξιά, ενώ η κάλυψη μόνο του μπροστινού ημικυκλίου είναι συνεπής με την κινηματική του σχήματος, το οποίο κινείται αποκλειστικά προς τα εμπρός.

Για κάθε αισθητήρα k , εκτελείται αλγόριθμος ευθύγραμμης ιχνηλάτησης ακτίνας (ray casting) κατά μήκος της κατεύθυνσης $\psi_t + \theta_k$. Η ακτίνα εξετάζεται διακριτά ανά $\Delta s = 0.5$ μονάδες μήκους, μέχρι είτε να βρεθεί τομή με εμπόδιο ή με το όριο του κόσμου, είτε να φτάσει στη μέγιστη εμβέλεια $\rho_{\max} = 30.0$ μονάδες:

$$\rho_t^{(k)} = \min \left\{ d \in [0, \rho_{\max}] : \mathbf{p}_t + d \cdot \hat{\mathbf{u}}_k \in \mathcal{O} \cup \partial\mathcal{W} \right\} \cup \{\rho_{\max}\} \quad (4.13)$$

όπου $\hat{\mathbf{u}}_k = (\cos(\psi_t + \theta_k), \sin(\psi_t + \theta_k))$ είναι το μοναδιαίο διάνυσμα στην κατεύθυνση του αισθητήρα, $\mathcal{O}$ η ένωση των εμποδίων και $\partial\mathcal{W}$ τα σύνορα του κόσμου. Όταν δεν εντοπίζεται τομή εντός της εμβέλειας, ο αισθητήρας επιστρέφει την τιμή $\rho_{\max}$.

Η ανάλυση $\Delta s = 0.5$ επιλέχθηκε ως συμβιβασμός μεταξύ ακρίβειας μέτρησης και υπολογιστικού κόστους. Αναλυτικότερα, μικρότερα βήματα θα βελτίωναν την ακρίβεια αλλά ο χρόνος προσομοίωσης ενός επεισοδίου θα αυξανόταν δραστηκώς.



Σχήμα 4.2: Διάταξη των πέντε αισθητήρων εμβέλειας του UAV. Οι αισθητήρες εκπέμπουν ακτίνες σε σχετικές γωνίες ως προς τον τρέχοντα προσανατολισμό ψ_t , καλύπτοντας μετωπιαίο τόξο 120° . Όταν μια ακτίνα συναντά εμπόδιο, ο αντίστοιχος αισθητήρας επιστρέφει την απόσταση έως το σημείο τομής, αλλιώς επιστρέφει τη μέγιστη εμβέλεια $\rho_{\max}$.

4.2.4 Συνάρτηση Ανταμοιβής

Η συνάρτηση ανταμοιβής του UAVEnv ακολουθεί τη φιλοσοφία της διαμόρφωσης ανταμοιβής που παρουσιάστηκε στην Ενότητα 2.5, συνδυάζοντας αραιές ανταμοιβές τερματισμού με πυκνά σήματα διαμόρφωσης. Διακρίνονται τρεις περιπτώσεις, σύγκρουση, επίτευξη στόχου και ενδιάμεσο βήμα.

Σύγκρουση. Σε περίπτωση σύγκρουσης με εμπόδιο ή έξοδο εκτός των ορίων του κόσμου, επιβάλλεται σταθερή αρνητική ανταμοιβή:

$$r_{\text{collision}} = -300.0 \quad (4.14)$$

Το μέγεθος της ποινής επιλέχθηκε ώστε να είναι κατά τάξεις μεγέθους μεγαλύτερο [3] από τις τυπικές ανταμοιβές ενός μη τερματικού βήματος, ώστε ο πράκτορας να μάθει με σαφήνεια ότι η σύγκρουση αποτελεί κατάσταση προς αποφυγή με κάθε κόστος.

Επίτευξη Στόχου. Όταν η απόσταση από τον στόχο γίνει μικρότερη από την ακτίνα στόχου $r_{\text{goal}} = 3.0$ μονάδες, ο πράκτορας λαμβάνει μεγάλη θετική ανταμοιβή:

$$r_{\text{goal}} = 1200.0 - 50.0 \cdot |\varepsilon_{\psi}| \quad (4.15)$$

όπου $\varepsilon_{\psi} = \text{wrap}_{\pi}(\psi_t - \psi_t^{\text{goal}})$ είναι το σφάλμα προσανατολισμού κατά τη στιγμή της άφιξης. Ο όρος $-50.0 \cdot |\varepsilon_{\psi}|$ ενθαρρύνει τον πράκτορα να φτάσει στον στόχο με προσανατολισμό ευθυγραμμισμένο προς αυτόν, στοιχείο σημαντικό για σενάρια όπου ο στόχος αντιπροσωπεύει σημείο προσγείωσης ή σύνδεσης με επόμενο σημείο διαδρομής. Η αρχική σταθερά 1200.0 εξασφαλίζει ότι ακόμη και στη χειρότερη περίπτωση ($\varepsilon_{\psi} = \pi$) η συνολική ανταμοιβή στόχου παραμένει σαφώς θετική (περίπου 1043).

Ενδιάμεσο Βήμα. Σε κάθε μη τερματικό βήμα η ανταμοιβή υπολογίζεται ως σταθμισμένο άθροισμα τεσσάρων συνιστωσών:

$$r_t = w_1 \cdot \Delta d_t - w_2 \cdot |\varepsilon_{\psi,t}| - w_3 \cdot e_t - w_4 \quad (4.16)$$

με τους όρους και τα βάρη να ορίζονται ως εξής:

- $\Delta d_t = d_{t-1}^{\text{goal}} - d_t^{\text{goal}}$ είναι η πρόοδος προς τον στόχο, με βάρος $w_1 = 10.0$. Θετικές τιμές υποδηλώνουν μείωση της απόστασης και ανταμείβονται.
- $|\varepsilon_{\psi,t}|$ είναι το απόλυτο σφάλμα προσανατολισμού ως προς τον στόχο, με βάρος $w_2 = 5.0$. Η ποινή ενθαρρύνει τον πράκτορα να διατηρεί ομαλή τροχιά κατευθυνόμενη προς τον στόχο.
- $e_t = |\Delta\psi_t| / \max |\Delta\psi|$ είναι ο κανονικοποιημένος δείκτης ενέργειας, με βάρος $w_3 = 1.0$. Έντονες στροφές ($\pm 30^\circ$) επιφέρουν τη μέγιστη ποινή 1.0, ενώ ευθεία πορεία (0°) μηδενική ποινή, ενθαρρύνοντας έτσι ομαλές τροχιές.
- Ο σταθερός όρος $w_4 = 0.5$ αποτελεί ποινή χρονικού βήματος και πιέζει τον πράκτορα να φτάσει στον στόχο σε όσο το δυνατόν λιγότερα βήματα.

Η ιεράρχηση των βαρών ακολουθεί τη φιλοσοφία που αναπτύχθηκε στην Ενότητα 2.5, $|r_{\text{collision}}| \gg w_1 > w_2 > w_3 > w_4$. Με αυτή τη διάταξη, ο πράκτορας μαθαίνει ιεραρχημένα. Αρχικά, μαθαίνει να αποφεύγει συγκρούσεις. Στη συνέχεια να προοδεύει προς τον στόχο και τέλος να βελτιστοποιεί την ομαλότητα και το μήκος της διαδρομής.

4.2.5 Ανίχνευση Σύγκρουσης και Τερματισμός

Η ανίχνευση σύγκρουσης πραγματοποιείται σε κάθε χρονικό βήμα μετά την ενημέρωση της θέσης. Συγκεκριμένα, ελέγχεται αν η νέα θέση του UAV ικανοποιεί οποιαδήποτε από τις ακόλουθες συνθήκες:

1. **Σύγκρουση με εμπόδιο:** Υπάρχει εμπόδιο i τέτοιο ώστε $\|\mathbf{p}_{t+1} - \mathbf{c}_i\| \leq r_i + \delta$, όπου $\delta = 0.5$ είναι ένας μικρός συντελεστής ασφαλείας που αντιπροσωπεύει ένα αποτελεσματικό σώμα του UAV.
2. **Έξοδος από τον κόσμο:** Η νέα θέση $\mathbf{p}_{t+1}$ βρίσκεται εκτός της περιοχής $\mathcal{W}$

Σε οποιαδήποτε από τις δύο περιπτώσεις, το επεισόδιο τερματίζεται με την ποινή $r_{\text{collision}}$ και ο μηχανισμός επιστρέφει στο εκπαιδευτικό βρόχο μια ένδειξη αποτυχίας (**reason: collision**).

Το επεισόδιο τερματίζει επίσης επιτυχώς όταν η απόσταση από τον στόχο πέφτει κάτω από την ακτίνα στόχου (**reason: goal_reached**). Τέλος, για την αποφυγή επεισοδίων στα οποία ο πράκτορας περιπλανάται χωρίς να συγκρούεται αλλά και χωρίς να επιτυγχάνει τον στόχο, ορίζεται ένα μέγιστο όριο βημάτων $T_{\text{max}} = 400$. Αν συμπληρωθούν τα T_{max} βήματα χωρίς τερματισμό το επεισόδιο λήγει χωρίς πρόσθετη ανταμοιβή ή ποινή πέραν εκείνης που έχει ήδη συσσωρευτεί. Επίσης, η τιμή $T_{\text{max}} = 400$ επιλέχθηκε έτσι ώστε να είναι πολλαπλάσιο του ελάχιστου αριθμού βημάτων που απαιτούνται για ευθεία διέλευση από την αρχή στον στόχο, επιτρέποντας έτσι στον πράκτορα να εκτελέσει σύνθετες παρακάμψεις χωρίς τον κίνδυνο πρόωρου τερματισμού.

4.3 Περιβάλλον Σμήνους (SwarmUAVEnv)

Η κλάση **SwarmUAVEnv** αποτελεί την επέκταση της **UAVEnvTopology** για τη διαχείριση πολλαπλών πρακτόρων που λειτουργούν παράλληλα σε κοινό περιβάλλον. Ενώ ο μηχανισμός γέννησης εμποδίων και η γεωμετρία του κόσμου παραμένουν αμετάβλητοι, η αναπαράσταση των οχημάτων μετατρέπεται από βαθμωτή σε διανυσματική και προστίθενται μηχανισμοί ανίχνευσης αλληλεπιδράσεων μεταξύ των μελών του σμήνους. Στις ακόλουθες υποενότητες αναλύονται οι διαφορές από το περιβάλλον μονού πράκτορα, η δομή του χώρου παρατηρήσεων και ο τρόπος τερματισμού.

4.3.1 Επέκταση από Μονό σε Πολλαπλά UAV

Στο περιβάλλον σμήνους, η κατάσταση του συστήματος περιγράφεται από έναν πίνακα θέσεων $\mathbf{P} \in \mathbb{R}^{N \times 2}$ και ένα διάνυσμα προσανατολισμών $\psi \in \mathbb{R}^N$, όπου N είναι ο αριθμός των πρακτόρων. Στην μελέτη αυτή εξετάστηκαν σμήνη με $n \in \{2, 3, \dots, 10\}$, με προεπιλεγμένη τιμή $N = 5$ για το βασικό σενάριο εκπαίδευσης. Επίσης, όλοι οι πράκτορες μοιράζονται κοινή πολιτική (parameter sharing), η οποία μειώνει δραστικά τον αριθμό εκπαιδευσίμων παραμέτρων και επιτρέπει στο σύστημα να γενικεύει σε μεταβλητά μεγέθη σμήνους χωρίς επανεκπαίδευση.

Οι κινηματικές παράμετροι του σμήνους διατηρούνται ταυτόσημες με αυτές του μονού περιβάλλοντος: ταχύτητα $v = 3.0$ μονάδες/δευτερόλεπτο και χρονικό βήμα $\Delta t = 0.5$ δευτερόλεπτα. Η ακτίνα στόχου παραμένει επίσης $r_{\text{goal}} = 3.0$ μονάδες, που αποδείχθηκε επαρκής για ταυτόχρονη σύγκλιση πολλαπλών πρακτόρων στην ίδια περιοχή χωρίς αμοιβαία παρεμπόδιση.

Κάθε πράκτορας έχει αποτελεσματικό σώμα με ακτίνα $r_{\text{body}} = 0.5$ μονάδες και απαιτείται να διατηρεί ελάχιστη απόσταση ασφαλείας $d_{\text{sep}} = 2.0$ μονάδες από κάθε άλλο μέλος του σμήνους. Δύο πράκτορες

i, j θεωρούνται ότι συγκρούονται όταν:

$$\|\mathbf{p}_i - \mathbf{p}_j\| \leq 2r_{\text{body}} + d_{\text{sep}} \quad (4.17)$$

Ο έλεγχος αυτός εκτελείται σε κάθε χρονικό βήμα και οδηγεί στον τερματισμό και των δύο εμπλεκόμενων πρακτόρων με ποινή $r_{\text{inter}} = -250.0$, μικρότερη σε απόλυτη τιμή από την ποινή σύγκρουσης με στατικό εμπόδιο (-300.0).

Η εκκίνηση κάθε επεισοδίου ακολουθεί μηχανισμό στοχαστικής γέννησης πρακτόρων κοντά στην αρχική θέση. Για κάθε νέο πράκτορα, γίνεται δειγματοληψία από κατανομή $\mathcal{N}(\mathbf{p}_{\text{start}}, \sigma_{\text{spawn}}^2 \mathbf{I})$ με $\sigma_{\text{spawn}} = 3.0$, και γίνεται αποδεκτή μόνο εφόσον δεν συγκρούεται με εμπόδια, με τα όρια του κόσμου, ή με ήδη τοποθετημένους πράκτορες. Σε ακραίες περιπτώσεις όπου ο μηχανισμός αποτυγχάνει μετά από 5000 προσπάθειες και η εκκίνηση του επεισοδίου εγκαταλείπεται.

Η κίνηση κάθε πράκτορα μέσα στο βήμα εκτελείται με τμηματική ολοκλήρωση. Η ολική μετατόπιση $\Delta \mathbf{x} = v \cdot \Delta t \cdot (\cos \psi, \sin \psi)$ διασπάται σε δέκα διαδοχικά υποβήματα και η ανίχνευση σύγκρουσης πραγματοποιείται μετά από κάθε υποβήμα. Παρότι η μετατόπιση ανά βήμα είναι μικρή ($v \cdot \Delta t = 1.5$ μονάδες), η τμηματική ολοκλήρωση εξασφαλίζει αυξημένη ακρίβεια ανίχνευσης σύγκρουσης, ιδίως σε γεωμετρικά στενά περάσματα μεταξύ εμποδίων.

4.3.2 Χώρος Παρατηρήσεων Σμήνους

Στο σμήνος, κάθε πράκτορας λαμβάνει μια εμπλουτισμένη παρατήρηση που συνδυάζει την ατομική του πληροφορία με σχετικές θέσεις των υπόλοιπων μελών. Η διάσταση της παρατήρησης εξαρτάται από το μέγεθος του σμήνους και δίνεται από τη σχέση

$$\dim(\mathbf{o}_i) = 9 + 2(N - 1) \quad (4.18)$$

Οι πρώτες εννέα συνιστώσες ταυτίζονται με την ατομική παρατήρηση του περιβάλλοντος μονού πράκτορα, τη θέση, τον προσανατολισμό, την απόσταση από τον στόχο και τις πέντε μετρήσεις εμβέλειας:

$$\mathbf{o}_i^{\text{core}} = (x_i, y_i, \psi_i, d_i^{\text{goal}}, \rho_i^{(1)}, \rho_i^{(2)}, \rho_i^{(3)}, \rho_i^{(4)}, \rho_i^{(5)}) \quad (4.19)$$

Σε αυτές προστίθενται $2(N - 1)$ συνιστώσες που περιγράφουν τις σχετικές θέσεις των υπόλοιπων πρακτόρων ως προς το UAV i :

$$\mathbf{o}_i^{\text{rel}} = (\mathbf{p}_j - \mathbf{p}_i)_{j \neq i}, \quad j \in \{1, \dots, N\} \quad (4.20)$$

Κάθε σχετικό διάνυσμα $\mathbf{p}_j - \mathbf{p}_i$ αποκόπτεται στο διάστημα $[-50, 50]$ σε κάθε άξονα, αποτρέποντας ακραίες τιμές που θα αποσταθεροποιούσαν την εκπαίδευση όταν δύο πράκτορες βρίσκονται σε απομακρυσμένα τμήματα του κόσμου. Για το σενάριο αναφοράς με $N = 5$, η συνολική διάσταση της παρατήρησης ανέρχεται σε $9 + 2 \cdot 4 = 17$.

Όπως και στο περιβάλλον μονού πράκτορα, ολόκληρο το διάνυσμα παρατήρησης κανονικοποιείται πριν την είσοδό του στο δίκτυο. Οι εννέα ατομικές συνιστώσες κανονικοποιούνται με τους συντελεστές που περιγράφηκαν στην Ενότητα 4.2.1, ενώ οι $2(N - 1)$ σχετικές θέσεις διαιρούνται με το ήμισυ του εύρους του κόσμου (50 μονάδες).

Επισημαίνεται ότι η παρατήρηση παρέχει σχετικές θέσεις των υπόλοιπων πρακτόρων, αλλά όχι τους προσανατολισμούς ή τις ταχύτητες τους. Αυτό αποτελεί μια συνειδητή σχεδιαστική επιλογή που διατηρεί

την παρατήρηση συμπαγή και επιτρέπει στον πράκτορα να συμπεράνει τη δυναμική των γειτόνων του από διαδοχικά χρονικά βήματα. Η εμβέλεια των αισθητήρων $\rho_{\max} = 30.0$ μονάδες ταυτίζεται με την ακτίνα ανίχνευσης και ορίζει την περιοχή εντός της οποίας ο πράκτορας μπορεί να αντιληφθεί στατικά εμπόδια.

Μια σημαντική επιπλοκή του χώρου παρατηρήσεων είναι ότι η διάσταση του εξαρτάται από το μέγεθος του σμήνους. Για την υποστήριξη της κοινής πολιτικής σε μεταβλητά μεγέθη N , η αρχιτεκτονική του πράκτορα DQN προσαρμόζεται κατά τη φάση αρχικοποίησης ώστε η διάσταση εισόδου του νευρωνικού δικτύου να αντιστοιχεί στο επιλεγμένο N . Η περιγραφή του πράκτορα παρουσιάζεται στην Ενότητα 4.4.

4.3.3 Συνθήκες Τερματισμού Σμήνους

Στο περιβάλλον μονού UAV ο τερματισμός είναι μονοσήμαντος, ενώ στο σμήνος η συνθήκη τερματισμού πρέπει να ορισθεί ανά πράκτορα. Επιπρόσθετα, διατηρείται διάνυσμα δεικτών τερματισμού $\mathbf{d} \in \{0,1\}^N$, όπου $d_i = 1$ υποδηλώνει ότι ο πράκτορας i έχει ολοκληρώσει το επεισόδιο με κάποιο τρόπο. Οι συνθήκες που ενεργοποιούν την κατάσταση τερματισμού για κάθε UAV είναι οι ακόλουθες:

1. **Σύγκρουση με εμπόδιο ή έξοδος εκτός ορίων:** Όπως στο περιβάλλον μονού πράκτορα, με ποινή -300.0 .
2. **Σύγκρουση με άλλο UAV:** Όταν η απόσταση από οποιοδήποτε άλλο ενεργό μέλος του σμήνους πέσει κάτω από το όριο ασφαλείας $2r_{\text{body}} + d_{\text{sep}} = 3.0$ μονάδες, με ποινή -250.0 .
3. **Επίτευξη στόχου:** Όταν η απόσταση από τον στόχο γίνει μικρότερη από την ακτίνα στόχου $r_{\text{goal}} = 3.0$ μονάδες, με ανταμοιβή $1200.0 - 50.0 \cdot |\varepsilon_\psi|$.
4. **Όριο χρόνου:** Όταν συμπληρωθούν $T_{\max} = 400$ βήματα, οποιοσδήποτε πράκτορας δεν έχει ολοκληρώσει με άλλον τρόπο σημαδεύεται ως τερματισμένος χωρίς πρόσθετη ανταμοιβή ή ποινή.

Από τη στιγμή που ο δείκτης d_i γίνει αληθής, ο πράκτορας i αγνοείται σε όλους τους μεταγενέστερους υπολογισμούς εντός του ίδιου επεισοδίου. Δεν ενημερώνεται η θέση του, δεν συμπεριλαμβάνεται στους ελέγχους σύγκρουσης με άλλα μέλη και δεν λαμβάνει επιπλέον ανταμοιβές. Η ενέργεια που υπογορεύει η πολιτική για αυτόν τον πράκτορα συνεχίζει να παράγεται από το νευρωνικό δίκτυο αλλά δεν εφαρμόζεται.

Το επεισόδιο τερματίζεται καθολικά όταν όλοι οι πράκτορες έχουν τερματιστεί, δηλαδή όταν $\bigwedge_{i=1}^N d_i = 1$. Αυτή η ασύγχρονη λογική επιτρέπει σε επιτυχημένους πράκτορες να ολοκληρώσουν την αποστολή τους χωρίς να επιβαρύνονται από τη δυσκολία που μπορεί να αντιμετωπίζουν άλλα μέλη του σμήνους, ενώ ταυτόχρονα διατηρεί τη συγχρονισμένη χρονική εξέλιξη του περιβάλλοντος. Η σχεδιαστική αυτή επιλογή είναι ιδιαίτερα σημαντική για την ανάλυση μετρικών απόδοσης ανά μέγεθος σμήνους, καθώς επιτρέπει τον διαχωρισμό μεταξύ μερικών επιτυχιών και ολικών αποτυχιών.

4.4 Αρχιτεκτονική Πράκτορα DQN (DQNAgent)

Ο πράκτορας DQN που χρησιμοποιήθηκε στην παρούσα εργασία υλοποιήθηκε εξ ολοκλήρου σε NumPy, χωρίς εξάρτηση από εξειδικευμένα πλαίσια βαθιάς μάθησης όπως PyTorch ή TensorFlow. Η σχεδιαστική αυτή επιλογή εξυπηρετεί δύο στόχους. Πρώτον εξασφαλίζει πλήρη διαφάνεια του αλγορίθμου, καθώς κάθε τμήμα του δικτύου, από την αρχικοποίηση των βαρών μέχρι την οπισθοδιάδοση του σφάλματος, υλοποιείται ρητά και είναι ορατό στον ερευνητή. Η υλοποίηση αποτελείται από τρία βασικά

στοιχεία. Συγκεκριμένα, από ένα νευρωνικό δίκτυο τύπου MLP, μια ζώνη επανάληψης εμπειρίας και τη λογική του αλγορίθμου Double DQN.

4.4.1 Νευρωνικό Δίκτυο MLP (_NumpyMLP)

Η κλάση `_NumpyMLP` ενσωματώνει ένα πλήρως συνδεδεμένο νευρωνικό δίκτυο τριών στρωμάτων (Multi-Layer Perceptron, MLP). Η ροή υπολογισμών στο δίκτυο ακολουθεί τη δομή

$$\mathbf{X} \rightarrow \text{fc}_1 \rightarrow \text{ReLU} \rightarrow \text{fc}_2 \rightarrow \text{ReLU} \rightarrow \text{fc}_{\text{out}} \quad (4.21)$$

όπου fc_1 και fc_2 είναι κρυφά στρώματα διάστασης $h = 128$ νευρώνων το καθένα, ενώ fc_{out} είναι το στρώμα εξόδου που παράγει μία τιμή Q ανά διακριτή ενέργεια. Για το περιβάλλον μονού UAV με $\dim(\mathbf{o}_t) = 9$ και $|\mathcal{A}| = 5$, το δίκτυο έχει συνολικά περίπου 18,000 εκπαιδευσιμες παραμέτρους. Για το περιβάλλον σμήνους με $N = 5$ και $\dim(\mathbf{o}_t) = 17$, ο αριθμός παραμέτρων ανέρχεται σε περίπου 19,000.


Ο μετασχηματισμός σε κάθε πλήρως συνδεδεμένο στρώμα ακολουθεί την κλασική σχέση γραμμικού συνδυασμού συνοδευόμενου από συνάρτηση ενεργοποίησης

$$\mathbf{z}^{(l)} = \mathbf{a}^{(l-1)}\mathbf{W}^{(l)} + \mathbf{b}^{(l)}, \quad \mathbf{a}^{(l)} = \text{ReLU}(\mathbf{z}^{(l)}) = \max(0, \mathbf{z}^{(l)}) \quad (4.22)$$

όπου $\mathbf{W}^{(l)}$ και $\mathbf{b}^{(l)}$ είναι ο πίνακας βαρών και το διάνυσμα μεροληψίας του στρώματος l αντίστοιχα. Η συνάρτηση ReLU αποτελεί τυπική επιλογή σε σύγχρονες αρχιτεκτονικές βαθιάς μάθησης λόγω του απλού υπολογισμού της και της δυνατότητας μετριασμού του φαινομένου εξαφανιζόμενης παραγώγου που παρατηρείται σε συναρτήσεις όπως η sigmoid ή η tanh [10]. Σημαντικό είναι ότι το στρώμα εξόδου fc_{out} δεν εφαρμόζει μη γραμμικότητα, καθώς οι τιμές Q μπορούν να λαμβάνουν αυθαίρετες πραγματικές τιμές, θετικές ή αρνητικές.

Η οπισθοδιάδοση σφάλματος (backpropagation) υλοποιείται χειροκίνητα μέσω ρητού υπολογισμού των παραγώγων. Ένα προσωρινό λεξικό (`_cache`) αποθηκεύει τις ενδιάμεσες ενεργοποιήσεις $\mathbf{z}^{(1)}, \mathbf{a}^{(1)}, \mathbf{z}^{(2)}, \mathbf{a}^{(2)}$ κατά την προς τα εμπρός διάδοση, οι οποίες χρησιμοποιούνται αργότερα στην προς τα πίσω διάδοση για τον υπολογισμό των $\nabla \mathbf{W}^{(l)}$ και $\nabla \mathbf{b}^{(l)}$.

Η επιλογή κρυφής διάστασης $h = 128$ νευρώνων ανά στρώμα ακολουθεί τυπικές πρακτικές σε υλοποιήσεις DQN για συνεχείς χώρους καταστάσεων χαμηλής έως μεσαίας διάστασης [9, 12]. Η αρχιτεκτονική τριών στρωμάτων διατηρεί επαρκή εκφραστικότητα για το τρέχον πρόβλημα ενώ παραμένει υπολογιστικά αποδοτική για εκπαίδευση σε NumPy χωρίς επιτάχυνση GPU.



Σχήμα 4.3: Αρχιτεκτονική του νευρωνικού δικτύου MLP του πράκτορα DQN. Το δίκτυο αποτελείται από τρία πλήρως συνδεδεμένα στρώματα με δύο ενδιάμεσες ενεργοποιήσεις ReLU. Η διάσταση εισόδου είναι 9 για το περιβάλλον μονού UAV και 17 για το βασικό σενάριο σμήνους ($N = 5$).

4.4.2 Αρχικοποίηση He και Αρχιτεκτονική Στρωμάτων

Η αρχικοποίηση των βαρών του δικτύου γίνεται με την τεχνική He (Kaiming He initialization) [23], η οποία είναι ειδικά σχεδιασμένη για στρώματα με συνάρτηση ενεργοποίησης ReLU. Συγκεκριμένα, για ένα στρώμα με n_{in} εισόδους, τα βάρη λαμβάνονται από δειγματοληψία κανονικής κατανομής με μέση τιμή μηδέν και διασπορά $2/n_{\text{in}}$.

$$\mathbf{W} \sim \mathcal{N}\left(0, \frac{2}{n_{\text{in}}}\right) \quad (4.23)$$

Η επιλογή του συντελεστή 2 στον αριθμητή αντισταθμίζει το γεγονός ότι η ReLU μηδενίζει περίπου τα μισά της εξόδου της, διατηρώντας έτσι σταθερή τη διασπορά των ενεργοποιήσεων κατά μήκος των στρωμάτων [23]. Χωρίς αυτή την προσαρμογή, η διασπορά θα μειωνόταν εκθετικά με το βάθος του δικτύου, με αποτέλεσμα την κατάρρευση των σημάτων στα βαθύτερα στρώματα. Τα διανύσματα μεροληψίας $\mathbf{b}^{(l)}$ αρχικοποιούνται ως μηδενικά.

4.4.3 Αλγόριθμος Βελτιστοποίησης Adam

Για την ενημέρωση των παραμέτρων του δικτύου χρησιμοποιείται ο αλγόριθμος βελτιστοποίησης Adam (Adaptive Moment Estimation) [24], υλοποιημένος εξ ολοκλήρου σε NumPy. Σε αντίθεση με την απλή στοχαστική κάθοδο κλίσης (Stochastic Gradient Descent, SGD), ο Adam διατηρεί προσαρμοσμένους ρυθμούς μάθησης για καθεμία από τις παραμέτρους του δικτύου, μέσω εκτιμήσεων της πρώτης και δεύτερης ροπής των παραγώγων [24]. Στη χρονική στιγμή t , ο αλγόριθμος ενημερώνει μια παράμετρο θ ως εξής:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (4.24)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (4.25)$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t} \quad (4.26)$$

$$\theta_{t+1} = \theta_t - \alpha \cdot \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} \quad (4.27)$$

όπου $g_t = \nabla_{\theta} L_t$ είναι η παράγωγος της συνάρτησης απώλειας, m_t και v_t είναι εκθετικά εξομαλυσμένοι μέσοι όροι της πρώτης και δεύτερης ροπής, και $\hat{m}_t$, $\hat{v}_t$ είναι οι διορθωμένες εκτιμήσεις τους έναντι της μεροληψίας προς το μηδέν (bias correction). Οι υπερπαραμέτροι λαμβάνουν τις τυπικές τιμές που προτείνονται από τους Kingma και Ba, οι οποίες είναι $\beta_1 = 0.9$, $\beta_2 = 0.999$, και $\epsilon = 10^{-8}$ [24]. Ο ρυθμός μάθησης ορίστηκε σε $\alpha = 10^{-3}$, τιμή που αντιστοιχεί στην προεπιλεγμένη ρύθμιση του αλγορίθμου [24].

Για τη ρύθμιση (regularization) του μοντέλου, εφαρμόζεται κανονικοποίηση L2 (weight decay) με συντελεστή $\lambda = 10^{-4}$. Η ποινή αυτή προστίθεται μόνο στους πίνακες βαρών $\mathbf{W}^{(l)}$ και όχι στα διανύσματα μεροληψίας $\mathbf{b}^{(l)}$, σύμφωνα με την τυπική πρακτική.

4.4.4 Huber Loss και Gradient Clipping

Η εκπαίδευση του δικτύου χρησιμοποιεί ως συνάρτηση απώλειας τη Huber Loss αντί της τυπικής μεθόδου τετραγωνικού σφάλματος (Mean Squared Error, MSE). Η Huber Loss συνδυάζει τη συμπεριφορά της MSE για μικρά σφάλματα με αυτή της απόλυτης τιμής για μεγάλα σφάλματα και ορίζεται

ως:

$$L_\delta(\Delta) = \begin{cases} \frac{1}{2}\Delta^2 & \text{αν } |\Delta| \leq \delta \\ \delta \cdot (|\Delta| - \frac{1}{2}\delta) & \text{αν } |\Delta| > \delta \end{cases} \quad (4.28)$$

όπου $\Delta = Q_{\text{pred}} - Q_{\text{target}}$ είναι σφάλμα πρόβλεψης και $\delta = 1.0$ είναι το όριο μετάβασης. Η αρχική εργασία του DQN [9] αναγνωρίζει την αξία της περικοπής σφάλματος στο διάστημα $[-1, 1]$, η οποία αντιστοιχεί ακριβώς στη χρήση Huber Loss με $\delta = 1.0$ για σφάλματα εκτός του διαστήματος $(-1, 1)$.

Η παράγωγος της Huber Loss ως προς το σφάλμα Δ είναι

$$\frac{\partial L_\delta}{\partial \Delta} = \begin{cases} \Delta & \text{αν } |\Delta| \leq \delta \\ \delta \cdot \text{sign}(\Delta) & \text{αν } |\Delta| > \delta \end{cases} \quad (4.29)$$

που είναι συνεχής και φραγμένη σε απόλυτη τιμή από δ , ανεξάρτητα από το μέγεθος του σφάλματος. Αυτή η ιδιότητα προσδίδει σταθερότητα στην εκπαίδευση DQN, καθώς αποτρέπει τις τεράστιες παραγώγους που θα προέκυπταν από την MSE όταν οι εκτιμήσεις Q είναι μακριά από τις σωστές τιμές [9].

Συμπληρωματικά προς τη Huber Loss εφαρμόζεται και ολική περικοπή παραγώγου (global gradient clipping) με μέγιστη ευκλείδεια νόρμα $\|\nabla\|_{\max} = 10.0$. Πριν την ενημέρωση Adam, υπολογίζεται η συνολική νόρμα όλων των παραγώγων του δικτύου:

$$\|\nabla\|_2 = \sqrt{\sum_l \|\nabla \mathbf{W}^{(l)}\|_F^2 + \|\nabla \mathbf{b}^{(l)}\|_2^2} \quad (4.30)$$

και εφόσον $\|\nabla\|_2 > \|\nabla\|_{\max}$, όλες οι παραγώγοι κλιμακώνονται ομοιόμορφα ώστε η νέα νόρμα να είναι ίση με το όριο

$$\nabla \leftarrow \nabla \cdot \frac{\|\nabla\|_{\max}}{\|\nabla\|_2 + \varepsilon} \quad (4.31)$$

Ο διπλός αυτός μηχανισμός σταθεροποίησης (Huber Loss σε συνδυασμό με gradient clipping) αποτρέπει αποτελεσματικά την έκρηξη παραγώγων (gradient explosion), η οποία αποτελεί αναγνωρισμένο πρόβλημα σε εκπαίδευση DRL με μεγάλες τερματικές ποινές [9].

4.4.5 Στρατηγική Εξερεύνησης ε -greedy

Η ισορροπία μεταξύ εξερεύνησης (exploration) και εκμετάλλευσης (exploitation) είναι θεμελιώδης πρόκληση στην Ενισχυτική Μάθηση. Ο πράκτορας πρέπει αφενός να δοκιμάζει νέες ενέργειες ώστε να ανακαλύπτει πιθανώς βέλτιστες στρατηγικές, αφετέρου να αξιοποιεί την υπάρχουσα γνώση για να συσσωρεύσει ανταμοιβές. Η παρούσα υλοποίηση χρησιμοποιεί τη στρατηγική ε -greedy, η οποία αποτελεί την κλασική επιλογή στο αρχικό DQN [9] και σε πολλές μεταγενέστερες επεκτάσεις του [12, 4].

Σε κάθε χρονικό βήμα, ο πράκτορας επιλέγει ενέργεια σύμφωνα με τον κανόνα:

$$a_t = \begin{cases} \text{τυχαία επιλογή από το } \mathcal{A} & \text{με πιθανότητα } \varepsilon \\ \arg \max_a Q(s_t, a; \theta) & \text{με πιθανότητα } 1 - \varepsilon \end{cases} \quad (4.32)$$

Στην αρχή της εκπαίδευσης, η παράμετρος εξερεύνησης ε ορίζεται ως $\varepsilon_0 = 1.0$, ώστε όλες οι ενέργειες να λαμβάνονται αρχικά τυχαία. Η τιμή του ε μειώνεται γραμμικά μετά από κάθε βήμα αλληλε-

πίδρασης με ρυθμό $\Delta\epsilon$, μέχρι να φτάσει την ελάχιστη τιμή $\epsilon_{\min} = 0.01$

$$\epsilon \leftarrow \max(\epsilon - \Delta\epsilon, \epsilon_{\min}) \quad (4.33)$$

Στα βασικά πειράματα μονού UAV και σμήνους $N = 5$ χρησιμοποιήθηκε ρυθμός $\Delta\epsilon = 5 \times 10^{-3}$ ανά βήμα. Επειδή τα πρώτα επεισόδια διαρκούν αρκετές εκατοντάδες βήματα, η μετάβαση από την αμιγή εξερεύνηση στην εκμετάλλευση ολοκληρώνεται μέσα στα πρώτα επεισόδια εκπαίδευσης και στο μεγαλύτερο μέρος της εκπαίδευσης ο πράκτορας λειτουργεί με $\epsilon = \epsilon_{\min}$. Αντίθετα, στα σαρωτικά πειράματα μεταβλητού μεγέθους σμήνους (Κεφάλαιο 5) υιοθετήθηκε σημαντικά μικρότερος ρυθμός $\Delta\epsilon = 4.2 \times 10^{-5}$ ανά βήμα, ώστε η εξερεύνηση να κατανέμεται ομαλά σε όλη τη διάρκεια των 800 επεισοδίων. Η ελάχιστη τιμή $\epsilon_{\min} = 0.01$ διατηρείται για το υπόλοιπο της εκπαίδευσης, διασφαλίζοντας ένα μικρό ποσοστό τυχαίων ενεργειών ως ασπίδα έναντι πρόωρης σύγκλισης σε τοπικά βέλτιστα [9].

4.4.6 Υλοποίηση Double DQN

Όπως αναπτύχθηκε στην Ενότητα 2.4.3, ο αλγόριθμος Double DQN (DDQN) αποτελεί βελτίωση του βασικού DQN, η οποία μετριάζει την υπερεκτίμηση των τιμών Q μέσω αποσύνδεσης της επιλογής ενέργειας από την αξιολόγηση της [12]. Στην παρούσα υλοποίηση, διατηρούνται δύο νευρωνικά δίκτυα με ταυτόσημη αρχιτεκτονική αλλά διαφορετικές παραμέτρους:

- Το **δίκτυο online** με παραμέτρους θ , το οποίο ενημερώνεται σε κάθε βήμα εκπαίδευσης και χρησιμοποιείται για τις ζωντανές αποφάσεις πολιτικής.
- Το **δίκτυο-στόχος (target network)** με παραμέτρους θ^- , οι οποίες ενημερώνονται περιοδικά μέσω αντιγραφής από το online δίκτυο [9].

Σε κάθε βήμα εκπαίδευσης, δείγμα μεγέθους $B = 64$ δειγματοληπτείται ομοιόμορφα από τη ζώνη επανάληψης εμπειρίας, η οποία διατηρεί έως $|D| = 100,000$ μεταβάσεις. Για κάθε δείγμα (s, a, r, s', d) , η τιμή-στόχος υπολογίζεται κατά τη φιλοσοφία του DDQN [12]

$$a^* = \arg \max_{a'} Q(s', a'; \theta) \quad (4.34)$$

$$y = r + \gamma \cdot Q(s', a^*; \theta^-) \cdot (1 - d) \quad (4.35)$$

Η επιλογή της ενέργειας a^* που μεγιστοποιεί την τιμή Q στην επόμενη κατάσταση πραγματοποιείται από το online δίκτυο. Αντίθετα, η αξιολόγηση αυτής της ενέργειας γίνεται από το δίκτυο-στόχο. Με την αποσύνδεση αυτή, αποφεύγεται η περίπτωση όπου τυχόν υπερεκτίμηση μιας τιμής Q από το online δίκτυο να ενισχύεται από τον εαυτό της κατά τον υπολογισμό του στόχου [12]. Ο συντελεστής έκπτωσης ορίζεται σε $\gamma = 0.99$, τιμή που αποδίδει σημαντικό βάρος στις μακροπρόθεσμες ανταμοιβές, στοιχείο απαραίτητο σε προβλήματα σχεδιασμού διαδρομής όπου ο τελικός στόχος βρίσκεται δεκάδες βήματα μακριά από την αρχική θέση [9].

Ο όρος $(1-d)$ μηδενίζει την αναμενόμενη μελλοντική ανταμοιβή όταν η μετάβαση οδηγεί σε τερματική κατάσταση. Η συνολική απώλεια Huber υπολογίζεται μεταξύ της προβλεπόμενης τιμής $Q(s, a; \theta)$ και της τιμής-στόχου y . Επίσης, η οπισθοδιάδοση ενημερώνει αποκλειστικά τις παραμέτρους θ του online δικτύου.

Το δίκτυο-στόχος ενημερώνεται περιοδικά μέσω σκληρής αντιγραφής των παραμέτρων (hard update)

κάθε $C = 4$ βήματα ενημέρωσης παραγώγων.

$$\theta^- \leftarrow \theta, \quad \text{κάθε } C \text{ βήματα} \quad (4.36)$$

Σε ένα τυπικό επεισόδιο σμήνους με N πράκτορες και T βήματα, η ζώνη επανάληψης εμπειρίας ενημερώνεται με $N \cdot T$ νέες μεταβάσεις. Όλοι οι πράκτορες μοιράζονται το ίδιο νευρωνικό δίκτυο και την ίδια ζώνη μνήμης, υλοποιώντας έτσι την αρχή της κοινής πολιτικής (parameter sharing) [5]. Αυτή η προσέγγιση όχι μόνο επιταχύνει την εκπαίδευση μέσω αυξημένης δειγματοληπτικής αποδοτικότητας, αλλά παρέχει και εγγενή επεκτασιμότητα, καθώς το ίδιο εκπαιδευμένο μοντέλο μπορεί να εφαρμοστεί σε σμήνη διαφορετικών μεγεθών χωρίς νέα εκπαίδευση, εφόσον έχει διατηρηθεί η διάσταση της παρατήρησης.

4.5 Διαμόρφωση Ανταμοιβής Σμήνους (SwarmRewardShaper)

Όπως αναλύθηκε στην Ενότητα 2.5, η συμπεριφορά σμήνους δεν αναδύεται αυτόματα από την ατομική εκπαίδευση πρακτόρων DQN. Η πολιτική που μαθαίνει ο πράκτορας μέσω της ατομικής συνάρτησης ανταμοιβής του περιβάλλοντος βελτιστοποιεί αποκλειστικά την ατομική επίτευξη του στόχου, αδιαφορώντας για τη γεωμετρία της ομάδας. Για την επίτευξη συλλογικής συμπεριφοράς, αναπτύχθηκε η κλάση SwarmRewardShaper, η οποία παρέχει πρόσθετες συνιστώσες ανταμοιβής σε κάθε πράκτορα ώστε να ενθαρρύνει τις τρεις θεμελιώδεις αρχές συμπεριφοράς σμήνους του Reynolds [7], δηλαδή τη συνοχή, τον διαχωρισμό και την ευθυγράμμιση.

Η συνολική ανταμοιβή κάθε πράκτορα i σε κάθε χρονικό βήμα προκύπτει ως άθροισμα της ατομικής ανταμοιβής που υπολογίζει το περιβάλλον σύμφωνα με την Ενότητα 4.2.4 και των τριών συνιστωσών σμήνους.

$$r_{\text{total},i} = r_{\text{individual},i} + r_{\text{cohesion},i} + r_{\text{separation},i} + r_{\text{alignment},i} \quad (4.37)$$

Οι συνιστώσες σμήνους υπολογίζονται μόνο για ενεργούς πράκτορες, δηλαδή για όσους δεν έχουν ακόμα τερματιστεί. Πρόκειται για σημαντική σχεδιαστική επιλογή. Όταν ένας πράκτορας έχει ολοκληρώσει την αποστολή του ή έχει συγχρυστεί, παύει να συνεισφέρει στη συλλογική δυναμική. Επίσης, δεν αποτελεί υποψήφιο γείτονα για τους υπόλοιπους. Εάν λιγότεροι από δύο πράκτορες παραμένουν ενεργοί σε ένα επεισόδιο, καμία συνιστώσα σμήνους δεν εφαρμόζεται, καθώς η έννοια του σμήνους χάνει το νόημα της.

Στις επόμενες υποενότητες αναλύεται η μαθηματική διατύπωση κάθε συνιστώσας.

4.5.1 Συνιστώσα Συνοχής (Cohesion)

Η συνοχή ενθαρρύνει τα μέλη του σμήνους να παραμένουν κοντά στο γεωμετρικό κέντρο της ομάδας, αποτρέποντας τον διασκορπισμό τους στο περιβάλλον [7, 15]. Στην παρούσα υλοποίηση, το κέντρο του σμήνους ορίζεται ως μέσος όρος των θέσεων όλων των ενεργών πρακτόρων

$$\mathbf{c}_{\text{swarm}} = \frac{1}{|\mathcal{A}_t|} \sum_{j \in \mathcal{A}_t} \mathbf{p}_j \quad (4.38)$$

όπου $\mathcal{A}_t$ είναι το σύνολο των δεικτών ενεργών πρακτόρων κατά τη χρονική στιγμή t . Η ανταμοιβή συνοχής για τον πράκτορα i είναι αρνητική και ανάλογη της ευκλείδειας απόστασης από το κέντρο του

σμήνους

$$r_{\text{cohesion},i} = -w_{\text{coh}} \cdot \|\mathbf{p}_i - \mathbf{c}_{\text{swarm}}\| \quad (4.39)$$

όπου $w_{\text{coh}} = 0.3$ είναι το βάρος της συνιστώσας. Όσο μεγαλύτερη η απόσταση ενός πράκτορα από το κέντρο του σμήνους, τόσο μεγαλύτερη η ποινή που λαμβάνει. Με αυτόν τον τρόπο, η πολιτική του πράκτορα ωθείται προς την κίνηση που μειώνει την απόσταση από το κέντρο, διατηρώντας τη συνολική συνοχή της ομάδας ως οντότητα. Σημαντικό στοιχείο αυτής της διατύπωσης είναι ότι η ποινή αυξάνεται γραμμικά και όχι τετραγωνικά με την απόσταση. Η γραμμική επιλογή αποδίδει μικρότερη ποινή σε μικρές αποκλίσεις και αποφεύγει την αδικαιολόγητη τιμωρία ευέλικτων ελιγμών αποφυγής εμποδίων.

Η κανονικοποίηση του κέντρου ως μέσου όρου ενεργών μόνο πρακτόρων διασφαλίζει ότι η συνιστώσα συνοχής παραμένει συνεπής όταν μέλη του σμήνους τερματίζονται. Για παράδειγμα, σε ένα σμήνος των πέντε πρακτόρων όπου δύο έχουν φτάσει ήδη στον στόχο, οι υπόλοιποι τρεις υπολογίζουν το νέο κέντρο τους και προσαρμόζονται ανάλογα χωρίς να επηρεάζονται από τις απομονωμένες θέσεις των τερματισμένων μελών.

4.5.2 Συνιστώσα Διαχωρισμού (Separation) και Ζώνη Κινδύνου

Η συνιστώσα διαχωρισμού αποτελεί την πιο πολύπλοκη από τις τρεις, καθώς πρέπει να ενσωματώσει δύο διακριτές αλλά αλληλένδετες αρχές. Αρχικά, ενθαρρύνει τη διατήρηση μιας επιθυμητής απόστασης μεταξύ ζευγών πρακτόρων, αποτρέποντας τόσο την υπερβολική συγκέντρωση όσο και τον υπερβολικό διασκορπισμό. Επιπρόσθετα, επιβάλλει μια έντονη ποινή όταν δύο πράκτορες πλησιάζουν επικίνδυνα, αποτρέποντας πιθανές συγκρούσεις πριν αυτές προκύψουν.

Η ομαλή συνιστώσα διαχωρισμού για ζεύγος πρακτόρων (i, j) έχει τη μορφή ανεστραμμένης τετραγωνικής συνάρτησης, με μέγιστο (μηδενική ποινή) στην επιθυμητή απόσταση $d^* = 6.0$ μονάδες

$$r_{\text{spacing},ij} = -w_{\text{sep}} \cdot \frac{(d_{ij} - d^*)^2}{(d^*)^2} \quad (4.40)$$

όπου $d_{ij} = \|\mathbf{p}_i - \mathbf{p}_j\|$ είναι η απόσταση μεταξύ των δύο πρακτόρων, $w_{\text{sep}} = 4.0$ είναι το βάρος της συνιστώσας και ο παρονομαστής $(d^*)^2$ κανονικοποιεί την ποινή ώστε να μην εξαρτάται από την κλίμακα της επιθυμητής απόστασης. Η συνάρτηση αυτή λαμβάνει τη μέγιστη τιμή της, ίση με μηδέν, όταν $d_{ij} = d^*$ και πέφτει συμμετρικά για μεγαλύτερες και μικρότερες αποστάσεις. Με αυτόν τον τρόπο, οι πράκτορες ενθαρρύνονται να διατηρούν περίπου σταθερές αποστάσεις μεταξύ τους, χωρίς να συρρέουν στενά ούτε να απομακρύνονται αδικαιολόγητα.

Όταν δύο πράκτορες πλησιάσουν σε απόσταση μικρότερη από ένα κρίσιμο όριο $d_{\min}^{\text{sep}} = 3.0$ μονάδες ενεργοποιείται πρόσθετη ποινή ζώνης κινδύνου:


$$r_{\text{danger},ij} = \begin{cases} -10 \cdot w_{\text{sep}} & \text{αν } d_{ij} < d_{\min}^{\text{sep}} \\ 0 & \text{αλλιώς} \end{cases} \quad (4.41)$$

Η ποινή ζώνης κινδύνου είναι δέκα φορές μεγαλύτερη από το βάρος της συνιστώσας διαχωρισμού, δημιουργώντας ένα έντονο σήμα μάθησης που οδηγεί τον πράκτορα να αποφύγει την επικίνδυνη ζώνη αμέσως μόλις την προσεγγίσει. Η συνολική ανταμοιβή διαχωρισμού για τον πράκτορα i προκύπτει από

το άθροισμα και των δύο όρων πάνω σε όλους τους άλλους ενεργούς πράκτορες:

$$r_{\text{separation},i} = \sum_{j \in \mathcal{A}_t, j \neq i} (r_{\text{spacing},ij} + r_{\text{danger},ij}) \quad (4.42)$$

Η συνδυασμένη αυτή διατύπωση εξυπηρετεί έναν ιεραρχικό σκοπό. Στην ομαλή περιοχή $d_{ij} \gg d_{\min}^{\text{sep}}$, ο πράκτορας λαμβάνει μια ήπια καθοδήγηση προς την επιθυμητή απόσταση. Καθώς ο κίνδυνος σύγκρουσης αυξάνεται, η συνιστώσα γίνεται έντονα αποτρεπτική. Έτσι, ο πράκτορας μαθαίνει ταυτόχρονα να διατηρεί την αρμονία του σμήνους σε φυσιολογικές συνθήκες και να αντιδρά γρήγορα σε επικίνδυνες προσεγγίσεις.



Σχήμα 4.4: Συνολική ανταμοιβή διαχωρισμού $r_{\text{spacing},ij} + r_{\text{danger},ij}$ ως συνάρτηση της απόστασης d_{ij} μεταξύ δύο πρακτόρων, για βάρος $w_{\text{sep}} = 4.0$. Η ομαλή συνιστώσα έχει τη μορφή ανεστραμμένης τετραγωνικής συνάρτησης με μέγιστο (μηδενική ποινή) στην επιθυμητή απόσταση $d^* = 6.0$. Όταν η απόσταση πέσει κάτω από το κρίσιμο όριο $d_{\min}^{\text{sep}} = 3.0$, ενεργοποιείται η ασυνεχής ποινή ζώνης κινδύνου με σταθερή προσθήκη $-10 \cdot w_{\text{sep}} = -40$. Στα σαρωτικά πειράματα μεταβλητού μεγέθους σμήνους, το βάρος w_{sep} κανονικοποιείται ως $4.0/(N - 1)$ (βλ. Κεφάλαιο 5).

4.5.3 Συνιστώσα Ευθυγράμμισης (Alignment)

Η ευθυγράμμιση ενθαρρύνει τα μέλη του σμήνους να κινούνται προς κοινή κατεύθυνση, ένα από τα πιο εντυπωσιακά χαρακτηριστικά των φυσικών σμηνών στη φύση [7]. Σε αντίθεση με τις δύο προηγούμενες συνιστώσες που χρησιμοποιούν ευκλείδειες αποστάσεις, η ευθυγράμμιση αφορά τις γωνίες προσανατολισμού των πρακτόρων.

Για κάθε ζεύγος ενεργών πρακτόρων (i, j) , η συμφωνία προσανατολισμού μετρείται μέσω του συνημιτόνου της γωνιακής διαφοράς:

$$a_{ij} = \cos(\psi_i - \psi_j) \quad (4.43)$$

Η συνάρτηση συνημιτόνου είναι ιδιαίτερα κατάλληλη για αυτόν τον σκοπό. Λαμβάνει τη μέγιστη τιμή +1 όταν οι δύο πράκτορες έχουν ταυτόσημο προσανατολισμό, μηδέν όταν είναι κάθετοι, και -1

όταν κινούνται σε αντίθετες κατευθύνσεις. Επιπλέον, η μέτρηση μέσω συνημιτόνου χειρίζεται σωστά την περιοδικότητα των γωνιών, οπότε δεν υπάρχει ανάγκη ρητής επεξεργασίας του διαστήματος $[-\pi, \pi]$.

Η συνολική ανταμοιβή ευθυγράμμισης για τον πράκτορα i ορίζεται ως μέσος όρος των a_{ij} πάνω σε όλους τους άλλους ενεργούς πράκτορες, πολλαπλασιασμένος με το βάρος της συνιστώσας:

$$r_{\text{alignment},i} = w_{\text{ali}} \cdot \frac{1}{|\mathcal{A}_t| - 1} \sum_{j \in \mathcal{A}_t, j \neq i} \cos(\psi_i - \psi_j) \quad (4.44)$$

όπου $w_{\text{ali}} = 0.8$ είναι το βάρος της συνιστώσας. Η κανονικοποίηση μέσω του αριθμού γειτόνων εξασφαλίζει ότι η ανταμοιβή ευθυγράμμισης δεν αυξάνεται γραμμικά με το μέγεθος του σμήνους, διατηρώντας έτσι σταθερό σήμα μάθησης ανεξαρτήτως του N . Σε αντίθεση με τις προηγούμενες συνιστώσες, η ευθυγράμμιση μπορεί να είναι θετική ή αρνητική. Θετικές τιμές ανταμείβουν συμφωνία προσανατολισμού, ενώ αρνητικές τιμωρούν διαφωνία.

4.5.4 Επιλογή Υπερπαραμέτρων

Οι τιμές των υπερπαραμέτρων του **SwarmRewardShaper** συνοψίζονται στον Πίνακα 4.1. Η σχετική σημασία των τριών συνιστωσών αντικατοπτρίζεται στα αντίστοιχα βάρη:

$$w_{\text{sep}} \gg w_{\text{ali}} > w_{\text{coh}} \quad (4.45)$$

Η υπεροχή του βάρους διαχωρισμού ($w_{\text{sep}} = 4.0$) έναντι των άλλων δύο συνιστωσών ακολουθεί την αρχική σύσταση του Reynolds, ότι σε καταστάσεις σύγκρουσης μεταξύ των τριών αρχών, ο διαχωρισμός πρέπει να υπερισχύει για να αποτρέπονται οι συγκρούσεις [7]. Η σχετικά μικρή τιμή του βάρους συνοχής ($w_{\text{coh}} = 0.3$) επιλέχθηκε ώστε η συνεκτικότητα να παρέχει ασθενή ωθητική δύναμη χωρίς να περιορίζει τους ελιγμούς αποφυγής εμποδίων. Η ευθυγράμμιση λαμβάνει ενδιάμεσο βάρος ($w_{\text{ali}} = 0.8$), αρκετό ώστε να αναδυθεί η συλλογική κατευθυντικότητα του σμήνους.

Πίνακας 4.1: Υπερπαραμέτροι του **SwarmRewardShaper**

Παράμετρος	Σύμβολο	Τιμή
Βάρος συνοχής	w_{coh}	0.3
Βάρος διαχωρισμού	w_{sep}	4.0
Βάρος ευθυγράμμισης	w_{ali}	0.8
Επιθυμητή απόσταση	d^*	6.0
Ελάχιστη απόσταση	$d_{\text{min}}^{\text{sep}}$	3.0
Πολλαπλασιαστής ζώνης κινδύνου	—	10

Η επιθυμητή απόσταση $d^* = 6.0$ είναι διπλάσια της κρίσιμης απόστασης σύγκρουσης $d_{\text{min}}^{\text{sep}} = 3.0$ μονάδες. Με αυτή τη ρύθμιση, οι πράκτορες ωθούνται σε κίνηση εντός ζώνης ασφαλούς αλλά συμπαγούς σμήνους, αρκετά κοντά μεταξύ τους ώστε να υπάρχει επαρκές περιθώριο ασφαλείας για αντιδραστικές αποφυγές σύγκρουσης. Η κρίσιμη απόσταση $d_{\text{min}}^{\text{sep}}$ ταυτίζεται με το όριο αλληλεπίδρασης σύγκρουσης που χρησιμοποιεί το περιβάλλον σμήνους (βλ. Ενότητα 4.3.1), διατηρώντας έτσι συνέπεια μεταξύ της γεωμετρικής ανίχνευσης σύγκρουσης και της επιβολής ποινής μέσω του **SwarmRewardShaper**.

Στο τέλος του κεφαλαίου, ο Πίνακας 4.2 συγκεντρώνει όλες τις υπερπαραμέτρους του πλήρους συ-

στήματος, συμπεριλαμβανομένων εκείνων του περιβάλλοντος προσομοίωσης, του πράκτορα DQN και του **SwarmRewardShaper**, προσφέροντας μια ολοκληρωμένη εικόνα της παραμετροποίησης του συστήματος.

Πίνακας 4.2: Συγκεντρωτικός πίνακας υπερπαραμέτρων του συστήματος όπως χρησιμοποιήθηκαν στα πειράματα του Κεφαλαίου 5.

Παράμετρος	Σύμβολο	Τιμή
<i>Περιβάλλον Προσομοίωσης (UAVEnvTopology)</i>		
Όρια κόσμου	$\mathcal{W}$	$[-50, 50]^2$
Αρχική θέση	$\mathbf{p}_{\text{σταρτ}}$	$(-40, -40)$
Θέση στόχου	$\mathbf{p}_{\text{γοαλ}}$	$(40, 40)$
Ελάχιστη ακτίνα εμποδίων	$r_{\min}$	3.0
Μέγιστη ακτίνα εμποδίων	$r_{\max}$	8.0
Εκκαθάριση μεταξύ εμποδίων	$d_{\text{εαφ}}$	1.0
Εκκαθάριση αρχής-στόχου από εμπόδιο	$d_{\text{σγ}}$	6.0
Μέγιστες προσπάθειες δειγματοληψίας	$K_{\max}$	500
Αριθμός εμποδίων (βασικά πειράματα)	—	8
Θόρυβος αρχικής θέσης	σ_p	2.0
Θόρυβος αρχικού προσανατολισμού (ραδ)	σ_ψ	0.2
<i>Περιβάλλον Μονού UAV (UAVEnv)</i>		
Ταχύτητα	v	3.0
Χρονικό βήμα	Δt	0.5
Ακτίνα στόχου	$r_{\text{γοαλ}}$	3.0
Χώρος ενεργειών (γωνίες)	$\mathcal{A}$	$\{-30^\circ, -15^\circ, 0^\circ, +15^\circ, +30^\circ\}$
Γωνίες αισθητήρων	$\theta_{\text{σενσορ}}$	$\{-60^\circ, -30^\circ, 0^\circ, +30^\circ, +60^\circ\}$
Μέγιστη εμβέλεια αισθητήρων	$\rho_{\max}$	30.0
Ανάλυση ιχνηλάτησης ακτίνας	Δs	0.5
Συντελεστής ασφαλείας σύγκρουσης	δ	0.5
Μέγιστα βήματα ανά επεισόδιο	$T_{\max}$	400
Ανταμοιβή σύγκρουσης	$r_{\text{ελλισιον}}$	-300.0
Ανταμοιβή στόχου	$r_{\text{γοαλ}}$	$1200.0 - 50 \cdot \varepsilon_\psi $
Βάρος προόδου	w_1	10.0
Βάρος σφάλματος προσανατολισμού	w_2	5.0
Βάρος ενέργειας	w_3	1.0
Σταθερή ποινή βήματος	w_4	0.5
<i>Περιβάλλον Σμήνους (SwarmUAVEnv)</i>		
Αριθμός πρακτόρων	N	5
Εύρος μεγέθους σμήνους (σαρωτικά πειράματα)	N	$\{2, 3, \dots, 10\}$
Ταχύτητα	v	3.0
Χρονικό βήμα	Δt	0.5
Ακτίνα στόχου	$r_{\text{γοαλ}}$	3.0
Ακτίνα σώματος UAV	r_{body}	0.5
Ελάχιστη απόσταση UAV-UAV	d_{sep}	2.0
Διασπορά γέννησης	$\sigma_{\text{σπαων}}$	3.0
Όριο αποκοπής σχετικής θέσης	$o_{\text{ελιπ}}$	50.0
Ανταμοιβή σύγκρουσης μεταξύ UAV	r_{inter}	-250.0
Υποβήματα ολοκλήρωσης	—	10
<i>Πράκτορας DQN (DQNAgent)</i>		
Διάσταση χρυσών στρωμάτων	h	128
Ρυθμός μάθησης (Adam)	$\frac{44}{\alpha}$	10^{-3}
L2 κανονικοποίηση (weight decay)	λ	10^{-4}

ΚΕΦΑΛΑΙΟ 5: Πειράματα και Αποτελέσματα

Στο παρόν κεφάλαιο παρουσιάζονται και αναλύονται τα αποτελέσματα των πειραμάτων που διενεργήθηκαν για την αξιολόγηση του προτεινόμενου συστήματος. Η πειραματική μελέτη οργανώνεται σε τέσσερις άξονες. Πρώτον, εξετάζεται η σύγκλιση του πράκτορα κατά την εκπαίδευση στο περιβάλλον μονού UAV και η ευρωστία του ως προς την πυκνότητα εμποδίων. Δεύτερον, παρουσιάζεται η εκπαίδευση και η αξιολόγηση του σμήνους αναφοράς με $N = 5$ πράκτορες. Τρίτον, αναλύεται συστηματικά η επίδραση του μεγέθους του σμήνους στις μετρικές απόδοσης, μέσω πειραμάτων με $N \in \{2, 3, \dots, 10\}$. Τέλος, μελετάται η συμπεριφορά του βασικού σμήνους σε σενάρια αυξανόμενης πυκνότητας εμποδίων.

5.1 Πρωτόκολλο Εκπαίδευσης και Αξιολόγησης

Πριν την παρουσίαση των αποτελεσμάτων, κρίνεται σκόπιμη η ρητή διατύπωση του πρωτοκόλλου που ακολουθήθηκε σε όλα τα πειράματα, ώστε να είναι σαφείς οι συνθήκες υπό τις οποίες εξήχθησαν τα ευρήματα. Όλες οι υπερπαραμέτροι του δικτύου, του περιβάλλοντος και της διαμόρφωσης ανταμοιβής συνοψίζονται στον Πίνακα 4.2 του Κεφαλαίου 4.

5.1.1 Διάρκεια και Παράμετροι Εκπαίδευσης

Η διάρκεια της εκπαίδευσης διαφοροποιήθηκε ανάλογα με τη φύση του εκάστοτε σεναρίου. Ο πράκτορας μονού UAV εκπαιδεύτηκε για 400 επεισόδια, ενώ ο πράκτορας σμήνους εκπαιδεύτηκε επίσης για 400 επεισόδια στο βασικό σενάριο $N = 5$. Στα σαρωτικά πειράματα μεταβλητού μεγέθους σμήνους ($N \in \{2, 3, \dots, 10\}$), η εκπαίδευση παρατάθηκε σε 800 επεισόδια ανά μέγεθος, ώστε να αντισταθμιστεί η μειωμένη σύγκλιση που παρατηρείται σε σμήνη ακραίων μεγεθών και να διασφαλιστεί δίκαιη σύγκριση σε ολόκληρο το εύρος. Σε όλες τις περιπτώσεις, το μέγιστο μήκος επεισοδίου περιορίστηκε σε $T_{\max} = 400$ χρονικά βήματα. Όλα τα πειράματα διεξήχθησαν σε περιβάλλοντα με 8 εμπόδια, εκτός όπου ρητά διαφοροποιείται.

Στα σαρωτικά πειράματα μεταβλητού μεγέθους σμήνους εφαρμόστηκαν δύο μεθοδολογικές προσαρμογές. Πρώτον, ο ρυθμός μείωσης της παραμέτρου εξερεύνησης ϵ μειώθηκε σε $\Delta\epsilon = 4.2 \times 10^{-5}$ ανά βήμα, σαφώς χαμηλότερος από το $\Delta\epsilon = 5 \times 10^{-3}$ ανά βήμα που χρησιμοποιήθηκε στα βασικά πειράματα. Η αλλαγή αυτή διασφαλίζει επαρκή εξερεύνηση κατά τη διάρκεια των 800 επεισοδίων εκπαίδευσης. Δεύτερον, το βάρος διαχωρισμού w_{sep} κανονικοποιήθηκε ως $w_{\text{sep}}^{\text{eff}} = 4.0/(N - 1)$, ώστε η συνολική ποινή αλληλεπιδράσεων ζευγών να μην αυξάνεται γραμμικά με τον αριθμό των γειτόνων κάθε πράκτορα. Στο βασικό σενάριο $N = 5$, η κανονικοποίηση δεν εφαρμόστηκε και το βάρος παρέμεινε στην ονομαστική τιμή $w_{\text{sep}} = 4.0$.

Σε όλα τα πειράματα χρησιμοποιήθηκε σταθερή αρχική τιμή $\text{seed} = 42$ για την εκπαίδευση, ώστε τα αποτελέσματα να είναι αναπαραγώγιμα. Οι τοπολογίες των αξιολογήσεων προήλθαν από διαφορετικά seeds, ξεκινώντας από $\text{seed} = 0$ και αυξάνοντας κατά ένα για κάθε νέο επεισόδιο.

5.1.2 Πρωτόκολλο Αξιολόγησης

Η αξιολόγηση των εκπαιδευμένων πρακτόρων πραγματοποιήθηκε σε ξεχωριστό σύνολο επεισοδίων με ντετερμινιστική επιλογή ενέργειας ($\epsilon = 0$), αποκλείοντας τον θόρυβο εξερεύνησης που χαρακτηρίζει

τη φάση εκπαίδευσης. Με εξαίρεση τη στρατηγική σταθερού περιβάλλοντος της Ενότητας 5.4.1, κάθε επεισόδιο αξιολόγησης ξεκινά με νέα στοχαστικά παραγόμενη τοπολογία εμποδίων, εξασφαλίζοντας ότι η αναφερόμενες μετρικές αντικατοπτρίζουν την ικανότητα γενίκευσης του πράκτορα και όχι απομνημόνευση συγκεκριμένων διαμορφώσεων. Στη στρατηγική σταθερού περιβάλλοντος, όπως διευκρινίζεται παρακάτω, η αξιολόγηση πραγματοποιείται στην ίδια σταθερή τοπολογία με την εκπαίδευση.

Ο αριθμός επεισοδίων αξιολόγησης διαφοροποιήθηκε ανάλογα με τη φύση κάθε πειράματος, με στόχο τη στατιστική επάρκεια χωρίς υπερβολική υπολογιστική επιβάρυνση. Συγκεκριμένα χρησιμοποιήθηκαν τα εξής:

- **Σαρωτικά πειράματα μεγέθους σμήνους ($N \in \{2, \dots, 10\}$):** 100 επεισόδια ανά μέγεθος, σε περιβάλλοντα με 8 εμποδία.
- **Επίδραση πυκνότητας εμποδίων στο σμήνος $N = 5$ (σενάρια $\{4, 6, 8\}$ εμποδίων):** 300 επεισόδια ανά σενάριο.
- **Εκτεταμένο εύρος εμποδίων (1 έως 10):** 100 επεισόδια ανά αριθμό εμποδίων.
- **Σύγκριση μονού UAV με σμήνος και σύγκριση μεγεθών $\{3, 4, 5\}$:** 200 επεισόδια ανά διαμόρφωση, σε περιβάλλοντα με 4 εμποδία.

5.1.3 Μετρικές Απόδοσης

Η ποιοτική και ποσοτική αξιολόγηση βασίζεται σε πέντε κύριες μετρικές [1]:

- **Ποσοστό Επιτυχίας (Success Rate):** Το ποσοστό των επεισοδίων αξιολόγησης στα οποία τουλάχιστον ένας πράκτορας σμήνους έφτασε στον στόχο εντός του χρονικού ορίου $T_{\max}$. Στο περιβάλλον μονού πράκτορα, αναφέρεται απλώς στην επιτυχή άφιξη του μοναδικού πράκτορα. Εκφράζεται ως ποσοστό επί τοις εκατό.

$$SR = \frac{1}{N_{ep}} \sum_{i=1}^{N_{ep}} \mathbf{1}(\text{επιτυχία}_i) \% \quad (5.1)$$

- **Μήκος Διαδρομής (Mean Path Length):** Το συνολικό ευκλείδειο μήκος της τροχιάς που διέγραψε ο πράκτορας (ή το κεντροειδές του σμήνους) από την αρχή στον στόχο. Ο μέσος όρος υπολογίζεται αποκλειστικά επί των επιτυχημένων επεισοδίων, ώστε αποτυχίες λόγω σύγκρουσης ή χρονικού ορίου να μην αλλοιώνουν τη μέτρηση.

$$D = \sum_{t=1}^T \|\mathbf{p}_t - \mathbf{p}_{t-1}\|_2 = \sum_{t=1}^T \sqrt{(x_t - x_{t-1})^2 + (y_t - y_{t-1})^2} \quad (5.2)$$

- **Ομαλότητα Διαδρομής (Path Smoothness):** Ο μέσος όρος της απόλυτης γωνιακής μεταβολής ανά βήμα $|\Delta\psi|$, εκφρασμένο σε rad. Χαμηλότερες τιμές υποδηλώνουν ομαλότερες τροχιές με λιγότερες απότομες αλλαγές κατεύθυνσης. Στο σμήνος, η μέτρηση αναφέρεται στον μέσο προσανατολισμό όλων των πρακτόρων.

$$S = \frac{1}{T} \sum_{t=1}^T |\Delta\psi_t| \quad (5.3)$$

- **Ενεργειακό Κόστος (Energy Proxy):** Το συνολικό άθροισμα $\sum |\Delta\psi|$ κατά τη διάρκεια του επεισοδίου. Λειτουργεί ως υποκατάστατο μέτρο ενεργειακής κατανάλωσης, υπό την υπόθεση ότι κάθε στροφή απαιτεί μηχανική προσπάθεια ανάλογη του μεγέθους της.

$$E = \sum_{t=1}^T |\Delta\psi_t| = T \cdot S \quad (5.4)$$

- **Μήκος Επεισοδίου (Episode Length):** Ο αριθμός χρονικών βημάτων που χρειάστηκε ο πράκτορας για να ολοκληρώσει το επεισόδιο. Στο σενάριο σμήνους, αφορά τον χρόνο μέχρι όλοι οι πράκτορες να τερματιστούν με κάποιο τρόπο (επιτυχία, σύγκρουση ή χρονικό όριο).

Με εξαίρεση το ποσοστό επιτυχίας, που υπολογίζεται επί του συνόλου των επεισοδίων αξιολόγησης, όλες οι αναφερόμενες μέσες τιμές (μήκος διαδρομής, ομαλότητα, ενεργειακό κόστος και μήκος επεισοδίου) υπολογίζονται αποκλειστικά επί των επιτυχημένων επεισοδίων, ώστε αποτυχίες λόγω σύγκρουσης ή χρονικού ορίου να μην αλλοιώνουν τις μετρήσεις.

Στις επόμενες ενότητες, οι μετρικές αυτές χρησιμοποιούνται συστηματικά για τη σύγκριση διαφορετικών σεναρίων και την εξαγωγή ποσοτικών συμπερασμάτων.

5.1.4 Παρατηρήσεις για τον Ορισμό της Επιτυχίας

Στο σενάριο σμήνους, ο ορισμός του επιτυχημένου επεισοδίου επιδέχεται διαφορετικές ερμηνείες. Στην παρούσα εργασία υιοθετήθηκε ο ασθενής ορισμός της επιτυχίας, σύμφωνα με το οποίο ένα επεισόδιο θεωρείται επιτυχημένο όταν τουλάχιστον ένας από τους N πράκτορες φτάσει στον στόχο εντός του χρονικού ορίου. Αυτή η επιλογή είναι ευθυγραμμισμένη με σενάρια αποστολής όπου η συλλογική επίτευξη μερικής αποστολής θεωρείται αποδεκτή ακόμη και αν μέρος του σμήνους αποτύχει.


Εναλλακτικοί ορισμοί επιτυχίας θα μπορούσαν να απαιτούν την άφιξη όλων των πρακτόρων (ισχυρός ορισμός) ή την άφιξη ποσοστού άνω ενός ορίου (ποσοτικός ορισμός). Οι εναλλακτικοί αυτοί ορισμοί θα οδηγούσαν σε χαμηλότερα ποσοστά επιτυχίας, καθώς θα τιμωρούσαν καθέναν από τους αποτυχημένους πράκτορες. Στη συζήτηση των αποτελεσμάτων που ακολουθεί, οι περιορισμοί αυτής της επιλογής λαμβάνονται υπόψη.

5.2 Εκπαίδευση και Αξιολόγηση Single UAV

Το πρώτο σύνολο πειραμάτων αξιολογεί τη βασική ικανότητα του πράκτορα DQN να μάθει πολιτική σχεδιασμού διαδρομής σε στατικό περιβάλλον. Ο πράκτορας μονού UAV εκπαιδεύεται και αξιολογείται στο περιβάλλον UAVEnv με τις παραμέτρους που συνοψίζονται στον Πίνακα 4.2. Η ανάλυση που ακολουθεί καλύπτει τη σύγκλιση κατά την εκπαίδευση και την ευρωστία του εκπαιδευμένου πράκτορα ως προς την πυκνότητα εμποδίων.

5.2.1 Καμπύλη Σύγκλισης Εκπαίδευσης

Η εκπαίδευση εκτελέστηκε για 400 επεισόδια σε περιβάλλον με 8 εμπόδια και σταθερή αρχική τιμή $\text{seed} = 42$. Στο Σχήμα 5.1 παρουσιάζεται η εξέλιξη της ανταμοιβής επεισοδίου (αριστερά) και του μήκους επεισοδίου σε βήματα (δεξιά). Η ανοιχτή γαλάζια γραμμή δείχνει την ωμή τιμή ανά επεισόδιο, ενώ η σκούρα μπλε γραμμή τον κυλιόμενο μέσο όρο 20 επεισοδίων.



Σχήμα 5.1: Καμπύλη σύγκλισης εκπαίδευσης του πράκτορα DQN για το περιβάλλον μονού UAV. Αριστερά: συνολική ανταμοιβή ανά επεισόδιο. Δεξιά: αριθμός βημάτων ανά επεισόδιο.

Στα πρώτα 20 επεισόδια, η ανταμοιβή λαμβάνει έντονα αρνητικές τιμές, με χαρακτηριστικές πτώσεις της τάξης των -2700 μονάδων, που υποδηλώνουν συχνές συγκρούσεις του πράκτορα με εμποδία. Λόγω της μείωσης της παραμέτρου ϵ ανά βήμα, η αμιγώς τυχαία εξερεύνηση περιορίζεται ουσιαστικά στα πρώτα επεισόδια και οι αρνητικές αυτές τιμές οφείλονται κυρίως στο αρχικά μη εκπαιδευμένο δίκτυο, του οποίου οι εκτιμήσεις Q δεν έχουν ακόμη συγκλίνει.

Από το επεισόδιο ~ 100 και μετά, ο κυλιόμενος μέσος όρος σταθεροποιείται κοντά στην τιμή 2200 , γεγονός που υποδηλώνει ότι ο πράκτορας έχει αποκτήσει αποτελεσματική πολιτική πλοήγησης. Παρατηρούνται περιστασιακές πτώσεις της ωμής ανταμοιβής σε τοπικά ελάχιστα κοντά στα επεισόδια 150 , 230 , και 280 , οι οποίες αντιστοιχούν σε σπάνιες αποτυχίες λόγω του υπολειπόμενου θορύβου εξερεύνησης $\epsilon_{\min} = 0.01$. Αυτές οι πτώσεις δεν επηρεάζουν τη συνολική σύγκλιση του πράκτορα.

Η ανάλυση του μήκους επεισοδίου επιβεβαιώνει την ποιότητα της εκπαιδευμένης πολιτικής. Στα πρώτα επεισόδια, το μήκος φτάνει τα $T_{\max} = 400$ βήματα, υποδεικνύοντας ότι ο πράκτορας περιπλανάται χωρίς να επιτύχει τον στόχο. Καθώς προχωρά η εκπαίδευση, το μήκος επεισοδίου σταθεροποιείται περίπου στα 75 βήματα, τιμή που είναι σύμφωνη με την αναμενόμενη ευθεία διαδρομή από την αρχή στον στόχο. Η ευκλείδεια απόσταση $\|\mathbf{p}_{\text{goal}} - \mathbf{p}_{\text{start}}\| = 80\sqrt{2} \approx 113.1$ μονάδες και με ταχύτητα ανά βήμα $v \cdot \Delta t = 1.5$ μονάδες, η ελάχιστη δυνατή διαδρομή χωρίς εμποδία θα διαρκούσε ≈ 75.4 βήματα. Η ακριβής συμφωνία υποδηλώνει ότι ο πράκτορας μαθαίνει σχεδόν βέλτιστες διαδρομές.


5.3 Εκπαίδευση και Αξιολόγηση Σμήνους Αναφοράς ($N = 5$)

Η δεύτερη φάση πειραμάτων εξετάζει την επέκταση του πράκτορα σε σενάριο σμήνους πέντε UAV. Το συγκεκριμένο μέγεθος επιλέχθηκε ως βασικό σενάριο εκπαίδευσης, καθώς αντιπροσωπεύει ένα ισορροπημένο μέγεθος μεταξύ απλότητας ζευγαρωτών αλληλεπιδράσεων και ουσιαστικής συλλογικής συμπεριφοράς. Η εκπαίδευση πραγματοποιήθηκε με το πρωτόκολλο `train_dqn_swarm.py` σε 400 επεισόδια, με βάρη διαμόρφωσης ανταμοιβής $w_{\text{coh}} = 0.3$, $w_{\text{sep}} = 4.0$, και $w_{\text{ali}} = 0.8$.

5.3.1 Καμπύλη Σύγκλισης

Η εξέλιξη της ανταμοιβής και του μήκους επεισοδίου για το σμήνος $N = 5$ παρουσιάζεται στο Σχήμα 5.2. Στο γράφημα ανταμοιβής αναφέρεται, για κάθε επεισόδιο, το άθροισμα της μέσης ανά

πράκτορα ανταμοιβής σε όλα τα βήματα του επεισοδίου. Η μετρική αυτή παραμένει στην ίδια τάξη μεγέθους με την ανά επεισόδιο ανταμοιβή του μονού περιβάλλοντος, αν και η απόλυτη τιμή της είναι χαμηλότερη λόγω της συνεισφοράς των συνιστωσών σμήνους.



Σχήμα 5.2: Καμπύλη σύγκλισης εκπαίδευσης του πράκτορα DQN για το σμήνος αναφοράς $N = 5$. Αριστερά: μέση ανταμοιβή σμήνους ανά βήμα. Δεξιά: αριθμός βημάτων ανά επεισόδιο.

Σε αντίθεση με το περιβάλλον μονού πράκτορα, η σύγκλιση στο σμήνος είναι σαφώς πιο αργή και θορυβώδης. Στα πρώτα 50 επεισόδια, παρατηρούνται ακραίες αρνητικές τιμές ανταμοιβής, με ορισμένα επεισόδια να φτάνουν σε τιμές μικρότερες των -6000 μονάδων. Αυτή η συμπεριφορά αντικατοπτρίζει δύο παράγοντες δυσκολίας του πολυπρακτορικού προβλήματος. Αφενός, η συσσώρευση ποινών σύγκρουσης από πολλαπλούς πράκτορες σε ένα επεισόδιο επιφέρει έντονα αρνητικές κορυφές. Αφετέρου, η εμπειρία που συσσωρεύεται στη ζώνη επανάληψης προέρχεται από πολλαπλούς πράκτορες με διαφορετικές καταστάσεις, οδηγώντας σε υψηλότερη μη στατικότητα της κατανομής μεταβάσεων.


Η σύγκλιση του κυλιόμενου μέσου όρου παρατηρείται σταδιακά μεταξύ των επεισοδίων 150 και 250, με την τελική τιμή ανταμοιβής να σταθεροποιείται περίπου στις 200–400 μονάδες ανά πράκτορα και επεισόδιο. Η συγκεκριμένη τιμή είναι σαφώς χαμηλότερη από αυτή του μονού περιβάλλοντος (≈ 2200), γεγονός αναμενόμενο καθώς η ανταμοιβή του σμήνους περιλαμβάνει και τις συνιστώσες διαχωρισμού και ευθυγράμμισης, που μπορούν να είναι αρνητικές ακόμη και σε επιτυχημένα επεισόδια.

Το μήκος επεισοδίου σταθεροποιείται περίπου στα 80 βήματα από το επεισόδιο ~ 50 και μετά, ελαφρώς υψηλότερα από τα 75 βήματα του μονού UAV. Αυτή η μικρή αύξηση οφείλεται στην ανάγκη αμοιβαίας αποφυγής μεταξύ των πρακτόρων του σμήνους, η οποία οδηγεί σε ελαφρώς πιο ελικοειδείς διαδρομές.

5.3.2 Δείγματα Τροχιών Αξιολόγησης

Μετά την ολοκλήρωση της εκπαίδευσης, ο πράκτορας αξιολογήθηκε σε τρία ντετερμινιστικά επεισόδια ($\varepsilon = 0$), οι τροχιές των οποίων παρουσιάζονται στο Σχήμα 5.3.

Στα τρία αυτά συγκεκριμένα επεισόδια, ένας από τους πέντε πράκτορες έφτασε στον στόχο σε κάθε περίπτωση. Πρόκειται για παρατήρηση που αξίζει συγκεκριμένης ερμηνείας. Στο παρόν πρωτόκολλο αξιολόγησης, ένα επεισόδιο θεωρείται επιτυχημένο όταν τουλάχιστον ένας πράκτορας φτάσει στον στόχο εντός του ορίου $T_{\max}$. Αυτός ο ορισμός ταυτοποιεί την επιτυχία του σμήνους με την επίτευξη της αποστολής έστω και από ένα μέλος του και επιτρέπει τους υπόλοιπους πράκτορες να λειτουργήσουν ως υποστηρικτικά μέλη ή να αποτύχουν χωρίς να ακυρώνεται η συνολική αποστολή.



Σχήμα 5.3: Δείγματα τροχιών αξιολόγησης του εκπαιδευμένου σμήνους $N = 5$ UAV. Πράσινος κύκλος: αρχική θέση. Μπλε αστέρι: στόχος. Έγχρωμες γραμμές: τροχιές ανά πράκτορα. Τετράγωνα σύμβολα: τελικές θέσεις των πρακτόρων στο τέλος του επεισοδίου.

Σε καθένα από τα τρία επεισόδια, ο πράκτορας που τελικά έφτασε στο στόχο διέγραψε σχετικά ομαλή και αποτελεσματική διαδρομή που παρέκαμπτε επιτυχώς τα εμπόδια. Οι υπόλοιποι πράκτορες παρουσιάζουν ποικίλες συμπεριφορές. Σε ορισμένες περιπτώσεις παραμένουν κοντά στην αρχική περιοχή, σε άλλες ξεκινούν να ακολουθούν τον επιτυχημένο πράκτορα αλλά τερματίζονται από σύγκρουση. Αυτή η ποικιλία αντικατοπτρίζει την πρόκληση της ταυτόχρονης πλοήγησης πολλαπλών πρακτόρων με κοινή πολιτική σε στενά διαθέσιμα περάσματα.

5.4 Επίδραση Μεγέθους Σμήνους (2 έως 10 UAV)

Η χρισιμότερη συστηματική ανάλυση του παρόντος κεφαλαίου αφορά την επίδραση του μεγέθους του σμήνους στην απόδοση του πράκτορα DQN. Σε αυτή τη μελέτη εκπαιδεύθηκαν ξεχωριστοί πράκτορες για κάθε μέγεθος $N \in \{2, 3, \dots, 10\}$ με κοινό πρωτόκολλο και αξιολογήθηκαν σε ταυτόσημες συνθήκες περιβάλλοντος. Η αρχιτεκτονική κοινής πολιτικής (parameter sharing) που χρησιμοποιήθηκε [5] επιτρέπει στο ίδιο νευρωνικό δίκτυο να υπαγορεύει αποφάσεις για όλα τα μέλη του σμήνους, οπότε η σύγκριση μεταξύ μεγεθών παρέχει ένα ξεκάθαρο μέτρο της επεκτασιμότητας της προσέγγισης.

Στην παρούσα μελέτη εξετάστηκαν δύο διαφορετικές στρατηγικές εκπαίδευσης που διαφέρουν ως προς τη στοχαστικότητα της διάταξης εμποδίων. Η πρώτη στρατηγική, με την ονομασία *Σταθερό Περιβάλλον* (Fixed Seed), διατηρεί την ίδια αρχική τιμή seed = 42 καθόλη τη διάρκεια εκπαίδευσης των 800 επεισοδίων, οπότε ο πράκτορας εκπαιδεύεται επανειλημμένα στην ίδια τοπολογία εμποδίων. Η δεύτερη στρατηγική, με την ονομασία *Σταδιακή Μάθηση* (Curriculum Learning), βασίζεται σε αρχές που αναπτύχθηκαν αρχικά από τον Bengio και τους συνεργάτες του [25] και εφαρμόζει σταδιακή αύξηση της δυσκολίας του προβλήματος. Στην παρούσα υλοποίηση, το πρώτο 40% των επεισοδίων εκτελείται με σταθερό περιβάλλον για την οικοδόμηση αρχικής πολιτικής, και το υπόλοιπο 60% με τυχαία τοπολογία ανά επεισόδιο για ενίσχυση της γενίκευσης.

5.4.1 Εκπαίδευση με Σταθερό Περιβάλλον (Fixed Seed)

Στη στρατηγική σταθερού περιβάλλοντος, ο πράκτορας εκτελεί όλα τα 800 επεισόδια εκπαίδευσης πάνω στην ίδια στοχαστικά παραγόμενη αλλά μετά σταθερή τοπολογία οκτώ εμποδίων. Η λογική αυτής της προσέγγισης είναι η εξαντλητική βελτιστοποίηση της πολιτικής για ένα συγκεκριμένο περιβάλλον, χωρίς διαταραχές από διαφορετικές γεωμετρικές διατάξεις σε κάθε επεισόδιο. Σημειώνεται ότι η αξιο-

λόγηση των πρακτόρων αυτής της στρατηγικής πραγματοποιείται επίσης στην ίδια σταθερή τοπολογία (seed=42) με μόνη πηγή στοχαστικότητας τις αρχικές θέσεις γέννησης των πρακτόρων. Οι αναφερόμενες μετρικές αποτυπώνουν επομένως την απόδοση εντός της τοπολογίας εκπαίδευσης και όχι τη γενίκευση σε άγνωστα περιβάλλοντα.

Καμπύλη Σύγκλισης

Στο Σχήμα 5.4 παρουσιάζονται οι καμπύλες ανταμοιβής εκπαίδευσης για όλα τα μεγέθη σμήνους. Όλες οι καμπύλες εμφανίζουν σταθεροποίηση μετά τα πρώτα 200–300 επεισόδια, με τις μικρότερες διαμορφώσεις ($N = 2, 3$) να επιτυγχάνουν υψηλότερες ανταμοιβές της τάξης των 1000 μονάδων ανά πράκτορα και βήμα και τις μεγαλύτερες ($N \geq 7$) να σταθεροποιούνται σε χαμηλότερα επίπεδα γύρω από τις 200–350 μονάδες. Η μείωση αυτή είναι μηχανική και οφείλεται στην κανονικοποίηση ανά πράκτορα της μέσης ανταμοιβής, όπως αναλύθηκε στην Ενότητα 5.3.1.



Σχήμα 5.4: Καμπύλες ανταμοιβής εκπαίδευσης για σμήνη μεγέθους $N = 2$ έως $N = 10$ με στρατηγική σταθερού περιβάλλοντος. Κάθε καμπύλη εκτείνεται σε 800 επεισόδια.

Ποσοστό Επιτυχίας


Στο Σχήμα 5.5 παρουσιάζεται το ποσοστό επιτυχίας από 100 ντετερμινιστικά επεισόδια αξιολόγησης ανά μέγεθος.

Τα αποτελέσματα παρουσιάζουν έντονη διακύμανση κατά μήκος των μεγεθών. Το $N = 3$ επιτυγχάνει το ανώτατο ποσοστό επιτυχίας (92%), ενώ τα $N = 6$ και $N = 7$ παρουσιάζουν δραματική πτώση σε 37% και 29% αντίστοιχα. Τα $N \in \{8, 9\}$ ανακάμπτουν στο 80%, ενώ τα ακραία $N = 2$ και $N = 10$ καταγράφουν 50% και 66% αντίστοιχα. Η μη μονοτονικότητα αυτή είναι κρίσιμη για την ερμηνεία της συγκεκριμένης στρατηγικής και επαναξιολογείται στην Ενότητα 5.4.3.


Μετρικές Διαδρομής

Στο Σχήμα 5.6 παρουσιάζονται οι μετρικές μήκους διαδρομής, ομαλότητας και ενεργειακού κόστους.

Παρατηρείται καθαρά ότι όλες οι μετρικές διαδρομής βελτιώνονται έντονα με την αύξηση του μεγέθους σμήνους. Το $N = 2$ παρουσιάζει εξαιρετικά υψηλό μέσο μήκος διαδρομής (113 μονάδες),



Σχήμα 5.5: Ποσοστό επιτυχίας ως συνάρτηση του μεγέθους σμήνους για τη στρατηγική σταθερού περιβάλλοντος.



Σχήμα 5.6: Μετρικές διαδρομής για τη στρατηγική σταθερού περιβάλλοντος. Αριστερά: μήκος διαδρομής. Κέντρο: ομαλότητα. Δεξιά: ενεργειακό κόστος.

ταυτόσημο με την ευθεία διαγώνια από την αρχή στον στόχο, ενώ τα μεγαλύτερα σμήνη επιτυγχάνουν διαδρομές 43–55 μονάδων. Η ομαλότητα φτάνει εξαιρετικά χαμηλές τιμές (0.012 rad/βήμα στο $N = 10$), συνεπείς με σχεδόν ευθύγραμμη κίνηση του κεντροειδούς.


5.4.2 Εκπαίδευση με Σταδιακή Μάθηση (Curriculum Learning)

Στη στρατηγική σταδιακής μάθησης, οι 320 πρώτες επαναλήψεις (40% των 800) εκτελούνται με σταθερή τοπολογία (seed = 42) και οι υπόλοιπες 480 επαναλήψεις με νέα στοχαστική τοπολογία σε κάθε επεισόδιο. Η λογική αυτής της προσέγγισης στηρίζεται στη γενικότερη αρχή του Curriculum Learning [25], σύμφωνα με την οποία η μάθηση ενισχύεται όταν ο πράκτορας εκτίθεται πρώτα σε ευκολότερες παραλλαγές του προβλήματος και βαθμιαία σε πιο σύνθετες.


Καμπύλες Σύγκλισης και Σύγκλιση

Στα Σχήματα 5.7 και 5.8 παρουσιάζονται οι καμπύλες ανταμοιβής εκπαίδευσης και ο αριθμός επεισοδίων μέχρι τη σύγκλιση, αντίστοιχα.

Ο αριθμός επεισοδίων μέχρι τη σύγκλιση δεν παρουσιάζει μονοτονική τάση ως προς το μέγεθος του σμήνους. Το μικρότερο σμήνος ($N = 2$) συγκλίνει ταχύτερα (206 επεισόδια), γεγονός αναμενόμενο καθώς ο πράκτορας ασχολείται με τη βασική συμπεριφορά πλοήγησης ζεύγους. Τα ενδιάμεσα μεγέθη $N = 3, 4, 5$ απαιτούν περισσότερα από 440 επεισόδια (547, 465, 448 αντίστοιχα), ενώ τα μεγαλύτερα



Σχήμα 5.7: Καμπύλες ανταμοιβής εκπαίδευσης για τη στρατηγική σταδιακής μάθησης. Παρατηρούνται περιοδικές διαταραχές στις πρώτες 320 επαναλήψεις λόγω της εναλλαγής μεταξύ σταθερής και τυχαίας φάσης.



Σχήμα 5.8: Αριθμός επεισοδίων μέχρι τη σύγκλιση (80% της μέγιστης εξομαλυσμένης ανταμοιβής) για κάθε μέγεθος σμήνους με τη στρατηγική σταδιακής μάθησης.


μεγέθη $N \geq 6$ συγκλίνουν ταχύτερα (300–314 επεισόδια), με εξαίρεση το $N = 8$ που απαιτεί 593 επεισόδια.

Ποσοστό Επιτυχίας και Μετρικές Διαδρομής

Στο Σχήμα 5.9 παρουσιάζεται η συγκεντρωτική επισκόπηση όλων των μετρικών για τη στρατηγική σταδιακής μάθησης.

Σε αντίθεση με τη στρατηγική σταθερού περιβάλλοντος, το ποσοστό επιτυχίας στη σταδιακή μάθηση κυμαίνεται σε στενότερη ζώνη τιμών (48%–80%), με μέσο όρο περίπου 66%. Το χαμηλότερο σημείο παρατηρείται στο $N = 2$ (48%) και το υψηλότερο στο $N = 9$ (80%), ενώ ενδιάμεσα μεγέθη ($N \in \{3, 5, 7\}$) επιτυγχάνουν σταθερά 70%–76%. Οι μετρικές διαδρομής εμφανίζουν παρόμοιες τάσεις με τη

UAV Swarm Comparison (N= 2 to 10) · DQN Agent



Σχήμα 5.9: Συγκεντρωτική επισκόπηση των έξι κύριων μετρικών για τη στρατηγική σταδιακής μάθησης.

στρατηγική σταθερού περιβάλλοντος, με μήκος και ενέργεια να μειώνονται και ομαλότητα να βελτιώνεται καθώς αυξάνεται το μέγεθος του σμήνους.

5.4.3 Σύγκριση Στρατηγικών Εκπαίδευσης

Η ταυτόχρονη παρατήρηση των αποτελεσμάτων των δύο στρατηγικών αποκαλύπτει μια θεμελιώδη αντίθεση. Στον Πίνακα 5.1 συγκεντρώνονται οι κύριοι δείκτες ποσοτικής σύγκρισης.

Πίνακας 5.1: Συγκριτικοί δείκτες των δύο στρατηγικών εκπαίδευσης κατά μήκος όλων των μεγεθών σμήνους.

Δείκτης	Σταθερό Περιβάλλον	Σταδιακή Μάθηση
Εύρος ποσοστού επιτυχίας	29%–92%	48%–80%
Μέσος όρος επιτυχίας	~ 60%	~ 66%
Εύρος ομαλότητας (rad)	0.012–0.065	0.026–0.144
Εύρος ενεργειακού κόστους (rad)	1.0–5.0	2.2–11.6

Η στρατηγική σταθερού περιβάλλοντος παρουσιάζει χαμηλότερες τιμές ομαλότητας και ενέργειας σε σύγκριση με τη σταδιακή μάθηση, υποδηλώνοντας πιο ευθύγραμμες και αποδοτικές διαδρομές. Ωστόσο, η ίδια στρατηγική παρουσιάζει δραματικά μεγαλύτερη διακύμανση στο ποσοστό επιτυχίας μεταξύ διαφορετικών μεγεθών σμήνους. Ενδεικτικό είναι το γεγονός ότι σε ορισμένα μεγέθη ($N = 6, 7$) το ποσοστό επιτυχίας πέφτει σε 29–37%, ενώ σε άλλα ($N = 3$) φτάνει το 92%.

Η ερμηνεία της σύγκρισης απαιτεί προσοχή, καθώς οι δύο στρατηγικές δεν αξιολογήθηκαν κάτω από πανομοιότυπες συνθήκες. Οι πράκτορες σταθερού περιβάλλοντος αξιολογήθηκαν στην ίδια τοπολογία (seed=42) στην οποία εκπαιδεύτηκαν, οπότε οι μετρικές τους αποτυπώνουν απόδοση εντός κατανομής.

Οι πράκτορες σταδιακής μάθησης αξιολογήθηκαν σε εκατό άγνωστες τυχαίες τοπολογίες, οπότε οι μετρικές τους αποτυπώνουν γενίκευση εκτός κατανομής. Κάθε άμεση αντιπαραβολή των δύο στηλών του Πίνακα 5.1 οφείλει να λαμβάνει υπόψη αυτή τη διαφορά.

Υπό αυτό το πρίσμα, η εκπαίδευση σε σταθερή τοπολογία επιτρέπει στον πράκτορα να εξειδικευτεί στη συγκεκριμένη γεωμετρία και να τη διασχίζει με ελάχιστες αλλαγές κατεύθυνσης, γεγονός που εξηγεί τις χαμηλότερες τιμές ομαλότητας και ενέργειας. Η έντονη διακύμανση του ποσοστού επιτυχίας (29% έως 92%) δεν αποτυπώνει γενίκευση σε νέα περιβάλλοντα, αλλά τον βαθμό στον οποίο κάθε ξεχωριστά εκπαιδευμένος πράκτορας κατέκτησε τη μία σταθερή διάταξη, σε συνδυασμό με την ευθραυστότητα της πολυπρακτορικής εκπαίδευσης που αναλύεται στην Ενότητα 5.5.3.

Η σταδιακή μάθηση, εκθέτοντας τον πράκτορα σε ποικιλία τοπολογιών, παράγει πολιτικές χωρίς εξειδίκευση σε μη συγκεκριμένη διαδρομή, οι οποίες παρουσιάζουν σαφώς πιο ομοιόμορφη απόδοση σε άγνωστες τοπολογίες. Η υψηλότερη τιμή ομαλότητας και το αυξημένο ενεργειακό κόστος αποτελούν το τίμημα αυτής της προσαρμοστικότητας, καθώς ο πράκτορας εκτελεί περισσότερες διορθωτικές στροφές για να ανταποκριθεί σε μεταβαλλόμενες γεωμετρίες. Πρόκειται για έκφραση του κλασικού διλήμματος μεταξύ εξειδίκευσης και γενίκευσης στη Μηχανική Μάθηση [26].

Από πρακτική σκοπιά και με δεδομένο τον περιορισμό των διαφορετικών συνθηκών αξιολόγησης, οι δύο στρατηγικές εξυπηρετούν διαφορετικές ανάγκες. Όταν το περιβάλλον επιχειρησιακής χρήσης είναι γνωστό και σταθερό, η εξειδίκευση σε αυτό παράγει εξαιρετικά αποδοτικές διαδρομές. Όταν αναμένεται μεταβλητό ή άγνωστο περιβάλλον, η σταδιακή μάθηση είναι εκείνη της οποίας τα αναφερόμενα μεγέθη αντιστοιχούν πράγματι σε γενίκευση και παρέχει πιο αξιόπιστη και προβλέψιμη απόδοση εκτός κατανομής.


Στις επόμενες ενότητες, για την αξιολόγηση της γενίκευσης σε ποικίλα σενάρια εμποδίων, χρησιμοποιείται ο πράκτορας του βασικού σεναρίου ($N = 5$ από την Ενότητα 5.3), ο οποίος εκπαιδεύτηκε σε σταθερή τοπολογία (seed=42) και αξιολογείται σε ξεχωριστές, τυχαία παραγόμενες τοπολογίες. Η αξιολόγηση σε άγνωστα περιβάλλοντα παρέχει έτσι ένα ουσιαστικό μέτρο της ικανότητας γενίκευσης του εκπαιδευμένου πράκτορα.

5.5 Αξιολόγηση Εκπαιδευμένων Πρακτόρων

Στην παρούσα ενότητα παρουσιάζεται η συστηματική αξιολόγηση του εκπαιδευμένου πράκτορα σμήνους αναφοράς $N = 5$ (από την Ενότητα 5.3) σε τέσσερις διαφορετικούς άξονες ανάλυσης. Πρώτα εξετάζεται η συμπεριφορά του πράκτορα σε σενάρια με διαφορετικό αριθμό εμποδίων (4, 6 και 8). Στη συνέχεια διερευνάται η ικανότητα γενίκευσης σε εκτεταμένο εύρος πυκνότητας εμποδίων από 1 έως 10. Έπειτα παρουσιάζεται η σύγκριση μικρότερων μεγεθών σμήνους (3, 4, 5 UAV) και τέλος η συστηματική αντιπαράθεση μονού UAV με το σμήνος αναφοράς. Όλες οι αξιολογήσεις πραγματοποιήθηκαν με ντετερμινιστική επιλογή ενέργειας ($\epsilon = 0$) σε στοχαστικά παραγόμενες τοπολογίες ξεχωριστές από αυτές της εκπαίδευσης.

5.5.1 Επίδραση Αριθμού Εμποδίων (4, 6, 8)

Η πρώτη μελέτη αξιολογεί τη συμπεριφορά του εκπαιδευμένου πράκτορα σε τρία σενάρια αυξανόμενης πυκνότητας εμποδίων, 4, 6 και 8 εμπόδια στον ίδιο χώρο $[-50, 50]^2$. Κάθε σενάριο αξιολογήθηκε σε 300 ντετερμινιστικά επεισόδια. Στο Σχήμα 5.10 παρουσιάζεται η εξέλιξη του ποσοστού επιτυχίας με την αύξηση των εμποδίων, ενώ στο Σχήμα 5.11 συγκεντρώνονται όλες οι μετρικές απόδοσης σε χρωματικά



Σχήμα 5.10: Ποσοστό επιτυχίας του εκπαιδευμένου σμήνους $N = 5$ σε σενάρια με 4, 6 και 8 εμπόδια. Κάθε σημείο προκύπτει από 300 ντετερμινιστικά επεισόδια αξιολόγησης.

κωδικοποιημένο πίνακα.

Το ποσοστό επιτυχίας μειώνεται σταδιακά καθώς αυξάνεται η πυκνότητα εμποδίων, από 79.3% στα 4 εμπόδια, σε 75.3% στα 6, και σε 72.0% στα 8. Η μείωση αυτή είναι ήπια και μονοτονική, γεγονός που υποδηλώνει ότι ο πράκτορας αντιμετωπίζει συστηματικά την αυξανόμενη γεωμετρική δυσκολία χωρίς απότομες πτώσεις στη συμπεριφορά. Σημειώνεται ότι ο πράκτορας εκπαιδεύτηκε αποκλειστικά σε σενάριο με 8 εμπόδια, οπότε τα σενάρια με 4 και 6 εμπόδια αποτελούν δοκιμασίες γενίκευσης σε ευκολότερα περιβάλλοντα.


Παράλληλα, οι μετρικές διαδρομής παραμένουν αξιοσημείωτα σταθερές μεταξύ των τριών σεναρίων. Το μέσο μήκος διαδρομής κυμαίνεται μεταξύ 47.6 και 50.0 μονάδων, η ομαλότητα γύρω από τα 0.045 rad ανά βήμα και το ενεργειακό κόστος σταθερά κοντά στις 3.66 rad. Η σταθερότητα αυτή υποδηλώνει ότι όταν ο πράκτορας καταφέρνει να φτάσει στον στόχο, η ποιότητα της διαδρομής παραμένει υψηλή ανεξάρτητα από την πυκνότητα εμποδίων. Η μεταβλητότητα εκδηλώνεται αποκλειστικά μέσω του ποσοστού αποτυχημένων επεισοδίων και όχι μέσω υποβάθμισης της ποιότητας των επιτυχημένων διαδρομών.

5.5.2 Απόδοση για 1 έως 10 Εμπόδια


Για την εκτεταμένη αξιολόγηση της γενίκευσης, ο πράκτορας δοκιμάστηκε σε σενάρια με αριθμό εμποδίων που κυμαίνεται από 1 έως 10. Κάθε σενάριο αξιολογήθηκε σε 100 ντετερμινιστικά επεισόδια με ξεχωριστή τυχαία τοπολογία ανά επεισόδιο. Τα αποτελέσματα παρουσιάζονται στο Σχήμα 5.12.

Σε αραιά περιβάλλοντα με 1 έως 3 εμπόδια, ο πράκτορας επιτυγχάνει ποσοστά επιτυχίας άνω του 85%, με μέγιστο 92% στο σενάριο με ένα μόνο εμπόδιο. Στη ζώνη μεσαίας πυκνότητας (4 έως 8 εμπόδια), η απόδοση παραμένει σταθερή στο εύρος 72%–79%, συμβατή με τα ευρήματα της Ενότητας 5.5.1. Σε σενάρια μεγάλης πυκνότητας (9 και 10 εμπόδια), η απόδοση πέφτει σε 62% και 60% αντίστοιχα, υποδηλώνοντας τη γεωμετρική δυσκολία του προβλήματος όταν τα διαθέσιμα περάσματα μεταξύ εμποδίων στενεύουν δραστικά.

Από τη συνολική αυτή ανάλυση προκύπτουν δύο σημαντικά συμπεράσματα. Καταρχάς, ο πράκτορας παρουσιάζει αξιοσημείωτη ικανότητα γενίκευσης σε πυκνότερες εμποδίων διαφορετικές από αυτή της



Σχήμα 5.11: Θερμικός χάρτης κανονικοποιημένων μετρικών απόδοσης για τα τρία σενάρια εμποδίων. Πράσινες αποχρώσεις υποδηλώνουν καλύτερη απόδοση ανά γραμμή. Οι μετρικές 1/Path, 1/Smooth και 1/Energy απεικονίζονται ως αντίστροφες ώστε οι υψηλότερες τιμές να αντιστοιχούν πάντα σε καλύτερη απόδοση.




Σχήμα 5.12: Ποσοστό επιτυχίας του εκπαιδευμένου σμήνους $N = 5$ σε σενάρια με αυξανόμενο αριθμό εμποδίων από 1 έως 10. Κάθε σημείο προκύπτει από 100 ντετερμινιστικά επεισόδια αξιολόγησης σε στοχαστικά παραγόμενα περιβάλλοντα.


εκπαίδευσης (8 εμπόδια), χωρίς δραστική κατάρρευση απόδοσης. Επιπροσθέτως, η σταδιακή μείωση του ποσοστού επιτυχίας με την αύξηση των εμποδίων είναι συνεπής με την αυξανόμενη δυσκολία του προβλήματος και αντικατοπτρίζει τους εγγενείς γεωμετρικούς περιορισμούς του χώρου, παρά κάποια αδυναμία της πολιτικής του πράκτορα.

5.5.3 Σύγκριση Μεγεθών Σμήνους (3, 4, 5 UAV)

Η τρίτη μελέτη συγκρίνει την απόδοση σμήνων μικρού μεγέθους, με 3, 4 και 5 UAV, σε σενάριο με 4 εμπόδια. Σε αντίθεση με τη μελέτη της Ενότητας 5.4 όπου οι πράκτορες προήλθαν από ενιαία σαρωτική εκπαίδευση, στην παρούσα σύγκριση οι πράκτορες $N = 3$ και $N = 4$ εκπαιδεύτηκαν ξεχωριστά με το πρωτόκολλο `train_all_swarm_sizes.py` για 400 επεισόδια ανά μέγεθος, ενώ ο πράκτορας $N = 5$ ταυτίζεται με εκείνον του βασικού σεναρίου της Ενότητας 5.3. Κάθε διαμόρφωση αξιολογήθηκε σε 200 ντετερμινιστικά επεισόδια. Τα αποτελέσματα παρουσιάζονται στο Σχήμα 5.13, ενώ οι αντίστοιχες καμπύλες εκπαίδευσης των πρακτόρων $N = 3$ και $N = 4$ απεικονίζονται στο Σχήμα 5.14.



Σχήμα 5.13: Σύγκριση τεσσάρων μετρικών απόδοσης μεταξύ σμήνων 3, 4 και 5 UAV σε σενάριο με 4 εμπόδια. Από αριστερά προς τα δεξιά: ποσοστό επιτυχίας, μήκος διαδρομής, ομαλότητα και ενεργειακό κόστος. Κάθε μέγεθος αντιστοιχεί σε ξεχωριστά εκπαιδευμένο πράκτορα.



Σχήμα 5.14: Καμπύλες σύγκλισης εκπαίδευσης για τους πράκτορες $N = 3$ (αριστερά) και $N = 4$ (δεξιά). Παρατηρούνται έντονες διαταραχές κατά τη διάρκεια της εκπαίδευσης, ιδιαίτερα στις περιπτώσεις μερικής αποσταθεροποίησης που χαρακτηρίζουν την πολυπρακτορική Q-Learning.

Τα αποτελέσματα παρουσιάζουν μη μονοτονική συμπεριφορά ως προς το μέγεθος. Το σμήνος των 3 UAV επιτυγχάνει 71% ποσοστό επιτυχίας, ενώ το αμέσως μεγαλύτερο των 4 UAV πέφτει στο 59.5%. Το σμήνος των 5 UAV, που αποτελεί το βασικό σενάριο εκπαίδευσης, ανακάμπτει στο 79.5%, το υψηλότερο από τα τρία. Η ίδια μη μονοτονικότητα εμφανίζεται και στις υπόλοιπες μετρικές. Το μήκος διαδρομής ακολουθεί την ίδια τάση (54.3, 62.3, 51.9 μονάδες), ενώ η ομαλότητα και το ενεργειακό κόστος εμφανίζουν επιδείνωση στο $N = 4$ (0.097 rad/βήμα και 8.1 μονάδες αντίστοιχα), σαφώς υψηλότερα από τις τιμές των $N = 3$ και $N = 5$.

Η εξήγηση αυτής της μη μονοτονικής συμπεριφοράς ανιχνεύεται στις καμπύλες εκπαίδευσης του Σχήματος 5.14. Ο πράκτορας $N = 3$ παρουσιάζει έντονη αποσταθεροποίηση γύρω από τα επεισόδια 100–130, με την ανταμοιβή να πέφτει προσωρινά κάτω από -40000 μονάδες. Ωστόσο, η εκπαίδευση ανακάμπτει πλήρως μέχρι το επεισόδιο ~ 150 και η πολιτική σταθεροποιείται έως το τέλος. Αντίθετα, ο πράκτορας $N = 4$ διατηρεί σταθερή σύγκλιση κατά μήκος όλης της εκπαίδευσης, αλλά παρουσιάζει απότομη πτώση στα τελευταία επεισόδια (γύρω από το 390), με την ανταμοιβή να καταρρέει σε τιμές κάτω των -20000 . Το πρωτόκολλο εκπαίδευσης αποθηκεύει το μοντέλο με την υψηλότερη ανταμοιβή

επεισοδίου, επομένως το αποθηκευμένο δίκτυο του $N = 4$ δεν αντιστοιχεί στη διαταραγμένη τελική κατάσταση αλλά σε ένα ενδιάμεσο σημείο πριν την κατάρρευση. Η χαμηλότερη απόδοση του $N = 4$ κατά την αξιολόγηση δεν οφείλεται συνεπώς στην τελική αυτή διαταραχή, αλλά στο ότι η συγκεκριμένη πολιτική, βέλτιστη ως προς την ανταμοιβή εκπαίδευσης στη σταθερή τοπολογία, γενικεύει λιγότερο ομοιόμορφα στις τυχαίες τοπολογίες αξιολόγησης σε σχέση με τους πράκτορες $N = 3$ και $N = 5$.

Το εύρημα αυτό αναδεικνύει μια χαρακτηριστική αδυναμία της εκπαίδευσης DQN σε πολυπρακτορικά περιβάλλοντα. Η μη στατικότητα της κατανομής μεταβάσεων, λόγω της ταυτόχρονης μάθησης από πολλαπλούς πράκτορες με κοινή πολιτική, μπορεί να οδηγήσει σε ξαφνική διαταραχή ακόμη και μετά από παρατεταμένη περίοδο σύγκλισης [5]. Η επιλογή του αποθηκευμένου μοντέλου με βάση την απόδοση σε ανεξάρτητο σύνολο τυχαίων τοπολογιών επικύρωσης, αντί της ανταμοιβής εκπαίδευσης στη σταθερή τοπολογία, θα μπορούσε να μετριάσει τέτοιες περιπτώσεις και αποτελεί κατεύθυνση μελλοντικής βελτίωσης.

Ανεξάρτητα από αυτή την επιπλοκή, η συστηματική σύγκριση επιβεβαιώνει ότι ο πράκτορας $N = 5$ αναπτύσσει την πιο ισορροπημένη και ομαλή πολιτική για το συγκεκριμένο πρόβλημα πολυπρακτορικής πλοήγησης σε στατικά εμπόδια.

5.5.4 Σύγκριση Single UAV vs Swarm

Η τελευταία σύγκριση αντιπαραθέτει τον πράκτορα μονού UAV (από την Ενότητα 5.2) με το σμήνος αναφοράς $N = 5$ ως προς τέσσερις μετρικές απόδοσης. Και οι δύο πράκτορες αξιολογήθηκαν σε σενάριο με 4 εμπόδια και 200 ντετερμινιστικά επεισόδια. Τα αποτελέσματα παρουσιάζονται στο Σχήμα 5.15.

Το σμήνος επιτυγχάνει συστηματικά καλύτερες τιμές και στις τέσσερις μετρικές. Το ποσοστό επιτυχίας ανέρχεται σε 79.5% έναντι 55.5% του μονού πράκτορα, διαφορά που υπερβαίνει τις 20 ποσοστιαίες μονάδες. Παρομοίως, το μέσο μήκος διαδρομής μειώνεται από 114.5 μονάδες στο μονό πράκτορα σε 51.9 μονάδες στο σμήνος, ενώ η ομαλότητα βελτιώνεται από 0.16 σε 0.05 rad/βήμα και το ενεργειακό κόστος από 12.4 σε 3.8 μονάδες.


Αυτό το εύρημα απαιτεί προσεκτική και πολυεπίπεδη ερμηνεία. Καταρχάς, η αυξημένη επιτυχία του σμήνους οφείλεται σε σημαντικό βαθμό στον ορισμό της μετρικής. Όπως αναλύθηκε στην Ενότητα 5.1.4, ένα επεισόδιο σμήνους θεωρείται επιτυχημένο όταν τουλάχιστον ένας από τους πέντε πράκτορες φτάσει στον στόχο. Με πέντε ανεξάρτητες ευκαιρίες έναντι της μίας του μονού πράκτορα, το σμήνος έχει εκ κατασκευής στατιστικό πλεονέκτημα στην καταγραφόμενη επιτυχία.

Όσον αφορά τις μετρικές διαδρομής, η ερμηνεία χρειάζεται προσοχή. Το μήκος και η ομαλότητα της διαδρομής του σμήνους υπολογίζονται για το κεντροειδές, που εμφανίζει εγγενή στατιστική εξομάλυνση. Η σύγκριση επομένως δεν αποδεικνύει ότι οι ατομικοί πράκτορες του σμήνους εκτελούν ποιοτικά καλύτερες διαδρομές, αλλά ότι η συλλογική κίνηση μετρημένη μέσω κεντροειδούς εμφανίζει πιο ευθύγραμμη και ομαλή συμπεριφορά.

Η μείωση του ενεργειακού κόστους από 12.4 σε 3.8 μονάδες (69% μείωση) είναι αξιοσημείωτη και αξίζει ξεχωριστής συζήτησης. Παρότι ένα μέρος της οφείλεται στη στατιστική εξομάλυνση, η συνολική μείωση είναι αρκετά μεγάλη ώστε να υποδηλώνει ουσιαστικό λειτουργικό πλεονέκτημα της συλλογικής προσέγγισης σε επίπεδο συνολικού λειτουργικού κόστους. Σε πρακτικά σενάρια αποστολής όπου η ενεργειακή κατανάλωση αποτελεί κρίσιμο περιορισμό, η συλλογική πλοήγηση σμήνους μπορεί να υπερισχύει της μονής πλοήγησης ακόμη και αν η ατομική απόδοση κάθε μέλους δεν είναι βέλτιστη.

Συμπερασματικά, η σύγκριση αναδεικνύει ότι το σμήνος προσφέρει στατιστικά πλεονεκτήματα τόσο στην ολοκλήρωση αποστολής όσο και στη συλλογική ποιότητα κίνησης, με τα ακριβή ποσοτικά οφέλη

DQN Performance: Single UAV vs 5-UAV Swarm



Σχήμα 5.15: Σύγκριση τεσσάρων μετρικών απόδοσης μεταξύ μονού UAV και σμήνους $N = 5$. Πάνω αριστερά: ποσοστό επιτυχίας. Πάνω δεξιά: μέσο μήκος διαδρομής. Κάτω αριστερά: μέση ομαλότητα. Κάτω δεξιά: ενεργειακό κόστος.

να εξαρτώνται από τον ορισμό επιτυχίας και τη μετρική αναφοράς.

ΚΕΦΑΛΑΙΟ 6: Συμπεράσματα και Μελλοντική Έρευνα

Στο παρόν κλείνον κεφάλαιο συνοψίζονται η συνολική συνεισφορά της εργασίας, αναλύονται τα κύρια ευρήματα που προέκυψαν από την πειραματική μελέτη, αναγνωρίζονται ρητά οι περιορισμοί του προτεινόμενου συστήματος και προτείνονται κατευθύνσεις για περαιτέρω έρευνα. Η ενότητα αυτή λειτουργεί τόσο ως αναστοχασμός επί της πορείας υλοποίησης όσο και ως βάση για μελλοντικές επεκτάσεις και προσεγγίσεις.

6.1 Σύνοψη Εργασίας

Η παρούσα διπλωματική εργασία ανέπτυξε ένα ολοκληρωμένο σύστημα σχεδιασμού διαδρομής και αποφυγής εμποδίων για σμήνη μη επανδρωμένων εναέριων οχημάτων, βασισμένο σε τεχνικές βαθιάς ενισχυτικής μάθησης. Συγκεκριμένα, υλοποιήθηκε από την αρχή σε καθαρή NumPy ένας πράκτορας Double DQN με τέσσερις βασικές συνιστώσες αλγοριθμικής ευστάθειας, στόχο-δίκτυο, ζώνη επανάληψης εμπειρίας, συνάρτηση κόστους Huber με αποκοπή παραγώγου και αρχικοποίηση He [23] με βελτιστοποίηση Adam [24]. Η επιλογή μηδενικής εξάρτησης από βιβλιοθήκες υψηλού επιπέδου επέτρεψε πλήρη διαφάνεια του αλγορίθμου και ακριβή έλεγχο όλων των αριθμητικών λεπτομερειών.

Παράλληλα, σχεδιάστηκαν δύο περιβάλλοντα προσομοίωσης, ένα μονού UAV με ντετερμινιστικά αλλά στοχαστικά παραγόμενα στατικά εμπόδια και ένα συνεργατικό σμήνους με κοινή πολιτική και ζώνη επανάληψης μεταξύ όλων των πρακτόρων. Για το σενάριο σμήνους αναπτύχθηκε ξεχωριστή συνάρτηση διαμόρφωσης ανταμοιβής (SwarmRewardShaper) που υλοποιεί τις τρεις θεμελιώδεις αρχές του μοντέλου boids του Reynolds [7], τη συνοχή, το διαχωρισμό και την ευθυγράμμιση. Η διαμόρφωση αυτή λειτουργεί ως πρόσθετο σήμα ανταμοιβής πάνω από την υποκείμενη πολιτική πλοήγησης του μονού UAV, χωρίς να αλλάζει τη βασική αρχιτεκτονική του πράκτορα.

Η αξιολόγηση του συστήματος πραγματοποιήθηκε σε τέσσερις άξονες, τη σύγκλιση εκπαίδευσης σε μονό και συλλογικό περιβάλλον, την επίδραση του μεγέθους σμήνους από $N = 2$ έως $N = 10$ με δύο διακριτές στρατηγικές εκπαίδευσης, ευρωστία του βασικού σμήνους σε σενάρια διαφορετικής πυκνότητας εμποδίων και τη συγκριτική ανάλυση μονής έναντι συλλογικής πλοήγησης.

6.2 Κύρια Συμπεράσματα και Συνεισφορά

Από την πειραματική μελέτη προκύπτουν αρκετά συμπεράσματα που αξίζει να σχολιαστούν ξεχωριστά, καθώς αφορούν τόσο τη βασική ικανότητα του προτεινόμενου συστήματος όσο και ευρύτερα ζητήματα μεθοδολογίας στη βαθιά πολυπρακτορική ενισχυτική μάθηση.

6.2.1 Επεκτασιμότητα της Κοινής Πολιτικής

Η αρχιτεκτονική κοινής πολιτικής (parameter sharing) απέδειξε ικανότητα λειτουργίας σε ευρύ φάσμα μεγεθών σμήνους, από ζεύγη πρακτόρων έως δεκαμελή σύνολα, χωρίς δραστική κατάρρευση της απόδοσης. Ωστόσο, τα ευρήματα αναδεικνύουν ότι η επεκτασιμότητα αυτή δεν είναι ομοιόμορφη. Σμήνη ακραίων μεγεθών παρουσιάζουν συστηματικά μειωμένη απόδοση, με το $N = 2$ να δυσκολεύεται λόγω

αδυναμίας ανάδυσης συλλογικής συμπεριφοράς και το $N = 10$ να υποφέρει από αυξημένη συμφύρση στην περιοχή εκκίνησης. Η περιοχή $N \in \{5, 7, 8, 9\}$ προσφέρει την πιο ισορροπημένη συμπεριφορά, εύρημα συμβατό με παρατηρήσεις της βιβλιογραφίας για τυπικά μεγέθη σμηνών αυτοοργάνωσης [15].

6.2.2 Δίλημμα Εξειδίκευσης - Γενίκευσης στην Εκπαίδευση

Η σύγκριση μεταξύ των δύο στρατηγικών εκπαίδευσης, σταθερού περιβάλλοντος και σταδιακής μάθησης, αναδεικνύει μια θεμελιώδη μεθοδολογική απόφαση που πρέπει να λαμβάνεται κατά τον σχεδιασμό συστημάτων ενισχυτικής μάθησης. Η εκπαίδευση σε σταθερή τοπολογία οδηγεί σε εξειδικευμένες πολιτικές με εξαιρετική ποιότητα διαδρομής, που παρουσιάζουν δραματική διακύμανση επιτυχίας (29% έως 92%) ανά μέγεθος σμηνούς. Αντίθετα, η σταδιακή μάθηση, αξιολογούμενη σε άγνωστες τοπολογίες παράγει πιο ομοιόμορφες αλλά λιγότερο εξειδικευμένες πολιτικές, με χαμηλότερη ποιότητα διαδρομής αλλά μικρότερη ζώνη επιτυχίας (48% έως 80%). Δεδομένου ότι οι δύο στρατηγικές αξιολογήθηκαν κάτω από διαφορετικές συνθήκες, η σύγκριση είναι ποιοτική και όχι αυστηρή αντιστοίχιση. Το κλασικό δίλημμα μεταξύ εξειδίκευσης και γενίκευσης [26] παραμένει εμφανές και η σωστή επιλογή εξαρτάται από τη φύση του τελικού επιχειρησιακού σεναρίου.

6.2.3 Ευθραυστότητα της Πολυπρακτορικής Q-Learning

Η σύγκριση των πρακτόρων $N = 3$ και $N = 4$ ανέδειξε ένα ανησυχητικό φαινόμενο που χαρακτηρίζει την πολυπρακτορική Q-Learning, την πιθανότητα απότομης αποσταθεροποίησης μετά από παρατεταμένη περίοδο σύγκλισης. Ο πράκτορας $N = 4$ παρουσίασε ξαφνική πτώση ανταμοιβής στα τελευταία επεισόδια εκπαίδευσης. Αν και το πρωτόκολλο διατηρεί το μοντέλο με την υψηλότερη ανταμοιβή και όχι το διαταραγμένο τελικό, το φαινόμενο αυτό υπογραμμίζει την αστάθεια της πολυπρακτορικής εκπαίδευσης και την ανάγκη επιλογής μοντέλου με κριτήριο τη γενίκευση. Το φαινόμενο αυτό οφείλεται στη μη στατικότητα της κατανομής μεταβάσεων που χαρακτηρίζει τα πολυπρακτορικά περιβάλλοντα, όπου πολλαπλοί πράκτορες μαθαίνουν ταυτόχρονα και η συμπεριφορά κάθε ενός μεταβάλλει την κατανομή εμπειριών των υπολοίπων [5]. Η παρατήρηση αυτή υπογραμμίζει την ανάγκη για μηχανισμούς ασφαλείας κατά την εκπαίδευση πολυπρακτορικών συστημάτων.

6.2.4 Στατιστική Φύση της Συλλογικής Επιτυχίας

Ίσως το σημαντικότερο μεθοδολογικό συμπέρασμα της εργασίας αφορά τον τρόπο μέτρησης της απόδοσης σε πολυπρακτορικά συστήματα. Η σύγκριση μονού UAV με σμήνος $N = 5$ έδειξε ότι το σμήνος επιτυγχάνει συστηματικά καλύτερα αποτελέσματα σε όλες τις μετρικές. Ωστόσο, μια πιο προσεκτική ανάλυση αποκαλύπτει ότι αυτή η ανωτερότητα προέρχεται σε σημαντικό βαθμό από στατιστικά τεχνικά χαρακτηριστικά παρά από ουσιαστική ανωτερότητα της συλλογικής στρατηγικής. Καταρχάς, ο ασθενής ορισμός της επιτυχίας που υιοθετήθηκε, σύμφωνα με τον οποίο αρκεί ένας πράκτορας να φτάσει στον στόχο, προσφέρει στο σμήνος δομικό πλεονέκτημα πέντε ευκαιριών έναντι της μίας του μονού πράκτορα. Επιπλέον, οι μετρικές διαδρομής υπολογίζονται για το κεντροειδές του σμήνους, που εμφανίζει εγγενή στατιστική εξομάλυνση μέσου όρου. Η ρητή αναγνώριση αυτών των τεχνικών χαρακτηριστικών αποτελεί απαραίτητη προϋπόθεση για ειλικρινή αξιολόγηση σμηνών και ίσως είναι η πιο πρακτικά χρήσιμη παρατήρηση της εργασίας.

6.3 Περιορισμοί

Η ειλικρινής αναγνώριση των περιορισμών αποτελεί κρίσιμη συνιστώσα κάθε ερευνητικής εργασίας. Στις επόμενες παραγράφους αναλύονται οι κύριες αδυναμίες του παρόντος συστήματος.

6.3.1 Στατικά Εμπόδια

Το προτεινόμενο σύστημα έχει σχεδιαστεί και αξιολογηθεί αποκλειστικά σε περιβάλλοντα με στατικά εμπόδια. Σε ρεαλιστικά σενάρια αποστολής, το περιβάλλον μπορεί να περιλαμβάνει κινούμενα εμπόδια όπως άλλα οχήματα, ζώα ή ανθρώπους. Η επέκταση του πράκτορα σε δυναμικά περιβάλλοντα θα απαιτούσε εμπλουτισμό του χώρου παρατήρησης με πληροφορίες σχετικής ταχύτητας και πιθανώς αναδρομικά νευρωνικά δίκτυα για εκτίμηση μελλοντικών τροχιών εμποδίων.

6.3.2 Δισδιάστατος Χώρος

Η προσομοίωση πραγματοποιείται σε δισδιάστατο χώρο, ενώ τα πραγματικά UAV κινούνται σε τρεις διαστάσεις. Η επέκταση σε τρισδιάστατο χώρο θα αύξανε σημαντικά την πολυπλοκότητα του χώρου ενεργειών, αν και η θεμελιώδης λογική αποφυγής εμποδίων και συλλογικής συμπεριφοράς θα παρέμενε ίδια.

6.3.3 Διακριτός Χώρος Ενεργειών

Η χρήση DQN επιβάλλει διακριτό χώρο ενεργειών, στην παρούσα υλοποίηση, περιορισμένο σε πέντε γωνίες στροφής. Τα πραγματικά UAV έχουν συνεχή έλεγχο τόσο της κατεύθυνσης όσο και της ταχύτητας. Η μετάβαση σε συνεχή έλεγχο θα απαιτούσε αλγορίθμους όπως Deep Deterministic Policy Gradient (DDPG) ή Soft Actor-Critic (SAC).

6.3.4 Ασθενής Ορισμός Επιτυχίας

Όπως αναπτύχθηκε στην Ενότητα 5.1.4, η εργασία υιοθέτησε τον ασθενή ορισμό επιτυχίας σύμφωνα με τον οποίο αρκεί ένα πράκτορας να φτάσει στον στόχο. Σε αποστολές όπου απαιτείται η ταυτόχρονη άφιξη όλων των μελών του σμήνους, όπως συντονισμένη παράδοση φορτίου ή σχηματισμένη πτήση, ο παρών πράκτορας δεν θα ήταν άμεσα κατάλληλος και θα απαιτούσε επανεκπαίδευση με κατάλληλα τροποποιημένη συνάρτηση ανταμοιβής.

6.3.5 Διαφορετικές Συνθήκες Αξιολόγησης στη Σύγκριση Στρατηγικών

Η σύγκριση μεταξύ των στρατηγικών σταθερού περιβάλλοντος και σταδιακής μάθησης (Ενότητα 5.4) υπόκειται σε έναν ουσιώδη μεθοδολογικό περιορισμό. Οι πράκτορες της στρατηγικής σταθερού περιβάλλοντος αξιολογήθηκαν στην ίδια τοπολογία (seed=42) στην οποία είχαν εκπαιδευτεί, με μόνη πηγή στοχαστικότητας τις αρχικές θέσεις γέννησης, ενώ οι πράκτορες της σταδιακής μάθησης αξιολογήθηκαν σε εκατό άγνωστες, τυχαία παραγόμενες τοπολογίες. Ως εκ τούτου, τα δύο σύνολα μετρικών δεν έχουν αυστηρή αντιστοίχιση, το πρώτο αποτυπώνει απόδοση εντός κατανομής και το δεύτερο γενίκευση εκτός κατανομής. Η συνέπεια αυτής της ασυμμετρίας είναι ότι η έντονη διακύμανση του ποσοστού επιτυχίας που παρατηρήθηκε στη στρατηγική σταθερού περιβάλλοντος (29% έως 92%) δεν πρέπει να ερμηνεύεται ως μέτρο γενίκευσης, αλλά ως ένδειξη του βαθμού στον οποίο κάθε ξεχωριστά εκπαιδευμένος πράκτο-

ρας κατέκτησε τη μία σταθερή διάταξη. Αντίστοιχα, η φαινομενική υπεροχή της στρατηγικής σταθερού περιβάλλοντος ως προς την ομαλότητα και το ενεργειακό κόστος ευνοείται από το γεγονός ότι αξιολογείται σε γνωστό περιβάλλον. Μια αυστηρά δίκαιη σύγκριση θα απαιτούσε την αξιολόγηση αμφοτέρων των στρατηγικών στο ίδιο σύνολο άγνωστων τοπολογιών και αποτελεί προφανή κατεύθυνση για μελλοντική επανάληψη των πειραμάτων. Το ποιοτικό συμπέρασμα, ότι η εκπαίδευση σε σταθερή τοπολογία ευνοεί την εξειδίκευση ενώ η σταδιακή μάθηση ευνοεί την γενίκευση, παραμένει βάσιμο, ωστόσο τα ακριβή ποσοτικά μεγέθη της σύγκρισης πρέπει να ερμηνεύονται υπό το πρίσμα αυτού του περιορισμού.

6.3.6 Απουσία Αβεβαιότητας Αισθητήρων

Στην παρούσα προσομοίωση, οι αισθητήρες των πρακτόρων παρέχουν ακριβείς μετρήσεις απόστασης. Στον φυσικό κόσμο, οι μετρήσεις υπόκεινται σε θόρυβο, διάφορες πηγές σφάλματος και περιστασιακές αστοχίες. Η ευρωστία του πράκτορα σε τέτοιες αβεβαιότητες παραμένει ανοικτό ζήτημα.

6.4 Προτάσεις για Μελλοντική Έρευνα

Με βάση τα ευρήματα και τους περιορισμούς που αναλύθηκαν, προτείνονται οι ακόλουθες κατευθύνσεις για μελλοντική έρευνα και ανάπτυξη.

6.4.1 Συνεχής Έλεγχος και Σύγχρονοι Αλγόριθμοι

Η μετάβαση από το DQN σε αλγορίθμους συνεχούς ελέγχου όπως DDPG ή SAC θα επέτρεπε πιο ρεαλιστική μοντελοποίηση της κίνησης UAV με συνεχείς γωνίες στροφής και μεταβλητή ταχύτητα. Επιπλέον, σύγχρονοι αλγόριθμοι πολυπρακτορικής ενισχυτικής μάθησης όπως MAPPO [27] ή QMIX [28] ενδέχεται να προσφέρουν καλύτερη ευστάθεια εκπαίδευσης από την απλή επέκταση DQN με κοινή πολιτική.

6.4.2 Δυναμικά και Τρισδιάστατα Περιβάλλοντα

Η επέκταση του περιβάλλοντος σε τρεις διαστάσεις και η συμπερίληψη κινούμενων εμποδίων θα αυξήσει σημαντικά την πρακτική χρησιμότητα του συστήματος. Η μετάβαση αυτή απαιτεί προσεκτικό σχεδιασμό του χώρου παρατήρησης ώστε να συμπεριλάβει χρονικά εξαρτημένες πληροφορίες, ενδεχομένως μέσω αναδρομικών στρωμάτων ή μηχανισμών προσοχής (attention)

6.4.3 Ετερογενή Σμήνη

Η παρούσα υλοποίηση υποθέτει πανομοιότυπους πράκτορες με κοινή πολιτική. Σε ρεαλιστικά σενάρια αποστολής, ένα σμήνος μπορεί να αποτελείται από UAV διαφορετικών ικανοτήτων, ρόλων ή προσανατολισμών. Η επέκταση σε ετερογενή σμήνη απαιτεί διαφοροποίηση της αρχιτεκτονικής, είτε μέσω επιπλέον διανυσμάτων role embedding εισόδου, είτε μέσω πολλαπλών εξειδικευμένων πολιτικών.

6.4.4 Ισχυρότεροι Ορισμοί Επιτυχίας

Η συστηματική αξιολόγηση κάτω από τον ισχυρό ορισμό επιτυχίας, σύμφωνα με τον οποίο όλοι οι πράκτορες πρέπει να φτάσουν στον στόχο, θα παρείχε μια πιο αυστηρή μέτρηση της συλλογικής ικανότητας. Παράλληλα, η μελέτη ποσοτικών ορισμών, όπως ποσοστό άφιξης άνω ενός ορίου, θα ανα-

δείχνει ενδιαμέσες περιπτώσεις χρήσιμες σε διαφορετικά σενάρια αποστολής. Παράλληλα, η επανάληψη της σύγκρισης στρατηγικών εκπαίδευσης κάτω από κοινό σύνολο άγνωστων τοπολογιών αξιολόγησης θα επέτρεπε αυστηρά αντιστοιχισμένη μέτρηση του διλήμματος εξειδίκευσης-γενίκευσης.

6.4.5 Πραγματική Ανάπτυξη και Sim-to-Real

Το πιο φιλόδοξο επόμενο βήμα είναι η μεταφορά της εκπαιδευμένης πολιτικής σε πραγματικά UAV. Αυτό θα απαιτούσε αντιμετώπιση του προβλήματος sim-to-real transfer, με τεχνικές όπως domain randomization [29] κατά την εκπαίδευση, ώστε ο πράκτορας να γενικεύσει σε φυσικούς αισθητήρες και ενεργοποιητές. Η συνεχής μάθηση (continual learning) και η ικανότητα εξήγησης των αποφάσεων (Explainable AI) θα ήταν επίσης σημαντικές για κρίσιμες αποστολές ασφαλείας.

6.4.6 Σύγκριση με Μη Μαθησιακές Μεθόδους

Τέλος, μια ολοκληρωμένη συγκριτική μελέτη του προτεινόμενου DQN πράκτορα με κλασικές μη μαθησιακές μεθόδους σχεδιασμού διαδρομής όπως A*, RRT, ή Artificial Potential Fields, θα καθόριζε την προστιθέμενη αξία της προσέγγισης ενισχυτικής μάθησης. Σε στατικά γνωστά περιβάλλοντα, οι κλασικές μέθοδοι έχουν δοκιμασμένη αποτελεσματικότητα, οπότε η ενισχυτική μάθηση αποκτά πραγματικό πλεονέκτημα κυρίως σε δυναμικά ή μερικώς γνωστά περιβάλλοντα.

6.5 Επίλογος

Συνοψίζοντας, η παρούσα εργασία ανέπτυξε και αξιολόγησε ένα σύστημα συλλογικής πλοήγησης μη επανδρωμένων εναέριων οχημάτων βασισμένο σε βαθιά ενισχυτική μάθηση. Πέρα από την τεχνική υλοποίηση, ωστόσο, η εμπειρία της εκπόνησης ανέδειξε δύο ευρύτερες παρατηρήσεις που αξίζει να σχολιαστούν. Πρώτον, η εκπαίδευση πολυπρακτορικών συστημάτων ενισχυτικής μάθησης εμπεριέχει σαφώς υψηλότερο βαθμό ευθραυστότητας από το αντίστοιχο μονοπρακτορικό πρόβλημα και απαιτεί προσεκτική παρακολούθηση και μηχανισμούς ασφαλείας κατά την εκπαίδευση. Δεύτερον, η αξιολόγηση τέτοιων συστημάτων επιδέχεται ποικιλία ορισμών επιτυχίας, μετρικών και συνθηκών δοκιμής, οι οποίοι μπορούν να οδηγήσουν σε δραστικά διαφορετικά συμπεράσματα ως προς την απόδοση. Η ρητή και ειλικρινής αναγνώριση αυτών των μεθοδολογικών επιλογών είναι απαραίτητη για κάθε σοβαρή έρευνα στον τομέα και αποτέλεσε σταθερή φιλοσοφία της παρούσας εργασίας.

Bibliography

- [1] I. A. Bartsiokas, C. Ntakolia, G. Avdikos, and D. Lyridis, “Intelligent multi-objective path planning for unmanned surface vehicles via deep and fuzzy reinforcement learning,” *Journal of Marine Science and Engineering*, 2025. Under review.
- [2] Ιάκωβος Στ. Βενιέρης, Δημήτρα-Θεοδώρα Ι. Κακλαμάνη, Εμμανουήλ Α. Βαρβαρίγος, and Αθανάσιος Δ. Παναγόπουλος, *KINHOTOS YΠΟΛΟΓΙΣΜΟΣΣ ΚΑΙ ΜΗΧΑΝΙΚΗ ΜΑΘΗΣΗ*. Θεσσαλονίκη: ΕΚΔΟΣΕΙΣ ΤΖΙΟΛΑ, 2024.
- [3] X. Zhou, P. Wu, H. Zhang, W. Guo, and Y. Liu, “Learn to navigate: Cooperative path planning for unmanned surface vehicles using deep reinforcement learning,” *IEEE Access*, vol. 7, pp. 165262–165278, 2019.
- [4] B. Xing, X. Wang, L. Yang, Z. Liu, and Q. Wu, “An algorithm of complete coverage path planning for unmanned surface vehicle based on reinforcement learning,” *Journal of Marine Science and Engineering*, vol. 11, no. 3, p. 645, 2023.
- [5] S. Nantogma, S. Zhang, X. Yu, X. An, and Y. Xu, “Multi-USV dynamic navigation and target capture: A guided multi-agent reinforcement learning approach,” *Electronics*, vol. 12, no. 7, p. 1523, 2023.
- [6] S. Aggarwal and N. Kumar, “Path planning techniques for unmanned aerial vehicles: A review, solutions, and challenges,” *Computer Communications*, vol. 149, pp. 270–299, 2020.
- [7] C. W. Reynolds, “Flocks, herds and schools: A distributed behavioral model,” in *Proceedings of the 14th Annual Conference on Computer Graphics and Interactive Techniques (SIGGRAPH ’87)*, pp. 25–34, ACM, 1987.
- [8] C. Ntakolia, K. Platanitis, G. Kladis, C. Skliros, and A. Zagorianos, “A genetic algorithm enhanced with fuzzy-logic for multi-objective unmanned aircraft vehicle path planning missions,” in *2022 International Conference on Unmanned Aircraft Systems (ICUAS)*, pp. 114–123, 2022.
- [9] V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, S. Petersen, C. Beattie, A. Sadik, I. Antonoglou, H. King, D. Kumaran, D. Wierstra, S. Legg, and D. Hassabis, “Human-level control through deep reinforcement learning,” *Nature*, vol. 518, pp. 529–533, 2015.
- [10] I. A. Bartsiokas, *Machine and Deep Learning Algorithms for Radio Resource Management in 5G and Beyond Networks*. PhD thesis, National Technical University of Athens, 2023. PhD Thesis.
- [11] T. Qu, G. Xiong, H. Ali, X. Dong, Y. Han, and Z. Shen, “USV path planning under marine environment simulation using DWA and safe reinforcement learning,” in *2023 IEEE 19th International Conference on Automation Science and Engineering (CASE)*, pp. 1–6, 2023.

- [12] C. Yan, X. Xiang, and C. Wang, “Towards real-time path planning through deep reinforcement learning for a UAV in dynamic environments,” *Journal of Intelligent & Robotic Systems*, vol. 98, no. 2, pp. 297–309, 2020.
- [13] H. van Hasselt, A. Guez, and D. Silver, “Deep reinforcement learning with double Q-learning,” in *Proceedings of the 30th AAAI Conference on Artificial Intelligence (AAAI)*, pp. 2094–2100, 2016.
- [14] B. Zhou, B. Huang, Y. Su, W. Wang, and E. Zhang, “Adaptive control scheme for USV trajectory tracking under complex environmental disturbances via deep reinforcement learning,” *IEEE Internet of Things Journal*, vol. 12, no. 11, pp. 15180–15193, 2025.
- [15] M. Brambilla, E. Ferrante, M. Birattari, and M. Dorigo, “Swarm robotics: A review from the swarm engineering perspective,” *Swarm Intelligence*, vol. 7, no. 1, pp. 1–41, 2013.
- [16] Y. Singh, S. Sharma, R. Sutton, D. Hatton, and A. Khan, “A constrained A* approach towards optimal path planning for an unmanned surface vehicle in a maritime environment containing dynamic obstacles and ocean currents,” *Ocean Engineering*, vol. 169, pp. 187–201, 2018.
- [17] X. Song and S. Hu, “2D path planning with Dubins-path-based A* algorithm for a fixed-wing UAV,” in *2017 3rd IEEE International Conference on Control Science and Systems Engineering (ICCSSE)*, pp. 69–73, 2017.
- [18] D. Zhang, Y. Xu, and X. Yao, “An improved path planning algorithm for unmanned aerial vehicle based on RRT-Connect,” in *2018 37th Chinese Control Conference (CCC)*, pp. 4854–4858, 2018.
- [19] H. Yang, Q. Jia, and W. Zhang, “An environmental potential field based RRT algorithm for UAV path planning,” in *2018 37th Chinese Control Conference (CCC)*, pp. 9922–9927, 2018.
- [20] H. V. Abeywickrama, B. A. Jayawickrama, Y. He, and E. Dutkiewicz, “Potential field based inter-UAV collision avoidance using virtual target relocation,” in *2018 IEEE 87th Vehicular Technology Conference (VTC Spring)*, pp. 1–5, 2018.
- [21] M. D. Phung and Q. P. Ha, “Safety-enhanced UAV path planning with spherical vector-based particle swarm optimization,” *Applied Soft Computing*, vol. 107, p. 107376, 2021.
- [22] J. Li, J. Chavez-Galaviz, K. Azizadenesheli, and N. Mahmoudian, “Dynamic obstacle avoidance for USVs using cross-domain deep reinforcement learning and neural network model predictive controller,” *Sensors*, vol. 23, no. 7, p. 3572, 2023.
- [23] K. He, X. Zhang, S. Ren, and J. Sun, “Delving deep into rectifiers: Surpassing human-level performance on ImageNet classification,” in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pp. 1026–1034, 2015.
- [24] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” in *International Conference on Learning Representations (ICLR)*, 2015.
- [25] Y. Bengio, J. Louradour, R. Collobert, and J. Weston, “Curriculum learning,” in *Proceedings of the 26th Annual International Conference on Machine Learning (ICML)*, pp. 41–48, 2009.

- [26] C. M. Bishop, *Pattern Recognition and Machine Learning*. Springer, 2006.
- [27] C. Yu, A. Velu, E. Vinitzky, J. Gao, Y. Wang, A. Bayen, and Y. Wu, “The surprising effectiveness of PPO in cooperative multi-agent games,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- [28] T. Rashid, M. Samvelyan, C. Schröder de Witt, G. Farquhar, J. Foerster, and S. Whiteson, “QMIX: Monotonic value function factorisation for deep multi-agent reinforcement learning,” in *Proceedings of the 35th International Conference on Machine Learning (ICML)*, pp. 4295–4304, 2018.
- [29] J. Tobin, R. Fong, A. Ray, J. Schneider, W. Zaremba, and P. Abbeel, “Domain randomization for transferring deep neural networks from simulation to the real world,” in *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pp. 23–30, 2017.